TÀI LIỆU HỌC VÀ CHUẨN BỊ THUYẾT TRÌNH

Mekdala Nounou (B25CHHT124) · Nhóm 8 · Tìm kiếm và Truy xuất thông tin · Đề tài LinCIR

1. Vai trò của bạn

Tổng quan lý thuyết (CIR, ZS-CIR, CLIP, Pic2Word, SEARLE) và liên hệ với các độ đo IR; phân tích định tính; thiết kế slides thuyết trình.

Slide	Nội dung	Thời gian
3	Bài toán CIR, vì sao zero-shot	1:00
4	Ý tưởng token giả	1:00

2. Bức tranh chung của đề tài (cả nhóm cần nắm)

Bài toán. Truy xuất ảnh kết hợp (Composed Image Retrieval – CIR): truy vấn gồm một ảnh tham chiếu và một câu mô tả thay đổi ("chiếc váy này nhưng màu bạc, tay ngắn hơn"); hệ thống trả về ảnh thỏa cả hai. Dữ liệu bộ ba ⟨ảnh, câu, ảnh đích⟩ đắt và nhỏ, nên hướng **zero-shot** huấn luyện không cần bộ ba.

Bài báo. LinCIR (Gu và cộng sự, CVPR 2024) học một mạng chiếu φ (MLP 3 lớp) biến một vector thành "từ giả" [$] trong không gian token của CLIP, **chỉ bằng văn bản**: che các từ khóa của câu bằng [$] = φ(vector của câu + nhiễu) và ép câu đã che có cùng vector với câu gốc (Self-Masking Projection, mất mát MSE). Khi truy vấn, thay vector câu bằng vector ảnh: "a photo of [$] that {câu điều chỉnh}" → tìm ảnh theo cosine.

Nhóm đã làm. (1) Chuyển mã nguồn chính thức sang Python 3.13 / transformers 5.x, kiểm chứng sai lệch 0 so với mô hình gốc. (2) Tái hiện: checkpoint chính thức đạt FashionIQ R@10 = 26,35 / R@50 = 46,12 (bài báo 26,28 / 46,49). (3) Hai cải tiến: **A** – thêm mất mát đối sánh InfoNCE; **B** – nhiễu có hướng theo modality gap. (4) Huấn luyện baseline, A, B, A+B trên Kaggle (2 × T4), mỗi biến thể 3 seed, 5.000 bước; đánh giá FashionIQ val + CIRCO val; kiểm định thống kê theo truy vấn.

Kết quả chính. B (nhiễu có hướng) tốt hơn baseline có ý nghĩa thống kê: FashionIQ R@10 +0,60 ($p = 0,006$), R@50 +1,27 ($p < 0,001$), CIRCO mAP@25/50 tăng có ý nghĩa; B còn vượt checkpoint chính thức 20.000 bước. **A (InfoNCE) không tốt hơn** trên FashionIQ và **kém rõ trên CIRCO** (mAP@5 −2,45, KTC 95% nằm dưới 0); A+B tương tự A. Giải thích: độ nhất quán của φ giữa ảnh và văn bản (cosine) B 0,84 > baseline 0,80 > A 0,64 — cùng thứ tự với CIRCO. Kết luận: H2 được ủng hộ, H1 và H3 bị bác bỏ.

Hạng mục	Số liệu / cấu hình
Backbone	CLIP ViT-L/14 (đóng băng); chỉ huấn luyện φ
Huấn luyện	AdamW, lr 1e-4, wd 0,01, batch 512, dropout 0,5, 5.000 bước (bài báo 20.000)
Dữ liệu train	Chỉ văn bản: chú thích CC3M + 2,47 triệu prompt Stable Diffusion + prompt Midjourney
Đánh giá	FashionIQ val (6.016 truy vấn, 3 nhóm, R@10/R@50); CIRCO val (220

	truy vấn, 123.403 ảnh, mAP@K)
Tái hiện	Checkpoint chính thức: FIQ R@10 26,35 vs 26,28; R@50 46,12 vs 46,49 (lệch lớn nhất 0,77 điểm)
Cải tiến A	$L = MSE + 0{,}5 \cdot InfoNCE$ ($\tau = 0{,}07$, 511 mẫu âm trong batch)
Cải tiến B	$n = 0{,}5 \cdot \Delta + u \cdot \varepsilon$; Δ = tâm ảnh − tâm văn bản trên 5.000 cặp COCO ($\|\Delta\| = 13{,}87$)
Giao thức	3 seed (12345, 2024, 7), checkpoint bước cuối, paired bootstrap 10.000 lần + Wilcoxon, kết luận khi $p < 0{,}05$
Tài nguyên	Kaggle 2 × T4 16 GB, 30 giờ GPU/tuần, giới hạn 12 giờ/phiên; 1,45 s/bước, 2,0 giờ/run
Kết quả (TB 3 seed)	FIQ R@10: baseline 25,90 · A 25,54 · B 26,50 · A+B 25,44; CIRCO mAP@5: 10,47 · 8,02 · 10,94 · 7,81

3. Trình bày rõ ràng, dễ hiểu (đọc trước khi tập)

Mẹo thuyết trình

- **Mở đầu bằng mạch chính trong 3 câu:** (1) Truy xuất ảnh kết hợp cần dữ liệu có nhãn rất tốn kém. (2) LinCIR huấn luyện chỉ bằng văn bản nên không cần dữ liệu đó. (3) Nhóm tái hiện LinCIR, thử hai cải tiến, chứng minh bằng kiểm định rằng một cải tiến tốt hơn và giải thích vì sao cải tiến còn lại kém hơn.
- **Mỗi slide theo trình tự:** nêu ý chính (tiêu đề) → nêu một con số → giải thích con số đó có nghĩa gì → nối sang slide sau. Không đọc toàn bộ bảng; chỉ nêu dòng hoặc cột cần thiết.
- **Diễn giải con số ngay khi nêu:** R@10 = 26 nghĩa là trong 26% số truy vấn, ảnh đúng nằm trong 10 kết quả đầu tiên; tăng 0,60 điểm R@10 tương đương thêm khoảng 6 truy vấn tìm đúng trên mỗi 1.000 truy vấn.
- **Thuật ngữ:** nêu tên tiếng Việt kèm tên tiếng Anh và định nghĩa một câu ở lần xuất hiện đầu tiên; các lần sau dùng đúng một tên đó.
- **Khi nói, làm tròn hợp lý** ("khoảng 26%", "giảm khoảng 23%"); số chính xác đã có trên slide và trong báo cáo.
- **Ngắt nghỉ sau kết luận chính** (slide 12) trước khi chuyển sang phần giải thích nguyên nhân.
- **Trả lời câu hỏi:** câu đầu nêu thẳng kết luận, câu sau nêu căn cứ (số liệu, mục trong báo cáo).

Slide của bạn: ý chính và con số cần nêu

Slide	Ý chính nói thành lời	Một con số và ý nghĩa
3	Truy vấn gồm một ảnh tham chiếu và một câu mô tả thay đổi; hệ thống phải tìm ảnh giữ đặc điểm của ảnh tham chiếu và áp dụng thay đổi. Bộ ba (ảnh tham chiếu, câu, ảnh đích) phải gán nhãn tay nên đắt và nhỏ, vì vậy cần zero-shot: không dùng bộ ba nào khi huấn luyện.	FashionIQ chỉ có 46,6 nghìn bộ ba, CIRR 28,8 nghìn

4	Ảnh tham chiếu được chuyển thành một token giả [$] và ghép vào câu "a photo of [$] that …"; bộ mã hóa văn bản tạo vector truy vấn để tìm ảnh. Chỉ cần huấn luyện mạng chiếu φ.	—

Thuật ngữ: định nghĩa ngắn

Thuật ngữ	Định nghĩa	Ví dụ trong đề tài
Truy xuất ảnh kết hợp (CIR)	Tìm ảnh bằng truy vấn gồm một ảnh tham chiếu và một câu mô tả thay đổi	Ảnh váy hoa xanh + "màu bạc, tay ngắn hơn" → tìm ảnh váy bạc tay ngắn
Zero-shot	Mô hình không được huấn luyện trên dữ liệu có nhãn của bài toán đích, được đánh giá trực tiếp	LinCIR không dùng bộ ba nào của FashionIQ hay CIRCO khi huấn luyện
Bộ ba có nhãn	Ảnh tham chiếu – câu điều chỉnh – ảnh đích, do người gán thủ công	FashionIQ có khoảng 46,6 nghìn bộ ba huấn luyện
CLIP	Mô hình gồm bộ mã hóa ảnh và bộ mã hóa văn bản, đưa ảnh và câu mô tả tương ứng về gần nhau	Nhóm dùng CLIP ViT-L/14, giữ nguyên không huấn luyện lại
Vector nhúng	Dãy số (768 chiều với ViT-L) biểu diễn nội dung của một ảnh hoặc một câu	Mỗi ảnh trong kho được mã hóa thành một vector
Độ tương đồng cosine	Mức độ cùng hướng của hai vector, càng gần 1 càng giống	Kết quả truy xuất được xếp theo cosine giữa truy vấn và từng ảnh
Token giả [$]	Một vector đặt vào vị trí của một từ trong câu, đại diện cho ảnh tham chiếu	Câu truy vấn: "a photo of [$] that is silver with shorter sleeves"
Mạng chiếu φ	Mạng nơ-ron nhỏ (3 lớp) biến vector thành token giả; là thành phần duy nhất được huấn luyện	Cả 4 biến thể của nhóm chỉ khác nhau ở cách huấn luyện φ
Self-Masking Projection (SMP)	Che các cụm tính từ – danh từ của câu bằng [$] và huấn luyện φ để câu đã che giữ nguyên vector của câu gốc	"gray cat sleeps on a pillow" → "[$] sleeps on [$]"
Khoảng cách ảnh – văn bản (modality gap)	Vector ảnh và vector văn bản của CLIP nằm ở hai vùng tách biệt	Ảnh và chú thích của chính nó chỉ có cosine trung bình 0,26 (5.000 cặp COCO)
Nhiễu khi huấn luyện	Thành phần ngẫu nhiên cộng vào vector văn bản để φ chịu được khác biệt giữa ảnh và văn bản	LinCIR dùng $n = u \cdot \varepsilon$, $u \sim U(0,1)$, $\varepsilon \sim N(0, I)$
Cải tiến B – nhiễu có hướng	Cộng thêm vector Δ (tâm vector ảnh trừ tâm vector văn bản) vào nhiễu, đẩy đầu vào của φ về phía vùng ảnh	$n = 0{,}5 \cdot \Delta + u \cdot \varepsilon$, Δ tính trên 5.000 cặp COCO
Cải tiến A – InfoNCE	Hàm mất mát đối sánh: mỗi câu phải gần chính nó hơn 511 câu khác trong cùng batch	$L = MSE + 0{,}5 \cdot InfoNCE$
Baseline	LinCIR gốc do nhóm tự huấn luyện, cùng cấu hình với các biến thể, dùng	5.000 bước, 3 seed

	làm mốc so sánh	
Checkpoint	Trọng số của mô hình được lưu tại một thời điểm huấn luyện	Checkpoint chính thức của tác giả huấn luyện 20.000 bước
Bước huấn luyện	Một lần cập nhật trọng số trên một batch 512 câu	5.000 bước mất khoảng 2 giờ trên GPU T4
Seed	Giá trị khởi tạo bộ sinh số ngẫu nhiên; khác seed thì thứ tự dữ liệu và nhiễu khác nhau	Mỗi biến thể chạy với 3 seed: 12345, 2024, 7
Độ lệch chuẩn (±)	Mức dao động của kết quả giữa các lần chạy khác seed	B: R@10 = 26,50 ± 0,04 — rất ổn định
R@10, R@50 (Recall@K)	Tỷ lệ truy vấn có ảnh đích nằm trong K kết quả đầu	FashionIQ chỉ có một ảnh đúng cho mỗi truy vấn
mAP@5	Trung bình độ chính xác trên K = 5 kết quả đầu, dùng khi mỗi truy vấn có nhiều ảnh đúng	CIRCO có trung bình 4,16 ảnh đúng mỗi truy vấn
p-value	Xác suất quan sát được mức chênh lệch như vậy nếu thực tế hai phương pháp ngang nhau	B so với baseline, FashionIQ R@10: p = 0,006
Khoảng tin cậy 95% (KTC)	Khoảng giá trị của mức chênh lệch thật với độ tin cậy 95%; nếu toàn bộ khoảng lớn hơn 0 thì cải tiến tốt hơn	B, R@50: Δ = +1,27, KTC [+0,81; +1,73]
Paired bootstrap	Lấy mẫu lại các truy vấn 10.000 lần, tính lại mức chênh mỗi lần để ước lượng p-value và KTC	So từng truy vấn của B với cùng truy vấn đó của baseline
Âm tính giả	Ảnh thực tế thỏa truy vấn nhưng không được gán nhãn là đáp án	Lý do bài báo khuyến nghị dùng mAP và K lớn thay vì R@1
Ablation	So sánh các biến thể bật/tắt từng thành phần để tách đóng góp của mỗi thành phần	Baseline, A, B, A+B

Cách đọc ký hiệu trên slide

Lần đầu gặp [$] trên slide, nói thêm: "ký hiệu đô-la trong ngoặc vuông là token giả"; các lần sau chỉ nói "token giả". Ví dụ câu nói: "Mạng phi biến ảnh tham chiếu thành một token giả, ghép vào câu mô tả thay đổi."

Ký hiệu	Đọc là	Nghĩa
φ	"phi"	Mạng chiếu 3 lớp, phần duy nhất được huấn luyện; biến một vector (ảnh hoặc câu) thành một token
[$]	"token giả" (hoặc "token đô-la")	Vị trí trong câu được thay bằng đầu ra của φ; "a photo of [$] that is blue" đọc là "a photo of token giả that is blue"
Δ	"đen-ta"	Vector chênh lệch: tâm vector ảnh trừ tâm vector văn bản
ε	"ép-xi-lon"	Nhiễu ngẫu nhiên theo phân phối chuẩn

u · ε	"u nhân ép-xi-lon"	Nhiễu của LinCIR; u là hệ số ngẫu nhiên từ 0 đến 1
α	"an-pha"	Hệ số của Δ trong cải tiến B (0,5)
λ	"lam-đa"	Trọng số của InfoNCE trong cải tiến A (0,5)
τ	"tô"	Nhiệt độ của InfoNCE (0,07)
z_c	"z c"	Vector của câu gốc
ẑ_c	"z c mũ"	Vector của câu đã che từ khóa bằng token giả
L_SMP	"hàm mất mát SMP"	Hàm mất mát MSE của Self-Masking Projection
R@K, R@10	"Recall tại K", "Recall tại 10"	Tỉ lệ truy vấn có ảnh đích trong K kết quả đầu
mAP@5	"m-A-P tại 5"	Độ chính xác trung bình trên 5 kết quả đầu
±	"cộng trừ"	Độ lệch chuẩn qua 3 seed; "26,50 ± 0,04" đọc là "26,50 cộng trừ 0,04"
p = 0,006	"p bằng không phẩy không không sáu"	Xác suất thấy mức chênh này nếu cải tiến thật ra không có tác dụng
InfoNCE, CLIP	"in-phô en-xi-i", "clíp"	Đọc thẳng tên tiếng Anh; tương tự baseline, seed, batch

4. Kiến thức và nội dung công việc

Truy xuất thông tin (chương I của môn học)

- IR: tìm tài liệu (thường phi cấu trúc) thỏa nhu cầu thông tin từ bộ sưu tập lớn. Mô hình tìm kiếm cổ điển: nhiệm vụ → nhu cầu thông tin → truy vấn → máy tìm kiếm + bộ sưu tập → kết quả → tinh chỉnh truy vấn.
- Precision = tỷ lệ tài liệu truy xuất thực sự liên quan; Recall = tỷ lệ tài liệu liên quan đã được truy xuất. Với danh sách xếp hạng: Recall@K, Precision@K, AP/mAP.
- Mô hình Boolean + chỉ mục ngược: khớp chính xác, không xếp hạng. CLIP + tìm kiếm vector: mã hóa mọi ảnh thành vector, truy vấn thành vector, xếp hạng theo cosine — một mô hình truy xuất có xếp hạng.

CIR và zero-shot CIR

- CIR: truy vấn = ảnh tham chiếu + câu mô tả thay đổi; ví dụ FashionIQ: váy hoa xanh + "is shiny and silver with shorter sleeves", "fit and flare" → váy bạc bóng.
- CIR có giám sát (TIRG, Combiner) học từ bộ ba có nhãn — đắt (FashionIQ ~46,6 nghìn, CIRR ~28,8 nghìn bộ ba), khó tổng quát. Zero-shot CIR không dùng bộ ba; huấn luyện trên dữ liệu sẵn có rồi đánh giá trực tiếp.

CLIP, Pic2Word, SEARLE

- CLIP: hai bộ mã hóa (ảnh, văn bản) học đối sánh trên 400 triệu cặp ảnh–văn bản → không gian chung; ảnh và câu mô tả của nó gần nhau.

- Pic2Word và SEARLE: học "từ giả" [$] đại diện cho ảnh, ghép vào câu; hạn chế là câu mẫu cố định và cần ảnh khi huấn luyện → LinCIR giải quyết bằng huấn luyện chỉ với văn bản (Trung trình bày tiếp).

Phân tích định tính

- Từ danh sách top-10 của từng truy vấn (topk_fiq_*.json), chọn ví dụ: (1) biến thể cải tiến đưa ảnh đích lên hạng 1 trong khi baseline không có trong top-5; (2) cả hai cùng thất bại.
- Đọc ví dụ: các ảnh xếp đầu có giữ đặc điểm của ảnh tham chiếu không, có áp dụng đúng thay đổi (màu, tay áo, kiểu dáng) không; thất bại thường do câu mơ hồ ("is the same"), thay đổi tinh tế, hoặc "âm tính giả" (ảnh đúng nhưng không được gán nhãn).
- Hình 5.3 (results/figures/qualitative_fiq_1.png): câu "is strapless with lighter colors" và "is lighter and blue and sleeveless"; B xếp đúng ảnh đích (váy dài cúp ngực, nền sáng) hạng 1, baseline trả về váy ngắn màu đậm, bỏ qua dáng váy và yêu cầu "sáng màu hơn". Nhiều ảnh top-5 thỏa phần lớn điều kiện nhưng không phải ảnh đích được gán nhãn → âm tính giả.

Thiết kế slides

- 16 slide, ~15 phút (slides/khung_slides.md). Mỗi slide một ý, ≤ 6 dòng; số liệu luôn có nguồn (bảng nào trong báo cáo); slide kết quả nêu cả p-value và KTC, không chỉ Δ.
- Dùng lại hình trong report/figures và results/figures; giữ một bảng màu, phông chữ thống nhất.

Tệp liên quan trong dự án

- report/figures/cir_example.png — ví dụ CIR thật
- slides/khung_slides.md, slides/QA_du_kien.md
- results/figures/qualitative_fiq_*.png (sau phiên eval)
- Chapter_I.pdf (bài giảng): slide 6–8

5. Kịch bản trình bày chi tiết

Slide	Ý chính cần nói
3	Kể ví dụ chiếc váy: ảnh tham chiếu + "màu bạc, tay ngắn hơn" → ảnh đích. Đây là truy xuất ảnh kết hợp, nhu cầu thông tin không diễn đạt trọn bằng chỉ chữ hay chỉ ảnh. Vì sao zero-shot: bộ ba phải gán nhãn tay, nhỏ (FashionIQ 46,6 nghìn, CIRR 28,8 nghìn) → mô hình có giám sát khó tổng quát → zero-shot không dùng bộ ba.
4	Ý tưởng: ảnh → [$] trong không gian token; câu "a photo of [$] that …" → vector truy vấn → tìm ảnh. Chỉ cần học φ. Đây là ý tưởng chung của các phương pháp zero-shot.

6. Câu hỏi phản biện dự kiến

H1. CIR khác tìm ảnh bằng văn bản thế nào?

→ Văn bản trong CIR chỉ mô tả phần thay đổi, không mô tả toàn bộ ảnh đích; hệ thống phải giữ đặc điểm của ảnh tham chiếu và áp dụng thay đổi.

H2. Tại sao gọi là zero-shot?

→ Không dùng bất kỳ bộ ba CIR có nhãn nào khi huấn luyện; mô hình được đánh giá trực tiếp trên FashionIQ, CIRCO.

H3. Recall@K khác Precision thế nào, sao CIRCO dùng mAP?

→ FashionIQ chỉ có 1 ảnh đúng → quan tâm ảnh đó có trong top-K (Recall@K). CIRCO có nhiều ảnh đúng → mAP@K đánh giá cả số lượng và vị trí của các ảnh đúng.

H4. Tìm kiếm vector khác chỉ mục ngược thế nào?

→ Chỉ mục ngược tra danh sách tài liệu chứa từ, khớp chính xác (Boolean). Tìm kiếm vector so độ tương đồng liên tục (cosine) giữa vector truy vấn và vector ảnh, cho danh sách có xếp hạng.

H5. Ví dụ thất bại cho thấy điều gì?

→ Trong Hình 5.3, top-5 có nhiều váy không dây tông xanh — đúng phần lớn yêu cầu nhưng không phải ảnh đích được gán nhãn: âm tính giả làm R@K đánh giá thấp chất lượng thực. Ngoài ra câu mơ hồ ("is the same") hay thay đổi tinh tế cũng gây thất bại.

H6. CLIP được huấn luyện thế nào?

→ Đối sánh 400 triệu cặp ảnh–chú thích: kéo vector ảnh và chú thích của nó lại gần, đẩy xa các cặp khác trong batch.

7. Tự kiểm tra trước buổi thuyết trình

- ☐ Giải thích CIR bằng ví dụ của chính mình trong 30 giây.
- ☐ Phân biệt Precision, Recall, Recall@K, mAP@K.
- ☐ Nói được 2 hạn chế của Pic2Word/SEARLE.
- ☐ Chọn và bình luận 2 ví dụ định tính.

8. Đọc thêm

- Báo cáo: chương 1–2, mục 5.8
- Bài giảng chương I: slide 6–8 (mô hình tìm kiếm, Precision/Recall)
- Bài báo LinCIR: mục 1–2; CLIP (Radford 2021): mục 1–2