# TÀI LIỆU HỌC VÀ CHUẨN BỊ THUYẾT TRÌNH

*Lâm Thành Trung (B25CHHT117) · Nhóm 8 · Tìm kiếm và Truy xuất thông tin · Đề tài LinCIR*

## 1. Vai trò của bạn

Đề xuất và cài đặt cải tiến A (bổ sung InfoNCE vào SMP); phân tích đường học theo số bước huấn luyện.

Tâm trình bày toàn bộ slide. Bạn **hỗ trợ trả lời phản biện** cho các slide liên quan đến phần việc của bạn dưới đây; khi Tâm mời, trả lời ngắn, nêu số liệu và nguồn (bảng nào trong báo cáo).

| Slide | Nội dung | Người trình bày |
|---|---|---|
| 7 | Self-Masking Projection | Tâm trình bày |
| 9 | Cải tiến A: InfoNCE (H1) | Tâm trình bày |
| 14 | Vì sao: độ nhất quán của φ | Tâm trình bày |

## 2. Bức tranh chung của đề tài (cả nhóm cần nắm)

### Tóm tắt dễ hiểu (đọc đầu tiên)

#### Bài báo nói về điều gì

**Bài toán.** Bạn đang xem ảnh một chiếc váy hoa màu xanh trên trang bán hàng. Bạn muốn tìm một chiếc gần giống nhưng có thêm vài thay đổi, và gõ: "màu bạc, bóng hơn, tay ngắn hơn". Hệ thống phải tìm trong hàng chục nghìn ảnh ra chiếc váy vừa giữ kiểu dáng của ảnh ban đầu, vừa có đúng các thay đổi đó. Bài toán tìm kiếm bằng một ảnh kèm một câu mô tả thay đổi như vậy gọi là **truy xuất ảnh kết hợp**.

Bài toán này khó vì câu "màu bạc, tay ngắn hơn" không tự mô tả được chiếc váy cần tìm. Nó chỉ có nghĩa khi đặt cạnh ảnh ban đầu. Hệ thống phải hiểu cả ảnh lẫn câu cùng lúc.

**Cách làm cũ và chỗ tốn kém.** Cách đơn giản là thuê người tạo dữ liệu mẫu: mỗi mẫu gồm ảnh ban đầu, câu mô tả thay đổi và ảnh đúng cần tìm. Việc này rất tốn công, nên bộ dữ liệu lớn nhất cũng chỉ có khoảng 46 nghìn mẫu. Mô hình học từ dữ liệu thời trang thì cũng chỉ dùng tốt cho thời trang.

Một số phương pháp gần đây tránh được việc thuê người gán nhãn. Ý tưởng chung là đổi ảnh ban đầu thành một "từ đặc biệt", rồi ghép từ đó vào câu tìm kiếm, ví dụ: "ảnh của [từ đặc biệt], màu bạc, tay ngắn hơn". Một mô hình có sẵn tên CLIP, vốn đã được huấn luyện trên hàng trăm triệu cặp ảnh và câu, sẽ biến câu này thành con số rồi so với từng ảnh trong kho. Chỉ cần dạy một mạng nhỏ (gọi là φ) cách đổi ảnh thành từ đặc biệt.

Tuy vậy, các phương pháp trước vẫn dùng ảnh khi dạy mạng φ. Việc này nặng: bộ ảnh huấn luyện chiếm khoảng 430 GB, trong khi phần chữ đi kèm chỉ 125 MB. Chúng cũng chỉ học với một mẫu câu cố định.

**Ý tưởng của LinCIR.** Tác giả (công ty NAVER, Hàn Quốc, công bố năm 2024) đề xuất dạy mạng φ **chỉ bằng chữ, không cần ảnh**. Cách làm:

1. Lấy một câu, ví dụ "con mèo xám ngủ trên gối".
2. Che các từ quan trọng, câu thành "[…] ngủ trên […]".
3. Cho mạng φ đọc câu gốc rồi tạo ra một từ đặc biệt điền vào chỗ trống.
4. Yêu cầu câu đã điền phải mang nghĩa giống câu gốc.

Muốn làm được, mạng φ phải học cách gói nội dung chính của cả câu vào một từ. Khi dùng thật, đưa ảnh vào thay cho câu, mạng φ tạo ra từ đặc biệt đại diện cho ảnh.

Có một trở ngại: trong CLIP, con số biểu diễn ảnh và con số biểu diễn chữ nằm ở hai vùng khác nhau, dù cùng nói về một thứ. Mạng φ học trên chữ nhưng lại phải xử lý ảnh. Tác giả giải quyết bằng cách thêm nhiễu ngẫu nhiên vào đầu vào khi huấn luyện, để mạng quen với những đầu vào lệch khỏi vùng chữ.

**Kết quả bài báo.** LinCIR đạt kết quả tốt nhất trên bốn bộ đánh giá, huấn luyện nhanh hơn các phương pháp trước 6 đến 8 lần, và trên bộ thời trang còn vượt một phương pháp phải dùng dữ liệu do người gán nhãn.

### Nhóm 8 đã làm gì

**1. Dựng lại và kiểm tra.** Mã nguồn của tác giả viết cho phiên bản thư viện cũ, không chạy được trên máy hiện nay. Nhóm viết lại phần bị hỏng, sửa 4 lỗi, rồi kiểm tra: phần viết lại cho ra con số giống hệt bản gốc. Sau đó nhóm chạy lại mô hình tác giả công bố bằng mã của nhóm. Kết quả khớp bài báo, lệch không quá 0,77 điểm. Như vậy cách đánh giá của nhóm đáng tin.

**2. Đặt câu hỏi.** LinCIR có hai thành phần chính: cách chấm điểm khi dạy mạng φ, và phần nhiễu. Nhóm hỏi: sửa một trong hai thành phần này thì kết quả có tốt hơn không?

**3. Hai cải tiến.**

- **Cải tiến A (sửa cách chấm điểm).** Cách chấm gốc chỉ yêu cầu câu đã điền giống câu gốc. Nó không phạt trường hợp câu đã điền cũng giống nhiều câu khác. Nhóm thêm một yêu cầu: câu đã điền phải giống câu gốc **hơn** 511 câu khác đang xét cùng lúc. Kỳ vọng là mạng φ phân biệt rõ hơn, nên tìm kiếm chính xác hơn.
- **Cải tiến B (sửa phần nhiễu).** Nhiễu gốc lệch ngẫu nhiên theo mọi hướng. Nhóm đo hướng từ vùng chữ sang vùng ảnh, rồi cho nhiễu lệch có chủ đích về phía vùng ảnh. Khi đó mạng φ được luyện với đầu vào gần với ảnh thật mà nó sẽ gặp khi dùng.
- **Kết hợp A+B** để xem hai cải tiến có cộng thêm cho nhau không.

**4. Thử nghiệm công bằng.** Nhóm chạy cả bốn phiên bản (bản gốc, A, B, A+B) với cùng điều kiện, mỗi phiên bản 3 lần với khởi tạo ngẫu nhiên khác nhau, tổng cộng 12 lần. Thực nghiệm chạy trên máy chủ GPU miễn phí của Kaggle, dùng gần 23 trên 30 giờ được phép mỗi tuần.

Kết quả được đánh giá trên hai bộ dữ liệu: thời trang (FashionIQ) và ảnh đời thực (CIRCO). Mọi chênh lệch đều được kiểm định thống kê để chắc rằng không do ngẫu nhiên.

### Kết quả

- **Cải tiến B tốt hơn bản gốc, và có ý nghĩa thống kê.** Trên bộ thời trang, cứ 1.000 lượt tìm kiếm thì B tìm đúng thêm khoảng 6 lượt trong 10 kết quả đầu. B chỉ huấn luyện bằng một phần tư thời gian nhưng vẫn vượt cả mô hình tác giả công bố.
- **Cải tiến A làm kết quả kém đi,** rõ nhất trên ảnh đời thực (điểm giảm từ 10,47 xuống 8,02). A+B cũng kém.

**Vì sao.** Nhóm đưa cùng một cặp ảnh và câu mô tả vào mạng φ, rồi đo hai đầu ra giống nhau đến mức nào:

- Với B, hai đầu ra giống nhau nhất: mạng xử lý ảnh nhất quán với cách nó xử lý chữ.
- Với A, độ giống giảm mạnh. Yêu cầu "phân biệt với 511 câu khác" khiến mạng học những chi tiết chỉ có ở chữ, mà ảnh không có.

**Kết luận của nhóm.** Với LinCIR, điều quan trọng nhất là mạng φ xử lý ảnh nhất quán với chữ. Làm cho mạng phân biệt các câu tốt hơn thì không giúp ích. Kết luận này có số đo trực tiếp và kiểm định thống kê làm căn cứ, không phải phỏng đoán.

## Tóm tắt kỹ thuật

**Bài toán.** Truy xuất ảnh kết hợp (Composed Image Retrieval – CIR): truy vấn gồm một ảnh tham chiếu và một câu mô tả thay đổi (“chiếc váy này nhưng màu bạc, tay ngắn hơn”); hệ thống trả về ảnh thỏa cả hai. Dữ liệu bộ ba ⟨ảnh, câu, ảnh đích⟩ đắt và nhỏ, nên hướng **zero-shot** huấn luyện không cần bộ ba.

**Bài báo.** LinCIR (Gu và cộng sự, CVPR 2024) học một mạng chiếu φ (MLP 3 lớp) biến một vector thành “từ giả” [$] trong không gian token của CLIP, **chỉ bằng văn bản**: che các từ khóa của câu bằng [$] = φ(vector của câu + nhiễu) và ép câu đã che có cùng vector với câu gốc (Self-Masking Projection, mất mát MSE). Khi truy vấn, thay vector câu bằng vector ảnh: “a photo of [$] that {câu điều chỉnh}” → tìm ảnh theo cosine.

**Nhóm đã làm.** (1) Chuyển mã nguồn chính thức sang Python 3.13 / transformers 5.x, kiểm chứng sai lệch 0 so với mô hình gốc. (2) Tái hiện: checkpoint chính thức đạt FashionIQ R@10 = 26,35 / R@50 = 46,12 (bài báo 26,28 / 46,49). (3) Hai cải tiến: **A** – thêm mất mát đối sánh InfoNCE; **B** – nhiễu có hướng theo modality gap. (4) Huấn luyện baseline, A, B, A+B trên Kaggle (2 × T4), mỗi biến thể 3 seed, 5.000 bước; đánh giá FashionIQ val + CIRCO val; kiểm định thống kê theo truy vấn.

**Kết quả chính. B (nhiễu có hướng) tốt hơn baseline có ý nghĩa thống kê**: FashionIQ R@10 +0,60 ($p = 0,006$), R@50 +1,27 ($p < 0,001$), CIRCO mAP@25/50 tăng có ý nghĩa; B còn vượt checkpoint chính thức 20.000 bước. **A (InfoNCE) không tốt hơn** trên FashionIQ và **kém rõ trên CIRCO** (mAP@5 −2,45, KTC 95% nằm dưới 0); A+B tương tự A. Giải thích: độ nhất quán của φ giữa ảnh và văn bản (cosine) B 0,84 > baseline 0,80 > A 0,64 — cùng thứ tự với CIRCO. Kết luận: H2 được ủng hộ, H1 và H3 bị bác bỏ.

| Hạng mục | Số liệu / cấu hình |
|---|---|
| Backbone | CLIP ViT-L/14 (đóng băng); chỉ huấn luyện φ |
| Huấn luyện | AdamW, lr 1e-4, wd 0,01, batch 512, dropout 0,5, 5.000 bước (bài báo 20.000) |
| Dữ liệu train | Chỉ văn bản: chú thích CC3M + 2,47 triệu prompt Stable Diffusion + prompt Midjourney |
| Đánh giá | FashionIQ val (6.016 truy vấn, 3 nhóm, R@10/R@50); CIRCO val (220 truy vấn, 123.403 ảnh, mAP@K) |
| Tái hiện | Checkpoint chính thức: FIQ R@10 26,35 vs 26,28; R@50 46,12 vs 46,49 (lệch lớn nhất 0,77 điểm) |
| Cải tiến A | $L = MSE + 0{,}5 \cdot InfoNCE$ ($\tau = 0{,}07$, 511 mẫu âm trong batch) |
| Cải tiến B | $n = 0{,}5 \cdot \Delta + u \cdot \varepsilon$; Δ = tâm ảnh − tâm văn bản trên 5.000 cặp COCO ($\|\Delta\| = 13{,}87$) |
| Giao thức | 3 seed (12345, 2024, 7), checkpoint bước cuối, paired bootstrap 10.000 lần + Wilcoxon, kết luận khi $p < 0{,}05$ |
| Tài nguyên | Kaggle 2 × T4 16 GB, 30 giờ GPU/tuần, giới hạn 12 giờ/phiên; 1,45 s/bước, 2,0 giờ/run |
| Kết quả (TB 3 seed) | FIQ R@10: baseline 25,90 · A 25,54 · B 26,50 · A+B 25,44; CIRCO mAP@5: 10,47 · 8,02 · 10,94 · 7,81 |

## 3. Trình bày rõ ràng, dễ hiểu (đọc trước khi tập)

### Mẹo thuyết trình

- **Mở đầu bằng mạch chính trong 3 câu:** (1) Truy xuất ảnh kết hợp cần dữ liệu có nhãn rất tốn kém. (2) LinCIR huấn luyện chỉ bằng văn bản nên không cần dữ liệu đó. (3) Nhóm tái hiện LinCIR, thử hai cải tiến, chứng minh bằng kiểm định rằng một cải tiến tốt hơn và giải thích vì sao cải tiến còn lại kém hơn.
- **Mỗi slide theo trình tự:** nêu ý chính (tiêu đề) → nêu một con số → giải thích con số đó có nghĩa gì → nối sang slide sau. Không đọc toàn bộ bảng; chỉ nêu dòng hoặc cột cần thiết.
- **Diễn giải con số ngay khi nêu:** R@10 = 26 nghĩa là trong 26% số truy vấn, ảnh đúng nằm trong 10 kết quả đầu tiên; tăng 0,60 điểm R@10 tương đương thêm khoảng 6 truy vấn tìm đúng trên mỗi 1.000 truy vấn.
- **Thuật ngữ:** nêu tên tiếng Việt kèm tên tiếng Anh và định nghĩa một câu ở lần xuất hiện đầu tiên; các lần sau dùng đúng một tên đó.
- **Khi nói, làm tròn hợp lý** (“khoảng 26%”, “giảm khoảng 23%”); số chính xác đã có trên slide và trong báo cáo.
- **Ngắt nghỉ sau kết luận chính** (slide 13) trước khi chuyển sang phần giải thích nguyên nhân.
- **Trả lời câu hỏi:** câu đầu nêu thẳng kết luận, câu sau nêu căn cứ (số liệu, mục trong báo cáo).

## Slide liên quan: ý chính và con số cần nắm

| Slide | Ý chính nói thành lời | Một con số và ý nghĩa |
|---|---|---|
| 7 | Che tính từ, danh từ trong câu bằng [$], thay [$] bằng token do φ tạo từ chính câu gốc, rồi yêu cầu câu đã che có cùng vector với câu gốc (MSE). Ví dụ "gray cat sleeps on a pillow" thành "[$] sleeps on [$]". Nhờ vậy [$] học được bản tóm tắt một từ của câu. | — |
| 9 | Cải tiến A sửa hàm mất mát: MSE chỉ kéo câu đã che về câu gốc, không phạt khi nó cũng gần các câu khác, trong khi đánh giá là xếp hạng. Thêm InfoNCE với 511 câu khác trong batch làm mẫu âm. Giả thuyết H1: A tăng R@K, mAP@K so với baseline. | Chi phí chỉ tăng 2% thời gian mỗi bước (1,474 so với 1,448 giây) |
| 14 | Đo độ tương đồng giữa đầu ra của φ khi nhận ảnh và khi nhận văn bản của cùng một cặp; thứ tự trùng với thứ tự CIRCO mAP@5. InfoNCE buộc [$] mang đặc trưng phân biệt các câu, không chuyển được sang ảnh. A thấp hơn baseline ở mọi mốc huấn luyện. | B 0,84, baseline 0,80, A 0,64 |

## Thuật ngữ: định nghĩa ngắn

| Thuật ngữ | Định nghĩa | Ví dụ trong đề tài |
|---|---|---|
| Truy xuất ảnh kết hợp (CIR) | Tìm ảnh bằng truy vấn gồm một ảnh tham chiếu và một câu mô tả thay đổi | Ảnh váy hoa xanh + "màu bạc, tay ngắn hơn" → tìm ảnh váy bạc tay ngắn |
| Zero-shot | Mô hình không được huấn luyện trên dữ liệu có nhãn của bài toán đích, được đánh giá trực tiếp | LinCIR không dùng bộ ba nào của FashionIQ hay CIRCO khi huấn luyện |
| Bộ ba có nhãn | Ảnh tham chiếu – câu điều chỉnh – ảnh đích, do người gán thủ công | FashionIQ có khoảng 46,6 nghìn bộ ba huấn luyện |
| CLIP | Mô hình gồm bộ mã hóa ảnh và bộ mã hóa văn bản, đưa ảnh và câu mô tả tương ứng về gần nhau | Nhóm dùng CLIP ViT-L/14, giữ nguyên không huấn luyện lại |
| Vector nhúng | Dãy số (768 chiều với ViT-L) biểu diễn nội dung của một ảnh hoặc một câu | Mỗi ảnh trong kho được mã hóa thành một vector |
| Độ tương đồng cosine | Mức độ cùng hướng của hai vector, càng gần 1 càng giống | Kết quả truy xuất được xếp theo cosine giữa truy vấn và từng ảnh |
| Token giả [$] | Một vector đặt vào vị trí của một từ trong câu, đại diện cho ảnh tham chiếu | Câu truy vấn: "a photo of [$] that is silver with shorter sleeves" |
| Mạng chiếu φ | Mạng nơ-ron nhỏ (3 lớp) biến vector thành token giả; là thành phần duy nhất được huấn luyện | Cả 4 biến thể của nhóm chỉ khác nhau ở cách huấn luyện φ |
| Self-Masking Projection (SMP) | Che các cụm tính từ – danh từ của câu bằng [$] và huấn luyện φ để câu đã che giữ nguyên vector của câu gốc | "gray cat sleeps on a pillow" → "[$] sleeps on [$]" |

| | | |
|---|---|---|
| Khoảng cách ảnh – văn bản (modality gap) | Vector ảnh và vector văn bản của CLIP nằm ở hai vùng tách biệt | Ảnh và chú thích của chính nó chỉ có cosine trung bình 0,26 (5.000 cặp COCO) |
| Nhiễu khi huấn luyện | Thành phần ngẫu nhiên cộng vào vector văn bản để φ chịu được khác biệt giữa ảnh và văn bản | LinCIR dùng $n = u \cdot \varepsilon$, $u \sim U(0,1)$, $\varepsilon \sim N(0, I)$ |
| Cải tiến B – nhiễu có hướng | Cộng thêm vector Δ (tâm vector ảnh trừ tâm vector văn bản) vào nhiễu, đẩy đầu vào của φ về phía vùng ảnh | $n = 0{,}5 \cdot \Delta + u \cdot \varepsilon$, Δ tính trên 5.000 cặp COCO |
| Cải tiến A – InfoNCE | Hàm mất mát đối sánh: mỗi câu phải gần chính nó hơn 511 câu khác trong cùng batch | $L = MSE + 0{,}5 \cdot InfoNCE$ |
| Baseline | LinCIR gốc do nhóm tự huấn luyện, cùng cấu hình với các biến thể, dùng làm mốc so sánh | 5.000 bước, 3 seed |
| Checkpoint | Trọng số của mô hình được lưu tại một thời điểm huấn luyện | Checkpoint chính thức của tác giả huấn luyện 20.000 bước |
| Bước huấn luyện | Một lần cập nhật trọng số trên một batch 512 câu | 5.000 bước mất khoảng 2 giờ trên GPU T4 |
| Seed | Giá trị khởi tạo bộ sinh số ngẫu nhiên; khác seed thì thứ tự dữ liệu và nhiễu khác nhau | Mỗi biến thể chạy với 3 seed: 12345, 2024, 7 |
| Độ lệch chuẩn (±) | Mức dao động của kết quả giữa các lần chạy khác seed | B: R@10 = 26,50 ± 0,04 — rất ổn định |
| R@10, R@50 (Recall@K) | Tỷ lệ truy vấn có ảnh đích nằm trong K kết quả đầu | FashionIQ chỉ có một ảnh đúng cho mỗi truy vấn |
| mAP@5 | Trung bình độ chính xác trên K = 5 kết quả đầu, dùng khi mỗi truy vấn có nhiều ảnh đúng | CIRCO có trung bình 4,16 ảnh đúng mỗi truy vấn |
| p-value | Xác suất quan sát được mức chênh lệch như vậy nếu thực tế hai phương pháp ngang nhau | B so với baseline, FashionIQ R@10: p = 0,006 |
| Khoảng tin cậy 95% (KTC) | Khoảng giá trị của mức chênh lệch thật với độ tin cậy 95%; nếu toàn bộ khoảng lớn hơn 0 thì cải tiến tốt hơn | B, R@50: Δ = +1,27, KTC [+0,81; +1,73] |
| Paired bootstrap | Lấy mẫu lại các truy vấn 10.000 lần, tính lại mức chênh mỗi lần để ước lượng p-value và KTC | So từng truy vấn của B với cùng truy vấn đó của baseline |
| Âm tính giả | Ảnh thực tế thỏa truy vấn nhưng không được gán nhãn là đáp án | Lý do bài báo khuyến nghị dùng mAP và K lớn thay vì R@1 |
| Ablation | So sánh các biến thể bật/tắt từng thành phần để tách đóng góp của mỗi thành phần | Baseline, A, B, A+B |

### Cách đọc ký hiệu trên slide

Lần đầu gặp [$] trên slide, nói thêm: "ký hiệu đô-la trong ngoặc vuông là token giả"; các lần sau chỉ nói "token giả". Ví dụ câu nói: "Mạng phi biến ảnh tham chiếu thành một token giả, ghép vào câu mô tả thay đổi."

| Ký hiệu | Đọc là | Nghĩa |
|---|---|---|
| φ | "phi" | Mạng chiếu 3 lớp, phần duy nhất được huấn luyện; biến một vector (ảnh hoặc câu) thành một token |
| [$] | "token giả" (hoặc "token đô-la") | Vị trí trong câu được thay bằng đầu ra của φ; "a photo of [$] that is blue" đọc là "a photo of token giả that is blue" |
| Δ | "đen-ta" | Vector chênh lệch: tâm vector ảnh trừ tâm vector văn bản |
| ε | "ép-xi-lon" | Nhiễu ngẫu nhiên theo phân phối chuẩn |
| u · ε | "u nhân ép-xi-lon" | Nhiễu của LinCIR; u là hệ số ngẫu nhiên từ 0 đến 1 |
| α | "an-pha" | Hệ số của Δ trong cải tiến B (0,5) |
| λ | "lam-đa" | Trọng số của InfoNCE trong cải tiến A (0,5) |
| τ | "tô" | Nhiệt độ của InfoNCE (0,07) |
| z_c | "z c" | Vector của câu gốc |
| ẑ_c | "z c mũ" | Vector của câu đã che từ khóa bằng token giả |
| L_SMP | "hàm mất mát SMP" | Hàm mất mát MSE của Self-Masking Projection |
| R@K, R@10 | "Recall tại K", "Recall tại 10" | Tỉ lệ truy vấn có ảnh đích trong K kết quả đầu |
| mAP@5 | "m-A-P tại 5" | Độ chính xác trung bình trên 5 kết quả đầu |
| ± | "cộng trừ" | Độ lệch chuẩn qua 3 seed; "26,50 ± 0,04" đọc là "26,50 cộng trừ 0,04" |
| p = 0,006 | "p bằng không phẩy không không sáu" | Xác suất thấy mức chênh này nếu cải tiến thật ra không có tác dụng |
| InfoNCE, CLIP | "in-phô en-xi-i", "clíp" | Đọc thẳng tên tiếng Anh; tương tự baseline, seed, batch |

## 4. Kiến thức và nội dung công việc

### Token giả (textual inversion)

- Biểu diễn một ảnh như một "từ" [$] trong không gian token của CLIP; ghép vào câu "a photo of [$] that {điều chỉnh}", bộ mã hóa văn bản tự "hiểu" ảnh và phần thay đổi, tạo vector truy vấn để tìm ảnh. Cần học mạng chiếu φ: vector → token.
- Pic2Word học φ bằng cách đối sánh vector ảnh với vector của "a photo of [$]"; SEARLE tối ưu token cho từng ảnh rồi chưng cất. Hạn chế: chỉ thấy câu mẫu cố định → kém với câu điều chỉnh phức tạp, giảm khi backbone lớn; phải chạy bộ mã hóa ảnh khi train.

### Self-Masking Projection (SMP)

- z_c = C(câu); ê = φ(z_c + n); che các cụm tính từ/danh từ bằng [$] → "[$] sleeps on [$]"; ẑ_c = C(câu đã che với [$] = ê); mất mát L_SMP = ‖z_c − ẑ_c‖².
- Trực giác: để câu đã che giữ nguyên nghĩa, [$] phải tóm tắt nội dung thiết yếu ("tóm tắt một từ"). Văn bản tự nhiên đa dạng → φ học được trong nhiều cấu trúc câu.
- Nhiễu n = u·ε, u ~ U(0,1), ε ~ N(0, I): chuẩn của nhiễu đa dạng (Gauss thuần trong 768 chiều có chuẩn gần như cố định ≈ 27,7). Mục đích: φ chịu được việc thay vector văn bản bằng vector ảnh khi suy luận (modality gap).

### Học đối sánh và InfoNCE

- Với batch B câu, chuẩn hóa L2 ẑ và z; ma trận độ tương đồng S = ẑ $z^T$ / τ (B × B). Đường chéo là cặp đúng, phần còn lại là mẫu âm.
- InfoNCE = entropy chéo của từng hàng với nhãn là đường chéo: −log( e^{S_ii} / Σ_j e^{S_ij} ). Bản đối xứng lấy trung bình theo hàng và theo cột.
- τ (nhiệt độ) điều khiển độ "sắc" của phân phối; τ = 0,07 là giá trị khởi tạo của chính CLIP. Batch 512 → mỗi câu có 511 mẫu âm.

### Cải tiến A — lập luận

- MSE chỉ kéo ẑ về z của chính câu đó, không phạt ẑ gần vector các câu khác; bài toán đánh giá là **xếp hạng** (ảnh đích phải đứng trên mọi ảnh khác) → cần tính phân biệt.
- InfoNCE tối ưu theo cosine như khi truy xuất và đẩy các câu khác ra xa; giữ MSE để bảo toàn chuẩn và vị trí tuyệt đối của vector (InfoNCE chỉ quan tâm hướng).
- L = L_SMP + λ·L_NCE, λ = 0,5. Chi phí: ẑ, z đã có sẵn; phép nhân 512 × 512 nhỏ → thời gian/bước chỉ tăng ~2% khi huấn luyện thật (1,474 so với 1,448 giây).
- Hiện thực: code/train_phi.py, cờ --infonce_weight, --infonce_temp (mặc định 0 = LinCIR gốc).

### Đường học

- Đánh giá các checkpoint 1.000–4.000 bước và bước cuối 5.000 của baseline và A (seed 12345) trên FashionIQ; vẽ R@10/R@50 theo số bước (results/figures/learning_curve.png).
- Đọc đồ thị: nếu đường còn tăng rõ ở 5.000 → chưa bão hòa, số tuyệt đối còn có thể cao hơn; nếu khoảng cách A − baseline ổn định theo số bước → cải tiến không phụ thuộc may rủi của điểm dừng. Kết quả: baseline tăng nhanh tới 2.000 bước rồi chậm lại (+0,25 điểm R@10 từ 4.000 đến 5.000); **A thấp hơn baseline trên R@10 ở mọi mốc** → A kém không phải do chọn điểm dừng.

### Tệp liên quan trong dự án

- code/train_phi.py — hàm mất mát (tìm comment # [NHOM8] Improvement A)
- configs/EXP-002-infonce.yaml

- results/figures/learning_curve.png (sau phiên eval)

## 5. Ý chính phần của bạn (để hỗ trợ trả lời)

| Slide | Ý chính cần nắm |
|---|---|
| 7 | Mở đầu phần phương pháp: Pic2Word/SEARLE cần ảnh khi huấn luyện và chỉ học câu mẫu cố định (ảnh CC3M 430 GB, chú thích 125 MB). LinCIR thay ảnh bằng chính câu văn: che từ khóa bằng [$] = φ(z_c), ép ẑ_c ≈ z_c. Giải thích ví dụ "[$] sleeps on [$]" và vì sao [$] học được "tóm tắt một từ". |
| 9 | Cải tiến A sửa trực tiếp hàm mất mát vừa trình bày. Vấn đề: MSE không phân biệt, trong khi đánh giá là xếp hạng. Giải pháp: + λ·InfoNCE với 511 mẫu âm, τ = 0,07. Chi phí chỉ +2%/bước. Kết quả: A không tốt hơn trên FashionIQ (R@10 25,54 so với 25,90) và giảm CIRCO mAP@5 2,45 điểm — nói thẳng H1 bị bác bỏ; nguyên nhân ở slide 14 (Dũng hỗ trợ trả lời). |

## 6. Câu hỏi phản biện dự kiến

**H1. Kỳ vọng InfoNCE giúp xếp hạng, sao kết quả lại kém hơn?**

→ Kỳ vọng: InfoNCE tối ưu cosine với cặp đúng so với 511 câu khác, đúng thứ được đo khi truy xuất. Thực tế: độ nhất quán φ(ảnh)–φ(văn bản) giảm từ 0,80 xuống 0,64. InfoNCE buộc [$] mang đặc trưng giúp **phân biệt các câu văn bản**; đặc trưng này gắn với miền văn bản, không chuyển sang vector ảnh → φ khớp quá mức với văn bản, mất khả năng tổng quát qua modality gap. Ảnh hưởng nặng trên CIRCO (ảnh đời thực đa dạng) hơn FashionIQ.

**H2. Cải tiến của bạn thất bại, vậy đóng góp ở đâu?**

→ Đây là kết quả âm có kiểm định rõ (KTC 95% của CIRCO mAP@5 nằm hoàn toàn dưới 0) và có giải thích cơ chế. Nó cho thấy nút thắt của LinCIR là tính nhất quán qua modality gap, không phải tính phân biệt giữa các câu — chính phát hiện này dẫn tới kết luận chung của nhóm và giải thích vì sao B thành công. Hướng thử tiếp: λ nhỏ hơn, hoặc đối sánh có cả vector ảnh.

**H3. Sao không bỏ hẳn MSE?**

→ InfoNCE chỉ ràng buộc hướng (sau chuẩn hóa). MSE giữ chuẩn và vị trí tuyệt đối để [$] vẫn là một token "hợp lệ" cho bộ mã hóa; bỏ MSE có nguy cơ [$] trôi khỏi phân phối token thật.

**H4. τ = 0,07 và λ = 0,5 chọn thế nào?**

→ τ = 0,07 là nhiệt độ khởi tạo của CLIP; λ = 0,5 cân bằng hai số hạng ở cùng bậc độ lớn. Không quét vì giới hạn GPU — đã ghi là hạn chế.

**H5. Có mẫu âm giả (hai câu gần như giống nhau trong batch) không?**

→ Có thể nhưng hiếm với batch 512 lấy ngẫu nhiên từ hàng triệu câu; ảnh hưởng nhỏ. Đây cũng là hạn chế chung của InfoNCE trong batch.

**H6. Khác gì mất mát đối sánh của Pic2Word?**

→ Pic2Word đối sánh vector ảnh với vector câu mẫu "a photo of [$]". Cải tiến A đối sánh câu đã che với câu gốc — hoàn toàn bằng văn bản, giữ ưu điểm của LinCIR.

**H7. Batch nhỏ hơn thì sao?**

→ Ít mẫu âm hơn → tín hiệu đối sánh yếu hơn. Vì vậy nhóm giữ batch 512 trên 1 GPU thay vì chia 2 GPU.

**H8. Đường học cho thấy gì về 5.000 bước?**

→ Hiệu năng tăng nhanh tới 2.000 bước rồi chậm lại (+0,25 điểm R@10 từ 4.000 đến 5.000); baseline 5.000 bước chỉ kém checkpoint 20.000 bước 0,45 điểm. A thấp hơn baseline ở mọi mốc R@10 nên kết luận về A không phụ thuộc điểm dừng.

## 7. Tự kiểm tra trước buổi thuyết trình

- ☐ Viết được L_SMP và L_NCE, giải thích từng ký hiệu.
- ☐ Giải thích bằng lời vì sao MSE không đủ cho bài toán xếp hạng.
- ☐ Đọc được đồ thị đường học và kết luận về 5.000 bước.
- ☐ Trả lời câu hỏi về τ, λ, batch, mẫu âm.

## 8. Đọc thêm

- Báo cáo: mục 2.5, 3.2–3.4, 4.1–4.2, 5.7
- Bài báo LinCIR: mục 3.1–3.2, Bảng 8–9
- van den Oord 2018 (InfoNCE): mục 2
- Pic2Word (Saito 2023), SEARLE (Baldrati 2023): phần phương pháp