TÀI LIỆU HỌC VÀ CHUẨN BỊ THUYẾT TRÌNH

Lâm Thành Trung (B25CHHT117) · Nhóm 8 · Tìm kiếm và Truy xuất thông tin · Đề tài LinCIR

1. Vai trò của bạn

Đề xuất và cài đặt cải tiến A (bổ sung InfoNCE vào SMP); phân tích đường học theo số bước huấn luyện.

Slide	Nội dung	Thời gian
5	Ý tưởng token giả	1:00
6	Hạn chế Pic2Word/SEARLE	0:40
7	LinCIR: Self-Masking Projection	1:30
8	Nhiễu & modality gap	0:45
11	Cải tiến A: InfoNCE	1:00

2. Bức tranh chung của đề tài (cả nhóm cần nắm)

Bài toán. Truy xuất ảnh kết hợp (Composed Image Retrieval – CIR): truy vấn gồm một ảnh tham chiếu và một câu mô tả thay đổi ("chiếc váy này nhưng màu bạc, tay ngắn hơn"); hệ thống trả về ảnh thỏa cả hai. Dữ liệu bộ ba ⟨ảnh, câu, ảnh đích⟩ đắt và nhỏ, nên hướng **zero-shot** huấn luyện không cần bộ ba.

Bài báo. LinCIR (Gu và cộng sự, CVPR 2024) học một mạng chiếu φ (MLP 3 lớp) biến một vector thành "từ giả" [$] trong không gian token của CLIP, **chỉ bằng văn bản**: che các từ khóa của câu bằng [$] = φ(vector của câu + nhiễu) và ép câu đã che có cùng vector với câu gốc (Self-Masking Projection, mất mát MSE). Khi truy vấn, thay vector câu bằng vector ảnh: "a photo of [$] that {câu điều chỉnh}" → tìm ảnh theo cosine.

Nhóm đã làm. (1) Chuyển mã nguồn chính thức sang Python 3.13 / transformers 5.x, kiểm chứng sai lệch 0 so với mô hình gốc. (2) Tái hiện: checkpoint chính thức đạt FashionIQ R@10 = 26,35 / R@50 = 46,12 (bài báo 26,28 / 46,49). (3) Hai cải tiến: **A** – thêm mất mát đối sánh InfoNCE; **B** – nhiễu có hướng theo modality gap. (4) Huấn luyện baseline, A, B, A+B trên Kaggle (2 × T4), mỗi biến thể 3 seed, 5.000 bước; đánh giá FashionIQ val + CIRCO val; kiểm định thống kê theo truy vấn.

Kết quả chính. B (nhiễu có hướng) tốt hơn baseline có ý nghĩa thống kê: FashionIQ R@10 +0,60 ($p = 0{,}006$), R@50 +1,27 ($p < 0{,}001$), CIRCO mAP@25/50 tăng có ý nghĩa; B còn vượt checkpoint chính thức 20.000 bước. **A (InfoNCE) không tốt hơn** trên FashionIQ và **kém rõ trên CIRCO** (mAP@5 −2,45, KTC 95% nằm dưới 0); A+B tương tự A. Giải thích: độ nhất quán của φ giữa ảnh và văn bản (cosine) B 0,84 > baseline 0,80 > A 0,64 — cùng thứ tự với CIRCO. Kết luận: H2 được ủng hộ, H1 và H3 bị bác bỏ.

Hạng mục	Số liệu / cấu hình
Backbone	CLIP ViT-L/14 (đóng băng); chỉ huấn luyện φ
Huấn luyện	AdamW, lr 1e-4, wd 0,01, batch 512, dropout 0,5, 5.000 bước (bài báo

	20.000)
Dữ liệu train	Chỉ văn bản: chú thích CC3M + 2,47 triệu prompt Stable Diffusion + prompt Midjourney
Đánh giá	FashionIQ val (6.016 truy vấn, 3 nhóm, R@10/R@50); CIRCO val (220 truy vấn, 123.403 ảnh, mAP@K)
Tái hiện	Checkpoint chính thức: FIQ R@10 26,35 vs 26,28; R@50 46,12 vs 46,49 (lệch lớn nhất 0,77 điểm)
Cải tiến A	$L = MSE + 0{,}5 \cdot InfoNCE$ ($\tau = 0{,}07$, 511 mẫu âm trong batch)
Cải tiến B	$n = 0{,}5 \cdot \Delta + u \cdot \varepsilon$; Δ = tâm ảnh − tâm văn bản trên 5.000 cặp COCO ($\|\Delta\| = 13{,}87$)
Giao thức	3 seed (12345, 2024, 7), checkpoint bước cuối, paired bootstrap 10.000 lần + Wilcoxon, kết luận khi $p < 0{,}05$
Tài nguyên	Kaggle 2 × T4 16 GB, 30 giờ GPU/tuần, giới hạn 12 giờ/phiên; 1,45 s/bước, 2,0 giờ/run
Kết quả (TB 3 seed)	FIQ R@10: baseline 25,90 · A 25,54 · B 26,50 · A+B 25,44; CIRCO mAP@5: 10,47 · 8,02 · 10,94 · 7,81

3. Trình bày rõ ràng, dễ hiểu (đọc trước khi tập)

Mẹo thuyết trình

- **Mở đầu bằng mạch chính trong 3 câu:** (1) Truy xuất ảnh kết hợp cần dữ liệu có nhãn rất tốn kém. (2) LinCIR huấn luyện chỉ bằng văn bản nên không cần dữ liệu đó. (3) Nhóm tái hiện LinCIR, thử hai cải tiến, chứng minh bằng kiểm định rằng một cải tiến tốt hơn và giải thích vì sao cải tiến còn lại kém hơn.
- **Mỗi slide theo trình tự:** nêu ý chính (tiêu đề) → nêu một con số → giải thích con số đó có nghĩa gì → nối sang slide sau. Không đọc toàn bộ bảng; chỉ nêu dòng hoặc cột cần thiết.
- **Diễn giải con số ngay khi nêu:** R@10 = 26 nghĩa là trong 26% số truy vấn, ảnh đúng nằm trong 10 kết quả đầu tiên; tăng 0,60 điểm R@10 tương đương thêm khoảng 6 truy vấn tìm đúng trên mỗi 1.000 truy vấn.
- **Thuật ngữ:** nêu tên tiếng Việt kèm tên tiếng Anh và định nghĩa một câu ở lần xuất hiện đầu tiên; các lần sau dùng đúng một tên đó.
- **Khi nói, làm tròn hợp lý** (“khoảng 26%”, “giảm khoảng 23%”); số chính xác đã có trên slide và trong báo cáo.
- **Ngắt nghỉ sau kết luận chính** (slide 14) trước khi chuyển sang phần giải thích nguyên nhân.
- **Trả lời câu hỏi:** câu đầu nêu thẳng kết luận, câu sau nêu căn cứ (số liệu, mục trong báo cáo).

Slide của bạn: ý chính và con số cần nêu

Slide	Ý chính nói thành lời	Một con số và ý nghĩa
5	Ảnh tham chiếu được chuyển thành một token giả [$] và ghép vào câu “a photo of [$] that …”; bộ mã hóa	—

	văn bản tạo vector truy vấn để tìm ảnh. Chỉ cần huấn luyện mạng chiếu φ.	
6	Pic2Word và SEARLE chỉ huấn luyện với câu mẫu cố định và phải chạy bộ mã hóa ảnh khi huấn luyện.	Ảnh CC3M khoảng 430 GB, chú thích chỉ 125 MB
7	LinCIR huấn luyện φ chỉ bằng văn bản: che các từ khóa của câu bằng [$] và yêu cầu câu đã che có cùng vector với câu gốc.	—
8	Vector ảnh và vector văn bản của CLIP nằm ở hai vùng tách biệt. φ học trên văn bản nhưng khi dùng lại nhận ảnh, nên LinCIR thêm nhiễu khi huấn luyện.	Ảnh và chú thích của chính nó chỉ có cosine 0,26 trên thang tối đa 1
11	Cải tiến A thêm hàm mất mát đối sánh để mỗi câu phân biệt với 511 câu khác. Kết quả: không tốt hơn trên FashionIQ và kém hơn trên CIRCO; nguyên nhân trình bày ở slide 15.	CIRCO mAP@5 giảm từ 10,47 xuống 8,02, tức giảm khoảng 23%

Thuật ngữ: định nghĩa ngắn

Thuật ngữ	Định nghĩa	Ví dụ trong đề tài
Truy xuất ảnh kết hợp (CIR)	Tìm ảnh bằng truy vấn gồm một ảnh tham chiếu và một câu mô tả thay đổi	Ảnh váy hoa xanh + "màu bạc, tay ngắn hơn" → tìm ảnh váy bạc tay ngắn
Zero-shot	Mô hình không được huấn luyện trên dữ liệu có nhãn của bài toán đích, được đánh giá trực tiếp	LinCIR không dùng bộ ba nào của FashionIQ hay CIRCO khi huấn luyện
Bộ ba có nhãn	Ảnh tham chiếu – câu điều chỉnh – ảnh đích, do người gán thủ công	FashionIQ có khoảng 46,6 nghìn bộ ba huấn luyện
CLIP	Mô hình gồm bộ mã hóa ảnh và bộ mã hóa văn bản, đưa ảnh và câu mô tả tương ứng về gần nhau	Nhóm dùng CLIP ViT-L/14, giữ nguyên không huấn luyện lại
Vector nhúng	Dãy số (768 chiều với ViT-L) biểu diễn nội dung của một ảnh hoặc một câu	Mỗi ảnh trong kho được mã hóa thành một vector
Độ tương đồng cosine	Mức độ cùng hướng của hai vector, càng gần 1 càng giống	Kết quả truy xuất được xếp theo cosine giữa truy vấn và từng ảnh
Token giả [$]	Một vector đặt vào vị trí của một từ trong câu, đại diện cho ảnh tham chiếu	Câu truy vấn: "a photo of [$] that is silver with shorter sleeves"
Mạng chiếu φ	Mạng nơ-ron nhỏ (3 lớp) biến vector thành token giả; là thành phần duy nhất được huấn luyện	Cả 4 biến thể của nhóm chỉ khác nhau ở cách huấn luyện φ
Self-Masking Projection (SMP)	Che các cụm tính từ – danh từ của câu bằng [$] và huấn luyện φ để câu đã che giữ nguyên vector của câu gốc	"gray cat sleeps on a pillow" → "[$] sleeps on [$]"
Khoảng cách ảnh – văn bản (modality gap)	Vector ảnh và vector văn bản của CLIP nằm ở hai vùng tách biệt	Ảnh và chú thích của chính nó chỉ có cosine trung bình 0,26 (5.000 cặp COCO)

Nhiễu khi huấn luyện	Thành phần ngẫu nhiên cộng vào vector văn bản để φ chịu được khác biệt giữa ảnh và văn bản	LinCIR dùng n = u·ε, u ~ U(0,1), ε ~ N(0, I)
Cải tiến B – nhiễu có hướng	Cộng thêm vector Δ (tâm vector ảnh trừ tâm vector văn bản) vào nhiễu, đẩy đầu vào của φ về phía vùng ảnh	n = 0,5·Δ + u·ε, Δ tính trên 5.000 cặp COCO
Cải tiến A – InfoNCE	Hàm mất mát đối sánh: mỗi câu phải gần chính nó hơn 511 câu khác trong cùng batch	L = MSE + 0,5·InfoNCE
Baseline	LinCIR gốc do nhóm tự huấn luyện, cùng cấu hình với các biến thể, dùng làm mốc so sánh	5.000 bước, 3 seed
Checkpoint	Trọng số của mô hình được lưu tại một thời điểm huấn luyện	Checkpoint chính thức của tác giả huấn luyện 20.000 bước
Bước huấn luyện	Một lần cập nhật trọng số trên một batch 512 câu	5.000 bước mất khoảng 2 giờ trên GPU T4
Seed	Giá trị khởi tạo bộ sinh số ngẫu nhiên; khác seed thì thứ tự dữ liệu và nhiễu khác nhau	Mỗi biến thể chạy với 3 seed: 12345, 2024, 7
Độ lệch chuẩn (±)	Mức dao động của kết quả giữa các lần chạy khác seed	B: R@10 = 26,50 ± 0,04 — rất ổn định
R@10, R@50 (Recall@K)	Tỷ lệ truy vấn có ảnh đích nằm trong K kết quả đầu	FashionIQ chỉ có một ảnh đúng cho mỗi truy vấn
mAP@5	Trung bình độ chính xác trên K = 5 kết quả đầu, dùng khi mỗi truy vấn có nhiều ảnh đúng	CIRCO có trung bình 4,16 ảnh đúng mỗi truy vấn
p-value	Xác suất quan sát được mức chênh lệch như vậy nếu thực tế hai phương pháp ngang nhau	B so với baseline, FashionIQ R@10: p = 0,006
Khoảng tin cậy 95% (KTC)	Khoảng giá trị của mức chênh lệch thật với độ tin cậy 95%; nếu toàn bộ khoảng lớn hơn 0 thì cải tiến tốt hơn	B, R@50: Δ = +1,27, KTC [+0,81; +1,73]
Paired bootstrap	Lấy mẫu lại các truy vấn 10.000 lần, tính lại mức chênh mỗi lần để ước lượng p-value và KTC	So từng truy vấn của B với cùng truy vấn đó của baseline
Âm tính giả	Ảnh thực tế thỏa truy vấn nhưng không được gán nhãn là đáp án	Lý do bài báo khuyến nghị dùng mAP và K lớn thay vì R@1
Ablation	So sánh các biến thể bật/tắt từng thành phần để tách đóng góp của mỗi thành phần	Baseline, A, B, A+B

4. Kiến thức và nội dung công việc

Token giả (textual inversion)

- Biểu diễn một ảnh như một "từ" [$] trong không gian token của CLIP; ghép vào câu "a photo of [$] that {điều chỉnh}", bộ mã hóa văn bản tự "hiểu" ảnh và phần thay đổi, tạo vector truy vấn để tìm ảnh. Cần học mạng chiếu φ: vector → token.
- Pic2Word học φ bằng cách đối sánh vector ảnh với vector của "a photo of [$]"; SEARLE tối ưu token cho từng ảnh rồi chưng cất. Hạn chế: chỉ thấy câu mẫu cố định → kém với câu điều chỉnh phức tạp, giảm khi backbone lớn; phải chạy bộ mã hóa ảnh khi train.

Self-Masking Projection (SMP)

- z_c = C(câu); ê = φ(z_c + n); che các cụm tính từ/danh từ bằng [$] → "[$] sleeps on [$]"; ẑ_c = C(câu đã che với [$] = ê); mất mát L_SMP = ‖z_c − ẑ_c‖².
- Trực giác: để câu đã che giữ nguyên nghĩa, [$] phải tóm tắt nội dung thiết yếu ("tóm tắt một từ"). Văn bản tự nhiên đa dạng → φ học được trong nhiều cấu trúc câu.
- Nhiễu n = u·ε, u ~ U(0,1), ε ~ N(0, I): chuẩn của nhiễu đa dạng (Gauss thuần trong 768 chiều có chuẩn gần như cố định ≈ 27,7). Mục đích: φ chịu được việc thay vector văn bản bằng vector ảnh khi suy luận (modality gap).

Học đối sánh và InfoNCE

- Với batch B câu, chuẩn hóa L2 ẑ và z; ma trận độ tương đồng S = ẑ z^T / τ (B × B). Đường chéo là cặp đúng, phần còn lại là mẫu âm.
- InfoNCE = entropy chéo của từng hàng với nhãn là đường chéo: −log(e^{S_ii} / Σ_j e^{S_ij}). Bản đối xứng lấy trung bình theo hàng và theo cột.
- τ (nhiệt độ) điều khiển độ "sắc" của phân phối; τ = 0,07 là giá trị khởi tạo của chính CLIP. Batch 512 → mỗi câu có 511 mẫu âm.

Cải tiến A — lập luận

- MSE chỉ kéo ẑ về z của chính câu đó, không phạt ẑ gần vector các câu khác; bài toán đánh giá là **xếp hạng** (ảnh đích phải đứng trên mọi ảnh khác) → cần tính phân biệt.
- InfoNCE tối ưu theo cosine như khi truy xuất và đẩy các câu khác ra xa; giữ MSE để bảo toàn chuẩn và vị trí tuyệt đối của vector (InfoNCE chỉ quan tâm hướng).
- L = L_SMP + λ·L_NCE, λ = 0,5. Chi phí: ẑ, z đã có sẵn; phép nhân 512 × 512 nhỏ → thời gian/bước chỉ tăng ~2% khi huấn luyện thật (1,474 so với 1,448 giây).
- Hiện thực: code/train_phi.py, cờ --infonce_weight, --infonce_temp (mặc định 0 = LinCIR gốc).

Đường học

- Đánh giá các checkpoint 1.000–4.000 bước và bước cuối 5.000 của baseline và A (seed 12345) trên FashionIQ; vẽ R@10/R@50 theo số bước (results/figures/learning_curve.png).
- Đọc đồ thị: nếu đường còn tăng rõ ở 5.000 → chưa bão hòa, số tuyệt đối còn có thể cao hơn; nếu khoảng cách A − baseline ổn định theo số bước → cải tiến không phụ thuộc may rủi của điểm dừng. Kết quả: baseline tăng nhanh tới 2.000 bước rồi chậm lại (+0,25 điểm R@10 từ 4.000 đến 5.000); **A thấp hơn baseline trên R@10 ở mọi mốc** → A kém không phải do chọn điểm dừng.

Tệp liên quan trong dự án

- code/train_phi.py — hàm mất mát (tìm comment # [NHOM8] Improvement A)
- configs/EXP-002-infonce.yaml
- results/figures/learning_curve.png (sau phiên eval)

5. Kịch bản trình bày chi tiết

Slide	Ý chính cần nói
5	Ý tưởng: ảnh → [$] trong không gian token; câu "a photo of [$] that …" → vector truy vấn → tìm ảnh. Chỉ cần học φ.
6	Pic2Word/SEARLE: câu mẫu cố định, cần ảnh khi huấn luyện → kém linh hoạt, tốn tài nguyên.
7	LinCIR thay ảnh bằng chính câu văn: che từ khóa bằng [$] = φ(z_c), ép ẑ_c ≈ z_c. Giải thích ví dụ "[$] sleeps on [$]" và vì sao [$] học được "tóm tắt một từ".
8	Khi suy luận φ nhận vector ảnh; ảnh và văn bản của CLIP nằm ở hai vùng khác nhau (modality gap) → thêm nhiễu u·ε khi train để φ chịu được.
11	Vấn đề: MSE không phân biệt, trong khi đánh giá là xếp hạng. Giải pháp: + λ·InfoNCE với 511 mẫu âm, τ = 0,07. Chi phí chỉ +2%/bước. Kết quả: A không tốt hơn trên FashionIQ (R@10 25,54 so với 25,90) và giảm CIRCO mAP@5 2,45 điểm — nói thẳng H1 bị bác bỏ; nguyên nhân Dũng giải thích ở slide 15.

6. Câu hỏi phản biện dự kiến

H1. Kỳ vọng InfoNCE giúp xếp hạng, sao kết quả lại kém hơn?

→ Kỳ vọng: InfoNCE tối ưu cosine với cặp đúng so với 511 câu khác, đúng thứ được đo khi truy xuất. Thực tế: độ nhất quán φ(ảnh)–φ(văn bản) giảm từ 0,80 xuống 0,64. InfoNCE buộc [$] mang đặc trưng giúp **phân biệt các câu văn bản**; đặc trưng này gắn với miền văn bản, không chuyển sang vector ảnh → φ khớp quá mức với văn bản, mất khả năng tổng quát qua modality gap. Ảnh hưởng nặng trên CIRCO (ảnh đời thực đa dạng) hơn FashionIQ.

H2. Cải tiến của bạn thất bại, vậy đóng góp ở đâu?

→ Đây là kết quả âm có kiểm định rõ (KTC 95% của CIRCO mAP@5 nằm hoàn toàn dưới 0) và có giải thích cơ chế. Nó cho thấy nút thắt của LinCIR là tính nhất quán qua

modality gap, không phải tính phân biệt giữa các câu — chính phát hiện này dẫn tới kết luận chung của nhóm và giải thích vì sao B thành công. Hướng thử tiếp: λ nhỏ hơn, hoặc đối sánh có cả vector ảnh.

H3. Sao không bỏ hẳn MSE?

→ InfoNCE chỉ ràng buộc hướng (sau chuẩn hóa). MSE giữ chuẩn và vị trí tuyệt đối để [$] vẫn là một token "hợp lệ" cho bộ mã hóa; bỏ MSE có nguy cơ [$] trôi khỏi phân phối token thật.

H4. τ = 0,07 và λ = 0,5 chọn thế nào?

→ τ = 0,07 là nhiệt độ khởi tạo của CLIP; λ = 0,5 cân bằng hai số hạng ở cùng bậc độ lớn. Không quét vì giới hạn GPU — đã ghi là hạn chế.

H5. Có mẫu âm giả (hai câu gần như giống nhau trong batch) không?

→ Có thể nhưng hiếm với batch 512 lấy ngẫu nhiên từ hàng triệu câu; ảnh hưởng nhỏ. Đây cũng là hạn chế chung của InfoNCE trong batch.

H6. Khác gì mất mát đối sánh của Pic2Word?

→ Pic2Word đối sánh vector ảnh với vector câu mẫu "a photo of [$]". Cải tiến A đối sánh câu đã che với câu gốc — hoàn toàn bằng văn bản, giữ ưu điểm của LinCIR.

H7. Batch nhỏ hơn thì sao?

→ Ít mẫu âm hơn → tín hiệu đối sánh yếu hơn. Vì vậy nhóm giữ batch 512 trên 1 GPU thay vì chia 2 GPU.

H8. Đường học cho thấy gì về 5.000 bước?

→ Hiệu năng tăng nhanh tới 2.000 bước rồi chậm lại (+0,25 điểm R@10 từ 4.000 đến 5.000); baseline 5.000 bước chỉ kém checkpoint 20.000 bước 0,45 điểm. A thấp hơn baseline ở mọi mốc R@10 nên kết luận về A không phụ thuộc điểm dừng.

7. Tự kiểm tra trước buổi thuyết trình

- ☐ Viết được L_SMP và L_NCE, giải thích từng ký hiệu.
- ☐ Giải thích bằng lời vì sao MSE không đủ cho bài toán xếp hạng.
- ☐ Đọc được đồ thị đường học và kết luận về 5.000 bước.
- ☐ Trả lời câu hỏi về τ, λ, batch, mẫu âm.

8. Đọc thêm

- Báo cáo: chương 3, mục 4.1–4.2, 5.7
- Bài báo LinCIR: mục 3.1–3.2, Bảng 8–9
- van den Oord 2018 (InfoNCE): mục 2
- Pic2Word (Saito 2023), SEARLE (Baldrati 2023): phần phương pháp