# TÀI LIỆU HỌC VÀ CHUẨN BỊ THUYẾT TRÌNH

*Nguyễn Xuân Tùng (B25CHHT119) · Nhóm 8 · Tìm kiếm và Truy xuất thông tin · Đề tài LinCIR*

## 1. Vai trò của bạn

Tái hiện: đánh giá checkpoint chính thức, đối chiếu với bài báo; phân tích khác biệt giữa bài báo và mã nguồn (cấu trúc φ, dữ liệu huấn luyện, trích từ khóa).

| Slide | Nội dung | Thời gian |
|---|---|---|
| 11 | Kết quả tái hiện | 0:45 |
| 12 | Kết quả chính + kiểm định | 1:30 |
| 14 | Kết luận & hạn chế | 0:45 |

## 2. Bức tranh chung của đề tài (cả nhóm cần nắm)

**Bài toán.** Truy xuất ảnh kết hợp (Composed Image Retrieval – CIR): truy vấn gồm một ảnh tham chiếu và một câu mô tả thay đổi ("chiếc váy này nhưng màu bạc, tay ngắn hơn"); hệ thống trả về ảnh thỏa cả hai. Dữ liệu bộ ba ⟨ảnh, câu, ảnh đích⟩ đắt và nhỏ, nên hướng **zero-shot** huấn luyện không cần bộ ba.

**Bài báo.** LinCIR (Gu và cộng sự, CVPR 2024) học một mạng chiếu φ (MLP 3 lớp) biến một vector thành "từ giả" [$] trong không gian token của CLIP, **chỉ bằng văn bản**: che các từ khóa của câu bằng [$] = φ(vector của câu + nhiễu) và ép câu đã che có cùng vector với câu gốc (Self-Masking Projection, mất mát MSE). Khi truy vấn, thay vector câu bằng vector ảnh: "a photo of [$] that {câu điều chỉnh}" → tìm ảnh theo cosine.

**Nhóm đã làm.** (1) Chuyển mã nguồn chính thức sang Python 3.13 / transformers 5.x, kiểm chứng sai lệch 0 so với mô hình gốc. (2) Tái hiện: checkpoint chính thức đạt FashionIQ R@10 = 26,35 / R@50 = 46,12 (bài báo 26,28 / 46,49). (3) Hai cải tiến: **A** – thêm mất mát đối sánh InfoNCE; **B** – nhiễu có hướng theo modality gap. (4) Huấn luyện baseline, A, B, A+B trên Kaggle (2 × T4), mỗi biến thể 3 seed, 5.000 bước; đánh giá FashionIQ val + CIRCO val; kiểm định thống kê theo truy vấn.

**Kết quả chính. B (nhiễu có hướng) tốt hơn baseline có ý nghĩa thống kê**: FashionIQ R@10 +0,60 ($p = 0,006$), R@50 +1,27 ($p < 0,001$), CIRCO mAP@25/50 tăng có ý nghĩa; B còn vượt checkpoint chính thức 20.000 bước. **A (InfoNCE) không tốt hơn** trên FashionIQ và **kém rõ trên CIRCO** (mAP@5 −2,45, KTC 95% nằm dưới 0); A+B tương tự A. Giải thích: độ nhất quán của φ giữa ảnh và văn bản (cosine) B 0,84 > baseline 0,80 > A 0,64 — cùng thứ tự với CIRCO. Kết luận: H2 được ủng hộ, H1 và H3 bị bác bỏ.

| Hạng mục | Số liệu / cấu hình |
|---|---|
| Backbone | CLIP ViT-L/14 (đóng băng); chỉ huấn luyện φ |
| Huấn luyện | AdamW, lr 1e-4, wd 0,01, batch 512, dropout 0,5, 5.000 bước (bài báo 20.000) |
| Dữ liệu train | Chỉ văn bản: chú thích CC3M + 2,47 triệu prompt Stable Diffusion + |

| | |
|---|---|
| | prompt Midjourney |
| Đánh giá | FashionIQ val (6.016 truy vấn, 3 nhóm, R@10/R@50); CIRCO val (220 truy vấn, 123.403 ảnh, mAP@K) |
| Tái hiện | Checkpoint chính thức: FIQ R@10 26,35 vs 26,28; R@50 46,12 vs 46,49 (lệch lớn nhất 0,77 điểm) |
| Cải tiến A | $L = MSE + 0{,}5 \cdot InfoNCE$ ($\tau = 0{,}07$, 511 mẫu âm trong batch) |
| Cải tiến B | $n = 0{,}5 \cdot \Delta + u \cdot \varepsilon$; $\Delta$ = tâm ảnh − tâm văn bản trên 5.000 cặp COCO ($\|\Delta\| = 13{,}87$) |
| Giao thức | 3 seed (12345, 2024, 7), checkpoint bước cuối, paired bootstrap 10.000 lần + Wilcoxon, kết luận khi $p < 0{,}05$ |
| Tài nguyên | Kaggle 2 × T4 16 GB, 30 giờ GPU/tuần, giới hạn 12 giờ/phiên; 1,45 s/bước, 2,0 giờ/run |
| Kết quả (TB 3 seed) | FIQ R@10: baseline 25,90 · A 25,54 · B 26,50 · A+B 25,44; CIRCO mAP@5: 10,47 · 8,02 · 10,94 · 7,81 |

## 3. Trình bày rõ ràng, dễ hiểu (đọc trước khi tập)

### Mẹo thuyết trình

- **Mở đầu bằng mạch chính trong 3 câu:** (1) Truy xuất ảnh kết hợp cần dữ liệu có nhãn rất tốn kém. (2) LinCIR huấn luyện chỉ bằng văn bản nên không cần dữ liệu đó. (3) Nhóm tái hiện LinCIR, thử hai cải tiến, chứng minh bằng kiểm định rằng một cải tiến tốt hơn và giải thích vì sao cải tiến còn lại kém hơn.
- **Mỗi slide theo trình tự:** nêu ý chính (tiêu đề) → nêu một con số → giải thích con số đó có nghĩa gì → nối sang slide sau. Không đọc toàn bộ bảng; chỉ nêu dòng hoặc cột cần thiết.
- **Diễn giải con số ngay khi nêu:** R@10 = 26 nghĩa là trong 26% số truy vấn, ảnh đúng nằm trong 10 kết quả đầu tiên; tăng 0,60 điểm R@10 tương đương thêm khoảng 6 truy vấn tìm đúng trên mỗi 1.000 truy vấn.
- **Thuật ngữ:** nêu tên tiếng Việt kèm tên tiếng Anh và định nghĩa một câu ở lần xuất hiện đầu tiên; các lần sau dùng đúng một tên đó.
- **Khi nói, làm tròn hợp lý** ("khoảng 26%", "giảm khoảng 23%"); số chính xác đã có trên slide và trong báo cáo.
- **Ngắt nghỉ sau kết luận chính** (slide 12) trước khi chuyển sang phần giải thích nguyên nhân.
- **Trả lời câu hỏi:** câu đầu nêu thẳng kết luận, câu sau nêu căn cứ (số liệu, mục trong báo cáo).

### Slide của bạn: ý chính và con số cần nêu

| Slide | Ý chính nói thành lời | Một con số và ý nghĩa |
|---|---|---|
| 11 | Nhóm đánh giá lại checkpoint chính thức bằng mã đã chuyển đổi; kết quả khớp bài báo, xác nhận quy trình đánh giá đúng. | Lệch lớn nhất 0,77 điểm phần trăm |
| 12 | B cao nhất ở mọi cột và tốt hơn baseline có ý nghĩa | B tăng 0,60 điểm R@10 |

| | | |
|---|---|---|
| | thống kê; A và A+B kém hơn trên CIRCO. | (thêm khoảng 6 truy vấn đúng trên 1.000), p = 0,006 |
| 14 | Chất lượng truy xuất phụ thuộc chủ yếu vào việc φ xử lý ảnh nhất quán với văn bản. B cải thiện điều này nên tốt hơn; A làm giảm nên kém hơn. Hạn chế chính: huấn luyện 5.000 bước và chưa quét siêu tham số. | B chỉ huấn luyện 5.000 bước nhưng vượt checkpoint chính thức 20.000 bước |

## Thuật ngữ: định nghĩa ngắn

| Thuật ngữ | Định nghĩa | Ví dụ trong đề tài |
|---|---|---|
| Truy xuất ảnh kết hợp (CIR) | Tìm ảnh bằng truy vấn gồm một ảnh tham chiếu và một câu mô tả thay đổi | Ảnh váy hoa xanh + "màu bạc, tay ngắn hơn" → tìm ảnh váy bạc tay ngắn |
| Zero-shot | Mô hình không được huấn luyện trên dữ liệu có nhãn của bài toán đích, được đánh giá trực tiếp | LinCIR không dùng bộ ba nào của FashionIQ hay CIRCO khi huấn luyện |
| Bộ ba có nhãn | Ảnh tham chiếu – câu điều chỉnh – ảnh đích, do người gán thủ công | FashionIQ có khoảng 46,6 nghìn bộ ba huấn luyện |
| CLIP | Mô hình gồm bộ mã hóa ảnh và bộ mã hóa văn bản, đưa ảnh và câu mô tả tương ứng về gần nhau | Nhóm dùng CLIP ViT-L/14, giữ nguyên không huấn luyện lại |
| Vector nhúng | Dãy số (768 chiều với ViT-L) biểu diễn nội dung của một ảnh hoặc một câu | Mỗi ảnh trong kho được mã hóa thành một vector |
| Độ tương đồng cosine | Mức độ cùng hướng của hai vector, càng gần 1 càng giống | Kết quả truy xuất được xếp theo cosine giữa truy vấn và từng ảnh |
| Token giả [$] | Một vector đặt vào vị trí của một từ trong câu, đại diện cho ảnh tham chiếu | Câu truy vấn: "a photo of [$] that is silver with shorter sleeves" |
| Mạng chiếu φ | Mạng nơ-ron nhỏ (3 lớp) biến vector thành token giả; là thành phần duy nhất được huấn luyện | Cả 4 biến thể của nhóm chỉ khác nhau ở cách huấn luyện φ |
| Self-Masking Projection (SMP) | Che các cụm tính từ – danh từ của câu bằng [$] và huấn luyện φ để câu đã che giữ nguyên vector của câu gốc | "gray cat sleeps on a pillow" → "[$] sleeps on [$]" |
| Khoảng cách ảnh – văn bản (modality gap) | Vector ảnh và vector văn bản của CLIP nằm ở hai vùng tách biệt | Ảnh và chú thích của chính nó chỉ có cosine trung bình 0,26 (5.000 cặp COCO) |
| Nhiễu khi huấn luyện | Thành phần ngẫu nhiên cộng vào vector văn bản để φ chịu được khác biệt giữa ảnh và văn bản | LinCIR dùng $n = u \cdot \varepsilon$, $u \sim U(0,1)$, $\varepsilon \sim N(0, I)$ |
| Cải tiến B – nhiễu có hướng | Cộng thêm vector Δ (tâm vector ảnh trừ tâm vector văn bản) vào nhiễu, đẩy đầu vào của φ về phía vùng ảnh | $n = 0{,}5 \cdot \Delta + u \cdot \varepsilon$, Δ tính trên 5.000 cặp COCO |
| Cải tiến A – InfoNCE | Hàm mất mát đối sánh: mỗi câu phải gần chính nó hơn 511 câu khác trong cùng batch | $L = MSE + 0{,}5 \cdot InfoNCE$ |

| | | |
|---|---|---|
| Baseline | LinCIR gốc do nhóm tự huấn luyện, cùng cấu hình với các biến thể, dùng làm mốc so sánh | 5.000 bước, 3 seed |
| Checkpoint | Trọng số của mô hình được lưu tại một thời điểm huấn luyện | Checkpoint chính thức của tác giả huấn luyện 20.000 bước |
| Bước huấn luyện | Một lần cập nhật trọng số trên một batch 512 câu | 5.000 bước mất khoảng 2 giờ trên GPU T4 |
| Seed | Giá trị khởi tạo bộ sinh số ngẫu nhiên; khác seed thì thứ tự dữ liệu và nhiễu khác nhau | Mỗi biến thể chạy với 3 seed: 12345, 2024, 7 |
| Độ lệch chuẩn (±) | Mức dao động của kết quả giữa các lần chạy khác seed | B: R@10 = 26,50 ± 0,04 — rất ổn định |
| R@10, R@50 (Recall@K) | Tỷ lệ truy vấn có ảnh đích nằm trong K kết quả đầu | FashionIQ chỉ có một ảnh đúng cho mỗi truy vấn |
| mAP@5 | Trung bình độ chính xác trên K = 5 kết quả đầu, dùng khi mỗi truy vấn có nhiều ảnh đúng | CIRCO có trung bình 4,16 ảnh đúng mỗi truy vấn |
| p-value | Xác suất quan sát được mức chênh lệch như vậy nếu thực tế hai phương pháp ngang nhau | B so với baseline, FashionIQ R@10: p = 0,006 |
| Khoảng tin cậy 95% (KTC) | Khoảng giá trị của mức chênh lệch thật với độ tin cậy 95%; nếu toàn bộ khoảng lớn hơn 0 thì cải tiến tốt hơn | B, R@50: Δ = +1,27, KTC [+0,81; +1,73] |
| Paired bootstrap | Lấy mẫu lại các truy vấn 10.000 lần, tính lại mức chênh mỗi lần để ước lượng p-value và KTC | So từng truy vấn của B với cùng truy vấn đó của baseline |
| Âm tính giả | Ảnh thực tế thỏa truy vấn nhưng không được gán nhãn là đáp án | Lý do bài báo khuyến nghị dùng mAP và K lớn thay vì R@1 |
| Ablation | So sánh các biến thể bật/tắt từng thành phần để tách đóng góp của mỗi thành phần | Baseline, A, B, A+B |

## Cách đọc ký hiệu trên slide

Lần đầu gặp [$] trên slide, nói thêm: “ký hiệu đô-la trong ngoặc vuông là token giả”; các lần sau chỉ nói “token giả”. Ví dụ câu nói: “Mạng phi biến ảnh tham chiếu thành một token giả, ghép vào câu mô tả thay đổi.”

| Ký hiệu | Đọc là | Nghĩa |
|---|---|---|
| φ | “phi” | Mạng chiếu 3 lớp, phần duy nhất được huấn luyện; biến một vector (ảnh hoặc câu) thành một token |
| [$] | “token giả” (hoặc “token đô-la”) | Vị trí trong câu được thay bằng đầu ra của φ; “a photo of [$] that is blue” đọc là “a photo of token giả that is blue” |
| Δ | “đen-ta” | Vector chênh lệch: tâm vector ảnh trừ tâm vector văn bản |

| | | |
|---|---|---|
| ε | “ép-xi-lon” | Nhiễu ngẫu nhiên theo phân phối chuẩn |
| u · ε | “u nhân ép-xi-lon” | Nhiễu của LinCIR; u là hệ số ngẫu nhiên từ 0 đến 1 |
| α | “an-pha” | Hệ số của Δ trong cải tiến B (0,5) |
| λ | “lam-đa” | Trọng số của InfoNCE trong cải tiến A (0,5) |
| τ | “tô” | Nhiệt độ của InfoNCE (0,07) |
| z_c | “z c” | Vector của câu gốc |
| ẑ_c | “z c mũ” | Vector của câu đã che từ khóa bằng token giả |
| L_SMP | “hàm mất mát SMP” | Hàm mất mát MSE của Self-Masking Projection |
| R@K, R@10 | “Recall tại K”, “Recall tại 10” | Tỉ lệ truy vấn có ảnh đích trong K kết quả đầu |
| mAP@5 | “m-A-P tại 5” | Độ chính xác trung bình trên 5 kết quả đầu |
| ± | “cộng trừ” | Độ lệch chuẩn qua 3 seed; “26,50 ± 0,04” đọc là “26,50 cộng trừ 0,04” |
| p = 0,006 | “p bằng không phẩy không không sáu” | Xác suất thấy mức chênh này nếu cải tiến thật ra không có tác dụng |
| InfoNCE, CLIP | “in-phô en-xi-i”, “clíp” | Đọc thẳng tên tiếng Anh; tương tự baseline, seed, batch |

## 4. Kiến thức và nội dung công việc

### Giao thức đánh giá FashionIQ

- Tập val: dress 2.017, shirt 2.038, toptee 1.961 truy vấn; kho ảnh tương ứng 3.817 / 6.346 / 5.373. Mỗi truy vấn có hai câu điều chỉnh, ghép “c1 and c2” và “c2 and c1”, mã hóa “a photo of [$] that …” cho cả hai thứ tự rồi lấy trung bình vector.
- Recall@K: tỷ lệ truy vấn có ảnh đích trong K kết quả đầu (K = 10, 50); báo cáo từng nhóm và trung bình (TB).

### Kết quả tái hiện (checkpoint chính thức, ViT-L)

- Dress 21,32 / 42,19 (bài báo 20,92 / 42,44); Shirt 28,70 / 46,76 (29,10 / 46,81); Toptee 29,02 / 49,41 (28,81 / 50,18); TB 26,35 / 46,12 (26,28 / 46,49). Lệch lớn nhất 0,77 điểm.
- Nguyên nhân lệch nhỏ: khác phiên bản thư viện/tokenizer, số học dấu phẩy động, ảnh FashionIQ từ bản sao HuggingFace (đủ 15.415/15.415 ảnh cần thiết). Đánh giá hai lần cho thứ hạng từng truy vấn giống hệt → quy trình ổn định.
- CIRCO val: mAP@5 = 10,50, mAP@10 = 12,22. Bài báo chỉ công bố tập test (12,59 / 13,58) — tập test chấm trên máy chủ, đáp án không công khai → không so trực tiếp; số val dùng làm mốc cho các biến thể.

### Khác biệt bài báo – mã nguồn

- **Cấu trúc φ:** bài báo ghi LN–Linear–GELU–Linear–GELU–Linear–LN, nhưng mã và checkpoint công bố **không có LayerNorm** (checkpoint nạp khớp tuyệt đối vào MLP không LN) → số liệu trong bài báo đến từ mô hình không LN.

- **Dữ liệu huấn luyện:** bài báo nêu CC3M + 2,47 triệu prompt Stable Diffusion; mã nạp thêm bộ prompt Midjourney.
- **Trích từ khóa:** mã giữ cả từ hạn định (DET, ví dụ "a", "the") trong cụm từ khóa.
- **Chọn checkpoint:** mã chọn theo R@1 trên CIRR dev; nhóm không có CIRR nên dùng checkpoint bước cuối cho mọi biến thể (không chọn trên tập báo cáo).
- Nhóm giữ hành vi của mã nguồn cho baseline vì đây là cấu hình sinh ra checkpoint công bố.

### Baseline nhóm tự chạy vs checkpoint chính thức

- Baseline của nhóm: 5.000 bước (bài báo 20.000), checkpoint bước cuối. Khoảng cách với checkpoint chính thức: FashionIQ R@10 25,90 so với 26,35 (−0,45), CIRCO mAP@5 10,47 so với 10,50 — gần như bằng. Ý nghĩa: cho biết ảnh hưởng của việc rút ngắn huấn luyện; mọi so sánh cải tiến là với baseline cùng cấu hình, không với số của bài báo.

### Tệp liên quan trong dự án

- experiments/runs/EXP-000-official-s0/ — metrics.json, per_query_*.csv
- scripts/eval_per_query.py — đánh giá (FashionIQ, CIRCO)
- code/models.py (lớp Phi), code/loader.py (build_loader, extract_keywords_spacy)

## 5. Kịch bản trình bày chi tiết

| Slide | Ý chính cần nói |
|---|---|
| 11 | Trước khi cải tiến phải chắc đường ống đúng: đánh giá checkpoint chính thức bằng mã đã chuyển đổi. Bảng: lệch tối đa 0,77 điểm, TB R@10 +0,07. Nêu 3 khác biệt bài báo–mã nguồn và vì sao nhóm theo mã. CIRCO val là mốc tham chiếu. |
| 12 | So với baseline nhóm tự chạy (không so với bài báo). Bảng kết quả (mean ± std, 3 seed) và bảng kiểm định (Δ, KTC 95%, p bootstrap, p Wilcoxon). Kết luận: B tốt hơn có ý nghĩa trên FashionIQ R@10 (+0,60, p = 0,006), R@50 (+1,27, p < 0,001) và CIRCO mAP@25/50; mAP@5/10 chưa đủ bằng chứng (chỉ 220 truy vấn). A và A+B kém trên CIRCO (KTC nằm dưới 0). |
| 14 | Kết luận: H2 (B) được ủng hộ, H1 (A) và H3 (A+B) bị bác bỏ; tính nhất quán của φ qua modality gap quyết định chất lượng truy xuất. Hạn chế: 5.000 bước, không quét λ/α, không có CIRR, CIRCO chỉ val. Hướng phát triển: đủ 20.000 bước, quét tham số, CIRR + CIRCO test, hướng C (IDF). |

## 6. Câu hỏi phản biện dự kiến

**H1. Lệch 0,77 điểm có đáng lo không?**

→ Không: cùng bậc với nhiễu do khác phiên bản thư viện và ảnh bản sao; có nhóm lệch dương, nhóm lệch âm, trung bình R@10 chỉ +0,07. Quan trọng là đường ống tái lập được (chạy lại giống hệt) và khớp bài báo.

**H2. Ảnh FashionIQ lấy từ bản sao có đáng tin?**

→ Đủ 15.415/15.415 ảnh cần cho tập val, mã ảnh khớp danh sách chính thức, và kết quả tái hiện khớp bài báo — nếu ảnh sai, R@K sẽ lệch lớn.

**H3. Bài báo có LayerNorm mà code không — vậy tái hiện cái nào?**

→ Checkpoint công bố không có LN và cho đúng số trong bài báo → bài báo mô tả chưa chính xác. Nhóm tái hiện đúng mô hình đã tạo ra số liệu.

**H4. Vì sao không so CIRCO với bài báo?**

→ Bài báo báo cáo tập test (chấm trên máy chủ); nhóm chỉ có đáp án tập val. Hai tập khác truy vấn nên không so trực tiếp.

**H5. Baseline 5.000 bước thấp hơn checkpoint chính thức thì kết luận còn giá trị?**

→ Có, vì so sánh cải tiến luôn là cùng cấu hình (cùng 5.000 bước, cùng dữ liệu, cùng seed). Khoảng cách với checkpoint chính thức chỉ nói về số bước, không về cải tiến.

**H6. Bỏ CIRR có ảnh hưởng gì?**

→ Không ảnh hưởng tính hợp lệ: vẫn có hai bộ ở hai lĩnh vực (thời trang, ảnh đời thực); bài báo cũng nhận xét CIRR nhiều nhiễu. Hạn chế là không đối chiếu được Bảng 6 của bài báo.

## 7. Tự kiểm tra trước buổi thuyết trình

- ☐ Nói được bảng tái hiện từ trí nhớ (ít nhất TB R@10, R@50 và mức lệch).
- ☐ Giải thích giao thức FashionIQ (hai câu, hai thứ tự).
- ☐ Nêu đủ 3 khác biệt bài báo–mã nguồn và hệ quả.
- ☐ Phân biệt so với bài báo (tái hiện) và so với baseline (cải tiến).

## 8. Đọc thêm

- Báo cáo: mục 3.5, 5.2, 5.4, 5.5, 5.6, chương 6, Kết luận
- Bài báo LinCIR: Bảng 3, 5, 6 và mục 4.2
- FashionIQ (Wu 2021), CIRCO trong SEARLE (Baldrati 2023)
- results/tables/main_results.md, significance.md (hỏi Dũng cách đọc p-value, KTC)