KỊCH BẢN THUYẾT TRÌNH

Nhóm 8 · Tái hiện và cải tiến LinCIR (CVPR 2024) · Người trình bày: Đào Văn Tâm

Cách dùng

- Kịch bản khớp từng trang của Slides_Nhom8_LinCIR.pptx (16 slide). Mỗi mục gồm lời nói và câu chuyển sang slide sau (in nghiêng).
- Thời lượng ước tính theo tốc độ nói khoảng 160 tiếng/phút: tổng khoảng 17:55. Đọc thành tiếng 2–3 lần, bấm giờ; nếu dài hơn 16 phút, rút gọn đoạn thứ ba của slide 11 (chi tiết Kaggle) và giữ các con số chính.
- Một số chi tiết không có trên slide nhưng có trong lời nói (cấu hình và số giờ chạy Kaggle ở slide 11, ví dụ câu ở slide 3 và 7). Đọc mục "Tóm tắt dễ hiểu" ngay sau bảng này trước khi tập. Bảng số liệu Kaggle đầy đủ ở Phụ lục A; thuật ngữ, tên riêng, viết tắt ở Phụ lục B; ký hiệu ở Phụ lục C.
- Chữ xám nhỏ trong ngoặc vuông là chú thích (cách đọc, viết tắt của gì, nghĩa) ở lần đầu một thuật ngữ xuất hiện; không đọc phần này thành tiếng.

Slide	Tiêu đề	Thời lượng	Mốc
1	Bìa	1:25	1:25
2	Phân chia công việc của nhóm 8	0:55	2:20
3	Truy vấn gồm một ảnh tham chiếu và một câu mô tả thay đổi	1:30	3:50
4	CIR là truy xuất có xếp hạng, đo bằng R@K và mAP@K	1:35	5:30
5	Ảnh được biến thành một "từ giả" [$] trong câu truy vấn	0:45	6:15
6	Bài báo LinCIR: huấn luyện truy xuất ảnh kết hợp chỉ bằng văn bản	1:10	7:20
7	LinCIR học từ giả chỉ bằng văn bản nhờ Self-Masking Projection	1:05	8:25
8	Nhiễu giúp φ dùng được vector ảnh dù hai miền lệch nhau	0:55	9:20

9	Cải tiến A: thêm InfoNCE để từ giả phân biệt được các câu	0:50	10:10
10	Cải tiến B: dịch nhiễu theo hướng của modality gap	1:00	11:10
11	Dựng lại mã nguồn và chạy 4 biến thể × 3 seed trên Kaggle	2:15	13:25
12	Checkpoint chính thức tái hiện khớp bài báo, lệch tối đa 0,77 điểm	0:50	14:15
13	Nhiễu có hướng (B) tốt hơn LinCIR, InfoNCE (A) làm giảm hiệu năng	1:10	15:25
14	Vì sao: B làm φ nhất quán hơn giữa ảnh và văn bản, A làm ngược lại	1:00	16:25
15	Kết luận: H2 được ủng hộ, H1 và H3 bị bác bỏ	1:20	17:45
16	Cảm ơn cô và các bạn đã theo dõi	0:10	17:55

Tóm tắt dễ hiểu (đọc trước khi tập)

Nắm phần này trước để nói tự nhiên: khi trình bày, giải thích bằng ngôn ngữ thường trước rồi mới gọi tên thuật ngữ.

Bài báo nói về điều gì

Bài toán. Bạn đang xem ảnh một chiếc váy hoa màu xanh trên trang bán hàng. Bạn muốn tìm một chiếc gần giống nhưng có thêm vài thay đổi, và gõ: "màu bạc, bóng hơn, tay ngắn hơn". Hệ thống phải tìm trong hàng chục nghìn ảnh ra chiếc váy vừa giữ kiểu dáng của ảnh ban đầu, vừa có đúng các thay đổi đó. Bài toán tìm kiếm bằng một ảnh kèm một câu mô tả thay đổi như vậy gọi là **truy xuất ảnh kết hợp**.

Bài toán này khó vì câu "màu bạc, tay ngắn hơn" không tự mô tả được chiếc váy cần tìm. Nó chỉ có nghĩa khi đặt cạnh ảnh ban đầu. Hệ thống phải hiểu cả ảnh lẫn câu cùng lúc.

Cách làm cũ và chỗ tốn kém. Cách đơn giản là thuê người tạo dữ liệu mẫu: mỗi mẫu gồm ảnh ban đầu, câu mô tả thay đổi và ảnh đúng cần tìm. Việc này rất tốn công, nên bộ dữ liệu lớn nhất cũng chỉ có khoảng 46 nghìn mẫu. Mô hình học từ dữ liệu thời trang thì cũng chỉ dùng tốt cho thời trang.

Một số phương pháp gần đây tránh được việc thuê người gán nhãn. Ý tưởng chung là đổi ảnh ban đầu thành một "từ đặc biệt", rồi ghép từ đó vào câu tìm kiếm, ví dụ: "ảnh của [từ đặc biệt], màu bạc, tay ngắn hơn". Một mô hình có sẵn tên CLIP, vốn đã được huấn luyện trên hàng trăm triệu cặp ảnh và câu, sẽ biến câu này thành con số rồi so với từng ảnh trong kho. Chỉ cần dạy một mạng nhỏ (gọi là φ) cách đổi ảnh thành từ đặc biệt.

Tuy vậy, các phương pháp trước vẫn dùng ảnh khi dạy mạng φ. Việc này nặng: bộ ảnh huấn luyện chiếm khoảng 430 GB, trong khi phần chữ đi kèm chỉ 125 MB. Chúng cũng chỉ học với một mẫu câu cố định.

Ý tưởng của LinCIR. Tác giả (công ty NAVER, Hàn Quốc, công bố năm 2024) đề xuất dạy mạng φ **chỉ bằng chữ, không cần ảnh**. Cách làm:

1. Lấy một câu, ví dụ "con mèo xám ngủ trên gối".
2. Che các từ quan trọng, câu thành "[…] ngủ trên […]".
3. Cho mạng φ đọc câu gốc rồi tạo ra một từ đặc biệt điền vào chỗ trống.
4. Yêu cầu câu đã điền phải mang nghĩa giống câu gốc.

Muốn làm được, mạng φ phải học cách gói nội dung chính của cả câu vào một từ. Khi dùng thật, đưa ảnh vào thay cho câu, mạng φ tạo ra từ đặc biệt đại diện cho ảnh.

Có một trở ngại: trong CLIP, con số biểu diễn ảnh và con số biểu diễn chữ nằm ở hai vùng khác nhau, dù cùng nói về một thứ. Mạng φ học trên chữ nhưng lại phải xử lý ảnh. Tác giả giải quyết bằng cách thêm nhiễu ngẫu nhiên vào đầu vào khi huấn luyện, để mạng quen với những đầu vào lệch khỏi vùng chữ.

Kết quả bài báo. LinCIR đạt kết quả tốt nhất trên bốn bộ đánh giá, huấn luyện nhanh hơn các phương pháp trước 6 đến 8 lần, và trên bộ thời trang còn vượt một phương pháp phải dùng dữ liệu do người gán nhãn.

Nhóm 8 đã làm gì

1. Dựng lại và kiểm tra. Mã nguồn của tác giả viết cho phiên bản thư viện cũ, không chạy được trên máy hiện nay. Nhóm viết lại phần bị hỏng, sửa 4 lỗi, rồi kiểm tra: phần viết lại cho ra con số giống hệt bản gốc. Sau đó nhóm chạy lại mô hình tác giả công bố bằng mã của nhóm. Kết quả khớp bài báo, lệch không quá 0,77 điểm. Như vậy cách đánh giá của nhóm đáng tin.

2. Đặt câu hỏi. LinCIR có hai thành phần chính: cách chấm điểm khi dạy mạng φ, và phần nhiễu. Nhóm hỏi: sửa một trong hai thành phần này thì kết quả có tốt hơn không?

3. Hai cải tiến.

- **Cải tiến A (sửa cách chấm điểm).** Cách chấm gốc chỉ yêu cầu câu đã điền giống câu gốc. Nó không phạt trường hợp câu đã điền cũng giống nhiều câu khác. Nhóm thêm một yêu cầu: câu đã điền phải giống câu gốc **hơn** 511 câu khác đang xét cùng lúc. Kỳ vọng là mạng φ phân biệt rõ hơn, nên tìm kiếm chính xác hơn.
- **Cải tiến B (sửa phần nhiễu).** Nhiễu gốc lệch ngẫu nhiên theo mọi hướng. Nhóm đo hướng từ vùng chữ sang vùng ảnh, rồi cho nhiễu lệch có chủ đích về phía vùng ảnh. Khi đó mạng φ được luyện với đầu vào gần với ảnh thật mà nó sẽ gặp khi dùng.
- **Kết hợp A+B** để xem hai cải tiến có cộng thêm cho nhau không.

4. Thử nghiệm công bằng. Nhóm chạy cả bốn phiên bản (bản gốc, A, B, A+B) với cùng điều kiện, mỗi phiên bản 3 lần với khởi tạo ngẫu nhiên khác nhau, tổng cộng 12 lần. Thực nghiệm chạy trên máy chủ GPU miễn phí của Kaggle, dùng gần 23 trên 30 giờ được phép mỗi tuần. Kết quả được đánh giá trên hai bộ dữ liệu: thời trang (FashionIQ) và ảnh đời thực (CIRCO). Mọi chênh lệch đều được kiểm định thống kê để chắc rằng không do ngẫu nhiên.

Kết quả

- **Cải tiến B tốt hơn bản gốc, và có ý nghĩa thống kê.** Trên bộ thời trang, cứ 1.000 lượt tìm kiếm thì B tìm đúng thêm khoảng 6 lượt trong 10 kết quả đầu. B chỉ huấn luyện bằng một phần tư thời gian nhưng vẫn vượt cả mô hình tác giả công bố.
- **Cải tiến A làm kết quả kém đi,** rõ nhất trên ảnh đời thực (điểm giảm từ 10,47 xuống 8,02). A+B cũng kém.

Vì sao. Nhóm đưa cùng một cặp ảnh và câu mô tả vào mạng φ, rồi đo hai đầu ra giống nhau đến mức nào:

- Với B, hai đầu ra giống nhau nhất: mạng xử lý ảnh nhất quán với cách nó xử lý chữ.
- Với A, độ giống giảm mạnh. Yêu cầu "phân biệt với 511 câu khác" khiến mạng học những chi tiết chỉ có ở chữ, mà ảnh không có.

Kết luận của nhóm. Với LinCIR, điều quan trọng nhất là mạng φ xử lý ảnh nhất quán với chữ. Làm cho mạng phân biệt các câu tốt hơn thì không giúp ích. Kết luận này có số đo trực tiếp và kiểm định thống kê làm căn cứ, không phải phỏng đoán.

Lời trình bày theo từng slide

Slide 1. Bìa

Khoảng 1:25 · đến mốc 1:25

Em chào cô và các bạn. Em là Đào Văn Tâm, đại diện Nhóm 8, lớp M25CQHT02-B. Đề tài của nhóm là tái hiện và cải tiến phương pháp LinCIR [đọc "lin-kơ, tác giả đọc như linker"; Language-only training for Composed Image Retrieval; phương pháp của bài báo: huấn luyện CIR chỉ bằng văn bản], công bố tại hội nghị CVPR [đọc "xi-vi-pi-a"; Conference on Computer Vision and Pattern Recognition; hội nghị hàng đầu về thị giác máy tính] 2024.

Trước khi vào chi tiết, em xin tóm tắt bằng một ví dụ. Khi xem ảnh một chiếc váy trên trang bán hàng, người dùng có thể muốn tìm chiếc gần giống nhưng "màu bạc, tay ngắn hơn". Hệ thống phải hiểu cả ảnh lẫn câu để tìm đúng chiếc váy đó; bài toán này gọi là truy xuất ảnh kết hợp. Bài báo LinCIR dạy máy làm việc này chỉ bằng văn bản, không cần ảnh và không cần người gán nhãn, nên huấn luyện nhanh hơn các cách trước 6 đến 8 lần.

Nhóm em dựng lại mã nguồn, kiểm tra kết quả khớp bài báo, rồi thử hai cải tiến. Cải tiến B, cho phần nhiễu khi huấn luyện lệch có chủ đích về phía ảnh, tốt hơn bản gốc có ý nghĩa thống kê. Cải tiến A, bắt mô hình phân biệt các câu rõ hơn, lại làm kết quả kém đi. Phần trình bày sẽ đi lần lượt qua bài toán, phương pháp, hai cải tiến, thực nghiệm và lý do của kết quả, trong khoảng mười lăm phút.

Chuyển: Trước hết, em xin giới thiệu cách nhóm chia công việc.

Slide 2. Phân chia công việc của nhóm 8

Khoảng 0:55 · đến mốc 2:20

Nhóm có năm thành viên, mỗi người phụ trách một phần. Em phụ trách chuyển đổi mã nguồn sang môi trường mới, kiểm chứng mã chạy đúng như bản gốc và vận hành toàn bộ thực nghiệm trên Kaggle [đọc "ca-gồ"; nền tảng của Google cho chạy notebook với GPU miễn phí theo hạn mức]. Bạn Trung đề xuất và cài đặt cải tiến A, đồng thời phân tích đường học. Bạn Tùng tái hiện kết quả của bài báo và đối chiếu bài báo với mã nguồn. Bạn Dũng thiết kế cách đánh giá, kiểm định thống kê, cài đặt cải tiến B và phân tích modality gap [đọc "mô-đa-li-ti ghép"; khoảng cách giữa vùng vector ảnh và vùng vector văn bản trong CLIP]. Bạn Mekdala Nounou làm phần tổng quan lý thuyết, phân tích định tính và thiết kế slide.

Em sẽ trình bày toàn bộ. Ở phần hỏi đáp, bạn phụ trách phần nào sẽ trả lời phần đó; cột bên phải là các slide mỗi bạn hỗ trợ.

Chuyển: Bây giờ em đi vào bài toán.

Slide 3. Truy vấn gồm một ảnh tham chiếu và một câu mô tả thay đổi

Khoảng 1:30 · đến mốc 3:50

Bài toán của bài báo là truy xuất ảnh kết hợp, viết tắt là CIR [đọc "xi-ai-a"; Composed Image Retrieval; truy xuất ảnh kết hợp: truy vấn gồm ảnh tham chiếu và câu mô tả thay đổi]. Truy vấn gồm hai phần: một ảnh tham chiếu và một câu mô tả thay đổi. Trong ví dụ trên slide, ảnh tham chiếu là một chiếc váy họa tiết xanh, còn câu là "is shiny and silver with shorter sleeves", tức là bóng hơn, màu bạc và tay ngắn hơn. Hệ thống phải tìm trong kho ảnh chiếc váy giữ kiểu dáng của ảnh tham chiếu nhưng áp dụng đúng các thay đổi, và trả về một danh sách ảnh được xếp hạng. Điểm khó là câu chỉ mô tả phần thay đổi, không mô tả toàn bộ ảnh đích, nên không thể chỉ tìm bằng chữ hoặc chỉ tìm bằng ảnh.

Cách học có giám sát cần các bộ ba gồm ảnh tham chiếu, câu và ảnh đích do người gán nhãn. Các bộ này đắt và ít: FashionIQ [đọc "pha-sần ai-kiu"; bộ dữ liệu CIR về thời trang (váy, áo sơ mi, áo phông), mỗi truy vấn có 1 ảnh đúng] chỉ có khoảng 46,6 nghìn bộ ba. Vì vậy hướng zero-shot [đọc "di-rô sốt"; không dùng dữ liệu có nhãn của chính bài toán khi huấn luyện] không dùng bộ ba nào khi huấn luyện. Bài báo LinCIR giải bài toán theo hướng này và chỉ dùng văn bản để huấn luyện.

Câu hỏi nhóm đặt ra là: nếu sửa một trong hai thành phần cốt lõi của LinCIR, là hàm mất mát hoặc nhiễu, thì kết quả truy xuất có tốt hơn không.

Chuyển: Để trả lời "tốt hơn" một cách định lượng, trước hết cần thống nhất cách đo.

Slide 4. CIR là truy xuất có xếp hạng, đo bằng R@K và mAP@K

Khoảng 1:35 · đến mốc 5:30

CIR vẫn là một bài toán truy xuất có xếp hạng như chương I của môn học: có nhu cầu thông tin, có truy vấn và hệ thống trả về danh sách xếp hạng. Điểm khác là thay vì khớp từ chính xác như mô hình Boolean [đọc "bu-li-ần"; mô hình truy xuất khớp chính xác theo biểu thức AND, OR, NOT] hay chỉ mục ngược [inverted index; bảng tra từ → danh sách tài liệu chứa từ đó], ở đây ảnh và truy vấn đều được mã hóa thành vector [đọc "véc-tơ"; dãy số biểu diễn một ảnh hoặc một câu] CLIP [đọc "clíp"; Contrastive Language–Image Pre-training; mô hình của OpenAI đưa ảnh và văn bản vào cùng một không gian vector], và ảnh được xếp hạng theo độ tương đồng cosine [đọc "cô-sin"; cosine similarity; độ tương đồng giữa hai vector, từ −1 đến 1, càng lớn càng giống] với vector truy vấn.

Nhóm dùng hai độ đo. Thứ nhất là Recall [đọc "ri-con"; độ phủ: tỉ lệ kết quả đúng được tìm thấy] tại K: số truy vấn có ảnh đích nằm trong K kết quả đầu, chia cho tổng số truy vấn. Độ đo này dùng cho FashionIQ, vì mỗi truy vấn chỉ có một ảnh đúng. Ví dụ R@10 [đọc "Recall tại 10"; Recall at 10; tỉ lệ truy vấn có ảnh đích trong 10 kết quả đầu] bằng 26 nghĩa là 26% số truy vấn có ảnh đích trong mười kết quả đầu. Thứ hai là mAP [đọc "em-ây-pi"; mean Average Precision; trung bình của AP trên các truy vấn] tại K, dùng cho CIRCO [đọc "xơ-cô"; Composed Image Retrieval on Common Objects in context; bộ dữ liệu CIR trên ảnh đời thực COCO, mỗi truy vấn có nhiều ảnh đúng], vì mỗi truy vấn có nhiều ảnh đúng.

AP [đọc "ây-pi"; Average Precision; trung bình Precision tại các vị trí có kết quả đúng] tại K lấy Precision [đọc "pri-xi-giần"; độ chính xác: tỉ lệ kết quả trả về là đúng] tại các vị trí có ảnh đúng, cộng lại rồi chia cho số ảnh đúng tối đa có thể nằm trong K kết quả; mAP là trung bình trên các truy vấn. Ảnh đúng xếp càng cao thì điểm càng cao.

Nhóm đánh giá trên FashionIQ val [đọc "va-li-đây-sần"; validation; tập kiểm định có đáp án công khai] và CIRCO val, và mọi so sánh đều được kiểm định thống kê theo từng truy vấn bằng bootstrap [đọc "bút-xtrép"; paired bootstrap; lấy mẫu lại các truy vấn 10.000 lần để ước lượng khoảng tin cậy của chênh lệch] ghép cặp và kiểm định Wilcoxon [đọc "uyn-cốc-xơn"; Wilcoxon signed-rank test; kiểm định phi tham số so sánh hai kết quả ghép cặp].

Chuyển: Tiếp theo là cách các phương pháp zero-shot biến một ảnh thành thứ mà bộ mã hóa văn bản hiểu được.

Slide 5. Ảnh được biến thành một "từ giả" [$] trong câu truy vấn

Khoảng 0:45 · đến mốc 6:15

Ý tưởng chung là biến ảnh tham chiếu thành một từ giả. Ảnh đi qua bộ mã hóa ảnh của CLIP, rồi qua một mạng chiếu nhỏ ký hiệu là phi [ký hiệu φ (phi); mạng chiếu 3 lớp, phần duy nhất được huấn luyện]; đầu ra là một token [đọc "tô-kần"; đơn vị đầu vào của bộ mã hóa văn bản (một từ hoặc mảnh từ)] giả, trên slide là ký hiệu đô-la trong ngoặc vuông. Token này được ghép vào câu "a photo of token giả that", nối với câu mô tả thay đổi. Bộ mã hóa văn bản biến cả câu thành vector truy vấn, rồi hệ thống xếp hạng ảnh trong kho theo cosine. Toàn bộ CLIP được giữ nguyên; thứ duy nhất phải học là mạng chiếu phi.

Chuyển: Vấn đề là học phi như thế nào, và đây chính là chỗ LinCIR khác các phương pháp trước.

Slide 6. Bài báo LinCIR: huấn luyện truy xuất ảnh kết hợp chỉ bằng văn bản

Khoảng 1:10 · đến mốc 7:20

Bài báo LinCIR của Gu và các cộng sự tại NAVER [đọc "nây-vơ"; tập đoàn công nghệ Hàn Quốc, nơi các tác giả làm việc], công bố ở CVPR 2024. Vấn đề họ chỉ ra là các phương pháp trước như Pic2Word [đọc "píc-tu-uơd"; Picture to Word; phương pháp zero-shot CIR trước LinCIR (CVPR 2023), học φ bằng ảnh] và SEARLE [đọc "xơ-lơ"; zero-Shot composEd imAge Retrieval with textuaL invErsion; phương pháp zero-shot CIR trước LinCIR (ICCV 2023), học φ bằng ảnh] học phi bằng ảnh, nên phải chạy bộ mã hóa ảnh ở mỗi bước huấn luyện: ảnh của bộ CC3M [đọc "xê-xê ba em"; Conceptual Captions 3 Million; bộ khoảng 3 triệu cặp ảnh – chú thích lấy từ web] chiếm khoảng 430 GB [đọc "ghi-ga-bai"; gigabyte; đơn vị dung lượng], trong khi chú thích chỉ 125 MB [đọc "mê-ga-bai"; megabyte; đơn vị dung lượng, 1.000 MB ≈ 1 GB]. Đồng

thời chúng chỉ học với một câu mẫu cố định "a photo of token giả", nên kém với các câu mô tả đa dạng.

Ý tưởng của LinCIR là học phi chỉ từ văn bản bằng cơ chế Self-Masking Projection [đọc "xen ma-xking prô-giéc-sần"; SMP; chiếu tự che: che từ khóa, thay bằng token do φ tạo từ chính câu đó], và thêm nhiễu khi huấn luyện để phi dùng được cho vector ảnh. Kết quả công bố: tốt nhất trên bốn bộ đánh giá zero-shot, huấn luyện nhanh hơn Pic2Word 6 lần và SEARLE 8,4 lần với ViT-L [đọc "vít L"; Vision Transformer – Large; bộ mã hóa ảnh cỡ lớn của CLIP], và trên FashionIQ còn vượt cả một phương pháp có giám sát. Mã nguồn được công khai, đây là cơ sở để nhóm dựng lại và cải tiến.

Chuyển: Em trình bày lần lượt hai thành phần chính, bắt đầu từ Self-Masking Projection.

Slide 7. LinCIR học từ giả chỉ bằng văn bản nhờ Self-Masking Projection

Khoảng 1:05 · đến mốc 8:25

Sơ đồ này là phương pháp gốc. Lấy một câu, ví dụ "gray cat sleeps on a pillow". Bộ mã hóa văn bản, được giữ nguyên, cho vector z c của câu. Vector này đi qua phi để thành một token giả. Song song, các từ khóa là tính từ và danh từ, được trích bằng thư viện spaCy [đọc "xpây-xi"; thư viện xử lý ngôn ngữ tự nhiên, dùng để tìm tính từ và danh từ], bị che bằng ký hiệu đô-la, nên câu trở thành "đô-la sleeps on đô-la". Sau đó thay ký hiệu đô-la bằng token mà phi vừa tạo và mã hóa lại câu này, được vector z c mũ.

Hàm mất mát là MSE [đọc "em-ét-i"; Mean Squared Error; sai số bình phương trung bình giữa hai vector] giữa z c và z c mũ: câu đã che phải mang cùng nghĩa với câu gốc. Muốn vậy, token giả phải gói nội dung chính của câu vào một từ. Trên sơ đồ, ô màu xanh là phần đóng băng, ô màu cam là phần được huấn luyện.

Chuyển: Nhưng khi dùng thật, phi lại nhận vector ảnh chứ không phải vector câu. Đó là lý do có thành phần thứ hai.

Slide 8. Nhiễu giúp φ dùng được vector ảnh dù hai miền lệch nhau

Khoảng 0:55 · đến mốc 9:20

Trong CLIP, vector ảnh và vector văn bản nằm ở hai vùng tách biệt, hiện tượng này gọi là modality gap. Nhóm đo trên 5.000 cặp ảnh – chú thích của COCO [đọc "cô-cô"; Common Objects in COntext; bộ ảnh đời thực của Microsoft; val2017 là tập kiểm định năm 2017]: tâm vùng ảnh và tâm vùng văn bản cách nhau 0,82, và một ảnh với chính chú thích của nó chỉ có cosine trung bình 0,26.

Phi học hoàn toàn trên văn bản nhưng khi suy luận lại nhận vector ảnh. Để phi chịu được độ lệch này, LinCIR cộng nhiễu vào z c khi huấn luyện: n bằng u nhân ép-xi-lon [ký hiệu ε

(epsilon); nhiễu ngẫu nhiên theo phân phối chuẩn], trong đó u lấy ngẫu nhiên từ 0 đến 1, còn ép-xi-lon theo phân phối chuẩn, nên độ lớn của nhiễu đa dạng.

Chuyển: Như vậy LinCIR có hai thành phần là hàm mất mát và nhiễu. Hai cải tiến của nhóm lần lượt nhắm vào từng thành phần.

Slide 9. Cải tiến A: thêm InfoNCE để từ giả phân biệt được các câu

Khoảng 0:50 · đến mốc 10:10

Cải tiến A sửa hàm mất mát. MSE chỉ kéo câu đã che về gần câu gốc, nhưng không phạt trường hợp câu đã che cũng gần các câu khác, trong khi việc đánh giá lại là bài toán xếp hạng: điều quan trọng là đúng hơn các ứng viên khác. Nhóm thêm hàm mất mát đối sánh InfoNCE [đọc "in-phô en-xi-i"; Info Noise-Contrastive Estimation; hàm mất mát đối sánh: kéo cặp đúng lại gần, đẩy các mẫu âm ra xa]: L bằng L SMP [đọc "hàm mất mát SMP"; loss of Self-Masking Projection; hàm MSE của LinCIR] cộng 0,5 nhân InfoNCE, với 511 câu khác trong cùng batch [đọc "bát"; lô dữ liệu xử lý cùng lúc trong một bước (ở đây 512 câu)] làm mẫu âm và nhiệt độ tô [ký hiệu τ (tau), temperature; nhiệt độ của InfoNCE, điều chỉnh độ "gắt" khi so sánh] bằng 0,07. Chi phí chỉ tăng khoảng 2% thời gian mỗi bước, 1,474 so với 1,448 giây.

Giả thuyết H1: thêm InfoNCE làm tăng R@K [đọc "Recall tại K"; Recall at K; tỉ lệ truy vấn có ảnh đích trong K kết quả đầu] và mAP@K [đọc "em-ây-pi tại K"; mean Average Precision at K; mAP chỉ xét K kết quả đầu] so với baseline [đọc "bây-lai"; mốc so sánh: LinCIR gốc do nhóm tự huấn luyện cùng cấu hình]. Em sẽ quay lại giả thuyết này ở phần kết quả.

Chuyển: Cải tiến B nhắm vào thành phần còn lại là nhiễu.

Slide 10. Cải tiến B: dịch nhiễu theo hướng của modality gap

Khoảng 1:00 · đến mốc 11:10

Nhiễu của LinCIR đều theo mọi hướng. Nó giúp phi quen với đầu vào bị lệch, nhưng không lệch về phía vùng ảnh, là nơi phi thực sự nhận đầu vào khi suy luận. Cải tiến B thêm một thành phần có hướng: n bằng 0,5 nhân đen-ta [ký hiệu Δ (delta); vector từ tâm vùng văn bản tới tâm vùng ảnh] cộng u nhân ép-xi-lon, trong đó đen-ta là vector từ tâm vùng văn bản tới tâm vùng ảnh. Đen-ta được tính một lần trên 5.000 cặp ảnh – chú thích của COCO val2017, có độ lớn 13,87; tập này khác các tập đánh giá nên không rò rỉ dữ liệu.

Giả thuyết H2: phi sẽ cho kết quả nhất quán hơn giữa ảnh và văn bản, từ đó R@K và mAP@K tăng. Vì A và B sửa hai thành phần khác nhau, nhóm đặt thêm giả thuyết H3: kết hợp A và B có thể cộng hưởng.

Chuyển: Để kiểm chứng ba giả thuyết, nhóm phải dựng lại mã và chạy thực nghiệm.

Slide 11. Dựng lại mã nguồn và chạy 4 biến thể × 3 seed trên Kaggle

Khoảng 2:15 · đến mốc 13:25

Mã nguồn gốc viết cho thư viện transformers [đọc "tran-xpho-mơ"; thư viện mô hình học sâu mã nguồn mở của Hugging Face] phiên bản 4.34 và dùng một hàm nội bộ đã bị bỏ ở phiên bản hiện tại, nên không chạy được. Em viết lại phần mã hóa văn bản từ các mô-đun con của CLIP, thay tokenizer [đọc "tô-kần-nai-dơ"; bộ tách câu thành các token] và sửa bốn lỗi trong mã gốc. Để chắc phần viết lại đúng, em so trực tiếp vector đầu ra với CLIP gốc trên cùng câu: sai lệch bằng 0,00 trên cả ViT-B/32 [đọc "vít B ba hai"; Vision Transformer – Base, patch 32 × 32; phiên bản CLIP nhỏ, dùng để chạy thử trên Mac] và ViT-L/14 [đọc "vít L mười bốn"; Vision Transformer – Large, patch 14 × 14; phiên bản CLIP nhóm dùng].

Thực nghiệm chạy trên Kaggle với 2 GPU [đọc "gi-pi-du"; Graphics Processing Unit; bộ xử lý đồ họa, dùng để huấn luyện mô hình] NVIDIA T4 [đọc "en-vi-đi-a ti-pho"; loại GPU 16 GB mà Kaggle cung cấp], mỗi GPU 16 GB, và 4 nhân CPU [đọc "xi-pi-du"; Central Processing Unit; bộ xử lý trung tâm]. Kaggle giới hạn 30 giờ GPU mỗi tuần và tối đa 12 giờ mỗi phiên. Cấu hình huấn luyện giống mã chính thức: CLIP ViT-L/14, batch 512, độ chính xác hỗn hợp fp16 [đọc "ép-pi mười sáu"; floating point 16-bit; số thực 16 bit, giúp huấn luyện nhanh và tốn ít bộ nhớ], AdamW [đọc "a-đam đáp-bờ-liu"; Adam with decoupled Weight decay; thuật toán tối ưu dùng để cập nhật φ] với tốc độ học 10 mũ trừ 4 và weight decay [đọc "uết đi-cây"; phạt trọng số lớn để giảm quá khớp] 0,01; mỗi run [đọc "ran"; một lần huấn luyện với một cấu hình và một seed] dùng tối đa 11,4 GB bộ nhớ trên một GPU. Bài báo huấn luyện 20.000 bước; trên T4 việc này mất khoảng 13 giờ mỗi run, vượt giới hạn một phiên, nên nhóm giảm xuống 5.000 bước, như nhau cho mọi biến thể, và dùng checkpoint [đọc "chếch-poi"; trọng số mô hình được lưu tại một bước huấn luyện] ở bước cuối.

Tổng cộng có 12 run: bốn biến thể baseline, A, B, A+B, mỗi biến thể ba seed [đọc "xít"; random seed; giá trị khởi tạo bộ sinh số ngẫu nhiên; chạy 3 seed để kiểm tra độ ổn định] là 12345, 2024 và 7. Mỗi GPU chạy một run độc lập để giữ đủ batch 512, nên hai run chạy song song. Phiên huấn luyện đầu tiên chỉ xong hai run, mỗi run 6,2 giờ, vì CPU bị nghẽn ở bước trích từ khóa bằng spaCy. Em chuyển spaCy sang xử lý theo lô và bỏ hai thành phần không dùng; nạp dữ liệu nhanh gấp 3,1 lần mà kết quả che từ khóa giống hệt bản cũ. Sau đó mỗi run chỉ còn khoảng 2 giờ, tương đương 1,45 giây mỗi bước. Theo bộ đếm hạn mức của Kaggle, toàn bộ dự án, gồm chạy thử, chuẩn bị dữ liệu, ba phiên huấn luyện và phiên đánh giá, dùng 22 giờ 52 phút trong hạn mức 30 giờ.

Chuyển: Trước khi so sánh các cải tiến, cần chắc quy trình đánh giá cho số liệu đúng.

Slide 12. Checkpoint chính thức tái hiện khớp bài báo, lệch tối đa 0,77 điểm

Khoảng 0:50 · đến mốc 14:15

Nhóm đánh giá lại checkpoint chính thức của tác giả bằng mã đã chuyển đổi. Trên FashionIQ, R@10 trung bình là 26,35, so với 26,28 trong bài báo; R@50 [đọc "Recall tại 50"; Recall at 50; tỉ lệ truy vấn có ảnh đích trong 50 kết quả đầu] là 46,12 so với 46,49. Mức lệch lớn nhất ở từng nhóm sản phẩm là 0,77 điểm, và khi chạy lại, thứ hạng của từng truy vấn giống hệt. Như vậy quy trình đánh giá đáng tin cậy.

Khi đọc mã, nhóm cũng thấy ba điểm khác với bài báo: mạng phi trong mã không có LayerNorm [đọc "lay-ơ noóc"; Layer Normalization; lớp chuẩn hóa giá trị trong mạng nơ-ron] như bài báo mô tả; mã nạp thêm một bộ prompt [đọc "prôm"; câu mô tả dùng để yêu cầu mô hình sinh ảnh] Midjourney [đọc "mít-giơ-ni"; dịch vụ sinh ảnh từ văn bản; mã nguồn dùng thêm các câu prompt của dịch vụ này] mà bài báo không nhắc tới; và cụm từ khóa bị che gồm cả mạo từ như "a", "the". Nhóm làm theo mã, vì chính mã đã tạo ra checkpoint và số liệu công bố.

Chuyển: Bây giờ là kết quả chính.

Slide 13. Nhiễu có hướng (B) tốt hơn LinCIR, InfoNCE (A) làm giảm hiệu năng

Khoảng 1:10 · đến mốc 15:25

Bảng này là trung bình và độ lệch chuẩn qua ba seed. Nhóm so với baseline do nhóm tự huấn luyện cùng cấu hình, không so với số của bài báo. Cải tiến B cao nhất ở cả ba cột: FashionIQ R@10 là 26,50, R@50 là 46,79 và CIRCO mAP@5 [đọc "em-ây-pi tại 5"; mean Average Precision at 5; mAP chỉ xét 5 kết quả đầu] là 10,94. So với baseline, B tăng 0,60 điểm R@10 với p [đọc "p (p-value)"; probability value; xác suất thấy mức chênh này nếu cải tiến thật ra không có tác dụng; $p < 0,05$ là có ý nghĩa] bằng 0,006, và 1,27 điểm R@50 với p nhỏ hơn 0,001; mức tăng 0,60 điểm R@10 tương đương khoảng 6 truy vấn đúng thêm trên mỗi 1.000 truy vấn. B chỉ huấn luyện 5.000 bước nhưng vượt cả checkpoint chính thức 20.000 bước ở hàng cuối.

Ngược lại, A giảm mạnh trên CIRCO: mAP@5 giảm 2,45 điểm, khoảng tin cậy 95% [95% confidence interval; khoảng chứa chênh lệch thật với độ tin cậy 95%; nằm hẳn dưới 0 nghĩa là chắc chắn kém hơn] từ âm 3,95 đến âm 1,07, nằm hoàn toàn dưới 0. A cộng B cũng giảm tương tự. Độ lệch chuẩn giữa các seed đều nhỏ, không quá 0,5 điểm, nên các khác biệt này không đến từ ngẫu nhiên khởi tạo.

Chuyển: Câu hỏi tiếp theo là vì sao B tốt hơn, còn A lại kém hơn.

Slide 14. Vì sao: B làm ϕ nhất quán hơn giữa ảnh và văn bản, A làm ngược lại

Khoảng 1:00 · đến mốc 16:25

Nhóm đo một đại lượng trực tiếp: với cùng một cặp ảnh – chú thích, đầu ra của phi khi nhận ảnh và khi nhận văn bản giống nhau đến mức nào, tính bằng cosine. Ở biểu đồ trái, B cao nhất với 0,84, checkpoint chính thức 0,81, baseline 0,80, A cộng B 0,69 và A thấp nhất với 0,64. Thứ tự này trùng với thứ tự CIRCO mAP@5.

Cách giải thích của nhóm: InfoNCE buộc token giả mang những đặc trưng giúp phân biệt các câu văn bản với nhau; các đặc trưng này gắn với miền văn bản và không chuyển được sang vector ảnh. Còn B đưa đầu vào lúc huấn luyện về gần vùng ảnh, nên phi xử lý ảnh nhất quán hơn. Biểu đồ phải là đường học theo số bước: A thấp hơn baseline ở mọi mốc từ 1.000 đến 5.000 bước, nên kết luận về A không phụ thuộc vào điểm dừng.

Chuyển: Em xin tổng kết lại.

Slide 15. Kết luận: H2 được ủng hộ, H1 và H3 bị bác bỏ

Khoảng 1:20 · đến mốc 17:45

Hình bên trái là một truy vấn thật trong FashionIQ. Hàng dưới là B, xếp đúng ảnh đích ở hạng 1; hàng trên là baseline, chủ yếu trả về váy ngắn màu tối. Cũng thấy nhiều ảnh trong top 5 đúng phần lớn yêu cầu nhưng không phải ảnh được gán nhãn; đây là hiện tượng âm tính giả [false negative; ảnh đúng yêu cầu nhưng không được gán nhãn là đáp án], làm R@K đánh giá thấp chất lượng thật của hệ thống.

Kết luận: H2 được ủng hộ, B tốt hơn LinCIR có ý nghĩa thống kê. H1 bị bác bỏ, A làm CIRCO mAP@5 giảm 2,45 điểm. H3 bị bác bỏ, A cộng B kém baseline trên CIRCO. Điều nhóm rút ra là chất lượng truy xuất của LinCIR phụ thuộc chủ yếu vào việc phi xử lý ảnh nhất quán với văn bản, hơn là khả năng phân biệt giữa các câu.

Đóng góp của nhóm gồm dựng lại mã, tái hiện, hai cải tiến, đánh giá có kiểm định và phân tích cơ chế. Hạn chế là mới huấn luyện 5.000 bước, chưa quét hệ số lam-đa [ký hiệu λ (lambda); trọng số của InfoNCE trong cải tiến A] và an-pha [ký hiệu α (alpha); hệ số của Δ trong cải tiến B], chưa đánh giá trên CIRR [đọc "xi-ai-a-a"; Composed Image Retrieval on Real-life images; bộ dữ liệu CIR ảnh đời thực; nhóm chưa dùng được vì chưa được cấp quyền ảnh] và tập test của CIRCO. Hướng tiếp theo là chạy đủ 20.000 bước, quét các hệ số và thử hướng C: chọn từ khóa cần che theo IDF [đọc "ai-đi-ép"; Inverse Document Frequency; tần suất tài liệu nghịch đảo: từ càng hiếm, trọng số càng cao].

Slide 16. Cảm ơn cô và các bạn đã theo dõi

Khoảng 0:10 · đến mốc 17:55

Phần trình bày của nhóm em đến đây là hết. Em cảm ơn cô và các bạn đã lắng nghe; nhóm em rất mong nhận được câu hỏi và góp ý.

Điều phối hỏi đáp: Khi có câu hỏi: nghe hết câu hỏi, nhắc lại ngắn gọn, rồi trả lời hoặc mời người phụ trách. Phương pháp, cải tiến A, đường học: Trung. Tái hiện, bảng kết quả, kết luận: Tùng. Độ đo, kiểm định, cải tiến B, modality gap: Dũng. Bài toán, lý thuyết, ví dụ định tính: Nou. Mã nguồn, Kaggle, thiết lập thực nghiệm: Tâm. Danh sách câu hỏi dự kiến: slides/QA_du_kien.md và mục 6 trong tài liệu học của từng người.

Phụ lục A. Thực nghiệm trên Kaggle: số liệu chi tiết

Dùng khi được hỏi về hạ tầng, cấu hình và thời gian chạy. Nguồn: nhật ký dự án (.claude/skills/roadmap/checklist.md), docs/decisions.md, configs/EXP-001-baseline.yaml.

Hạng mục	Số liệu
Phần cứng	2 × NVIDIA T4 16 GB, 4 vCPU; Python 3.13, PyTorch 2.11
Hạn mức Kaggle	30 giờ GPU mỗi tuần; tối đa 12 giờ mỗi phiên
Đã dùng	22 giờ 52 phút / 30 giờ (đến khi xong phiên đánh giá cuối, 14:02 thứ Sáu 09/10/2026, giờ Hà Nội)
Cấu hình huấn luyện	CLIP ViT-L/14; batch 512; fp16; AdamW, tốc độ học 1e-4, weight decay 0,01; dropout của φ 0,5; tốc độ học cố định; 5.000 bước; lưu checkpoint mỗi 500 bước (để vẽ đường học); dùng checkpoint bước cuối
Bộ nhớ GPU	tối đa 11,4 GB / 15 GB cho một run
Số run	12 run = 4 biến thể (baseline, A, B, A+B) × 3 seed (12345, 2024, 7), cộng đánh giá checkpoint chính thức
Thời gian mỗi run	trước tối ưu: 4,5 giây/bước, 6,2 giờ/run (2 run song song); sau tối ưu: 1,45 giây/bước, khoảng 2,0 giờ/run (B seed 7: 1,91 giờ; A+B seed 7: 2,11 giờ)
Vì sao 5.000 bước	20.000 bước như bài báo mất khoảng 13 giờ/run trên T4, vượt giới hạn 12 giờ/phiên; mọi biến thể dùng cùng số bước
Tối ưu nạp dữ liệu	spaCy xử lý theo lô, bỏ NER và lemmatizer: nhanh gấp 3,1 lần; từ khóa trích ra giống hệt (kiểm tra 3.000 câu thật)
Các phiên đã chạy	chạy thử dữ liệu giả (06/10); chuẩn bị dữ liệu đánh giá và đánh giá checkpoint chính thức (07/10); huấn luyện 1: baseline, A

	seed 12345 (08/10); huấn luyện 2: 8 run (08–09/10); huấn luyện cuối: B, A+B seed 7 (09/10); đánh giá toàn bộ 12 run (09/10)
Dữ liệu đánh giá	FashionIQ val: 15.415 ảnh, 3 nhóm sản phẩm; CIRCO val: 220 truy vấn trên 123.403 ảnh COCO; Δ tính trên 5.000 cặp COCO val2017

Phụ lục B. Thuật ngữ, tên riêng và viết tắt

Thuật ngữ	Cách đọc	Viết tắt của	Nghĩa
AdamW	a-đam đáp-bờ-liu	Adam with decoupled Weight decay	thuật toán tối ưu dùng để cập nhật φ
an-pha		ký hiệu α (alpha)	hệ số của Δ trong cải tiến B
AP	ây-pi	Average Precision	trung bình Precision tại các vị trí có kết quả đúng
baseline	bây-lai		mốc so sánh: LinCIR gốc do nhóm tự huấn luyện cùng cấu hình
batch	bát		lô dữ liệu xử lý cùng lúc trong một bước (ở đây 512 câu)
Boolean	bu-li-ần		mô hình truy xuất khớp chính xác theo biểu thức AND, OR, NOT
bootstrap	bút-xtrép	paired bootstrap	lấy mẫu lại các truy vấn 10.000 lần để ước lượng khoảng tin cậy của chênh lệch
CC3M	xê-xê ba em	Conceptual Captions	bộ khoảng 3 triệu cặp ảnh

		3 Million	– chú thích lấy từ web
checkpoint	chếch-poi		trọng số mô hình được lưu tại một bước huấn luyện
chỉ mục ngược		inverted index	bảng tra từ → danh sách tài liệu chứa từ đó
CIR	xi-ai-a	Composed Image Retrieval	truy xuất ảnh kết hợp: truy vấn gồm ảnh tham chiếu và câu mô tả thay đổi
CIRCO	xơ-cô	Composed Image Retrieval on Common Objects in context	bộ dữ liệu CIR trên ảnh đời thực COCO, mỗi truy vấn có nhiều ảnh đúng
CIRR	xi-ai-a-a	Composed Image Retrieval on Real-life images	bộ dữ liệu CIR ảnh đời thực; nhóm chưa dùng được vì chưa được cấp quyền ảnh
CLIP	clíp	Contrastive Language–Image Pre-training	mô hình của OpenAI đưa ảnh và văn bản vào cùng một không gian vector
COCO	cô-cô	Common Objects in COntext	bộ ảnh đời thực của Microsoft; val2017 là tập kiểm định năm 2017
cosine	cô-sin	cosine similarity	độ tương đồng giữa hai vector, từ −1 đến 1, càng lớn càng giống
CPU	xi-pi-du	Central Processing Unit	bộ xử lý trung tâm
CVPR	xi-vi-pi-a	Conference on Computer Vision and Pattern Recognition	hội nghị hàng đầu về thị giác máy tính

FashionIQ	pha-sần ai-kiu		bộ dữ liệu CIR về thời trang (váy, áo sơ mi, áo phông), mỗi truy vấn có 1 ảnh đúng
fp16	ép-pi mười sáu	floating point 16-bit	số thực 16 bit, giúp huấn luyện nhanh và tốn ít bộ nhớ
GB	ghi-ga-bai	gigabyte	đơn vị dung lượng
GPU	gi-pi-du	Graphics Processing Unit	bộ xử lý đồ họa, dùng để huấn luyện mô hình
IDF	ai-đi-ép	Inverse Document Frequency	tần suất tài liệu nghịch đảo: từ càng hiếm, trọng số càng cao
InfoNCE	in-phô en-xi-i	Info Noise-Contrastive Estimation	hàm mất mát đối sánh: kéo cặp đúng lại gần, đẩy các mẫu âm ra xa
Kaggle	ca-gồ		nền tảng của Google cho chạy notebook với GPU miễn phí theo hạn mức
khoảng tin cậy 95%		95% confidence interval	khoảng chứa chênh lệch thật với độ tin cậy 95%; nằm hẳn dưới 0 nghĩa là chắc chắn kém hơn
L SMP	hàm mất mát SMP	loss of Self-Masking Projection	hàm MSE của LinCIR
lam-đa		ký hiệu λ (lambda)	trọng số của InfoNCE trong cải tiến A
LayerNorm	lay-ơ noóc	Layer Normalization	lớp chuẩn hóa giá trị trong mạng nơ-ron
LinCIR	lin-kơ, tác giả	Language-only training for	phương pháp của bài báo: huấn luyện CIR chỉ bằng

	đọc như linker	Composed Image Retrieval	văn bản
mAP	em-ây-pi	mean Average Precision	trung bình của AP trên các truy vấn
mAP@5	em-ây-pi tại 5	mean Average Precision at 5	mAP chỉ xét 5 kết quả đầu
mAP@K	em-ây-pi tại K	mean Average Precision at K	mAP chỉ xét K kết quả đầu
MB	mê-ga-bai	megabyte	đơn vị dung lượng, 1.000 MB ≈ 1 GB
Midjourney	mít-giơ-ni		dịch vụ sinh ảnh từ văn bản; mã nguồn dùng thêm các câu prompt của dịch vụ này
modality gap	mô-đa-li-ti ghép		khoảng cách giữa vùng vector ảnh và vùng vector văn bản trong CLIP
MSE	em-ét-i	Mean Squared Error	sai số bình phương trung bình giữa hai vector
NAVER	nây-vơ		tập đoàn công nghệ Hàn Quốc, nơi các tác giả làm việc
NVIDIA T4	en-vi-đi-a ti-pho		loại GPU 16 GB mà Kaggle cung cấp
p	p (p-value)	probability value	xác suất thấy mức chênh này nếu cải tiến thật ra không có tác dụng; $p < 0,05$ là có ý nghĩa
phi		ký hiệu φ (phi)	mạng chiếu 3 lớp, phần duy nhất được huấn luyện

Pic2Word	píc-tu-ươd	Picture to Word	phương pháp zero-shot CIR trước LinCIR (CVPR 2023), học φ bằng ảnh
Precision	pri-xi-giần		độ chính xác: tỉ lệ kết quả trả về là đúng
prompt	prôm		câu mô tả dùng để yêu cầu mô hình sinh ảnh
R@10	Recall tại 10	Recall at 10	tỉ lệ truy vấn có ảnh đích trong 10 kết quả đầu
R@50	Recall tại 50	Recall at 50	tỉ lệ truy vấn có ảnh đích trong 50 kết quả đầu
R@K	Recall tại K	Recall at K	tỉ lệ truy vấn có ảnh đích trong K kết quả đầu
Recall	ri-con		độ phủ: tỉ lệ kết quả đúng được tìm thấy
run	ran		một lần huấn luyện với một cấu hình và một seed
SEARLE	xơ-lơ	zero-Shot composEd imAge Retrieval with textuaL invErsion	phương pháp zero-shot CIR trước LinCIR (ICCV 2023), học φ bằng ảnh
seed	xít	random seed	giá trị khởi tạo bộ sinh số ngẫu nhiên; chạy 3 seed để kiểm tra độ ổn định
Self-Masking Projection	xen ma-xking prô-giéc-sần	SMP	chiếu tự che: che từ khóa, thay bằng token do φ tạo từ chính câu đó
spaCy	xpây-xi		thư viện xử lý ngôn ngữ tự nhiên, dùng để tìm tính từ và danh từ
token	tô-kần		đơn vị đầu vào của bộ mã

			hóa văn bản (một từ hoặc mảnh từ)
tokenizer	tô-kần-nai-dơ		bộ tách câu thành các token
transformers	tran-xpho-mơ		thư viện mô hình học sâu mã nguồn mở của Hugging Face
tô		ký hiệu τ (tau), temperature	nhiệt độ của InfoNCE, điều chỉnh độ "gắt" khi so sánh
val	va-li-đây-sần	validation	tập kiểm định có đáp án công khai
vector	véc-tơ		dãy số biểu diễn một ảnh hoặc một câu
ViT-B/32	vít B ba hai	Vision Transformer – Base, patch 32 × 32	phiên bản CLIP nhỏ, dùng để chạy thử trên Mac
ViT-L	vít L	Vision Transformer – Large	bộ mã hóa ảnh cỡ lớn của CLIP
ViT-L/14	vít L mười bốn	Vision Transformer – Large, patch 14 × 14	phiên bản CLIP nhóm dùng
weight decay	uết đi-cây		phạt trọng số lớn để giảm quá khớp
Wilcoxon	uyn-cốc-xơn	Wilcoxon signed-rank test	kiểm định phi tham số so sánh hai kết quả ghép cặp
zero-shot	di-rô sót		không dùng dữ liệu có nhãn của chính bài toán khi huấn luyện
âm tính giả		false negative	ảnh đúng yêu cầu nhưng không được gán nhãn là đáp án

ép-xi-lon		ký hiệu ε (epsilon)	nhiễu ngẫu nhiên theo phân phối chuẩn
đen-ta		ký hiệu Δ (delta)	vector từ tâm vùng văn bản tới tâm vùng ảnh

Phụ lục C. Cách đọc ký hiệu trên slide

Ký hiệu	Đọc là	Nghĩa
φ	"phi"	Mạng chiếu 3 lớp, phần duy nhất được huấn luyện; biến một vector (ảnh hoặc câu) thành một token
[$]	"token giả" (hoặc "token đô-la")	Vị trí trong câu được thay bằng đầu ra của φ; "a photo of [$] that is blue" đọc là "a photo of token giả that is blue"
Δ	"đen-ta"	Vector chênh lệch: tâm vector ảnh trừ tâm vector văn bản
ε	"ép-xi-lon"	Nhiễu ngẫu nhiên theo phân phối chuẩn
u · ε	"u nhân ép-xi-lon"	Nhiễu của LinCIR; u là hệ số ngẫu nhiên từ 0 đến 1
α	"an-pha"	Hệ số của Δ trong cải tiến B (0,5)
λ	"lam-đa"	Trọng số của InfoNCE trong cải tiến A (0,5)
τ	"tô"	Nhiệt độ của InfoNCE (0,07)
z_c	"z c"	Vector của câu gốc
ẑ_c	"z c mũ"	Vector của câu đã che từ khóa bằng token giả
L_SMP	"hàm mất mát SMP"	Hàm mất mát MSE của Self-Masking Projection
R@K, R@10	"Recall tại K", "Recall tại 10"	Tỉ lệ truy vấn có ảnh đích trong K kết quả đầu
mAP@5	"m-A-P tại 5"	Độ chính xác trung bình trên 5 kết quả đầu

±	"cộng trừ"	Độ lệch chuẩn qua 3 seed; "26,50 ± 0,04" đọc là "26,50 cộng trừ 0,04"
p = 0,006	"p bằng không phẩy không không sáu"	Xác suất thấy mức chênh này nếu cải tiến thật ra không có tác dụng
InfoNCE, CLIP	"in-phô en-xi-i", "clíp"	Đọc thẳng tên tiếng Anh; tương tự baseline, seed, batch