TÌM KIẾM VÀ TRUY XUẤT THÔNG TIN · NHÓM 8

Huấn luyện hiệu quả chỉ bằng văn bản cho truy xuất ảnh kết hợp Zero-shot



Tái hiện và cải tiến LinCIR (CVPR 2024)

Giảng viên: TS. Đào Thị Thuý Quỳnh · Lớp M25CQHT02-B
Đào Văn Tâm · Lâm Thành Trung · Nguyễn Xuân Tùng
Trần Quang Đức Dũng · Mekdala Nounou

Truy vấn gồm một ảnh tham chiếu và một câu mô tả thay đổi

Ảnh tham chiếu



+ văn bản điều chỉnh

"*is shiny and silver with shorter sleeves*"
"*fit and flare*"

hệ thống CIR tìm trong kho ảnh

Ảnh đích



CIR

- Giữ đặc điểm của ảnh
- Áp dụng phần thay đổi
- Trả về danh sách ảnh có xếp hạng

Dữ liệu bộ ba đắt và nhỏ nên cần CIR không cần mẫu

46,6k

bộ ba FashionIQ

28,8k

bộ ba CIRR

0

bộ ba dùng trong zero-shot CIR

Hệ quả

- **Có giám sát:** gán nhãn thủ công, khó mở rộng sang lĩnh vực mới
- **Zero-shot:** huấn luyện trên dữ liệu sẵn có, đánh giá trực tiếp trên bộ CIR

CIR là truy xuất có xếp hạng, đo bằng R@K và mAP@K

Chương I

- Nhu cầu → truy vấn → xếp hạng
- Precision, Recall
- Boolean + chỉ mục ngược: khớp chính xác

Độ đo của CIR

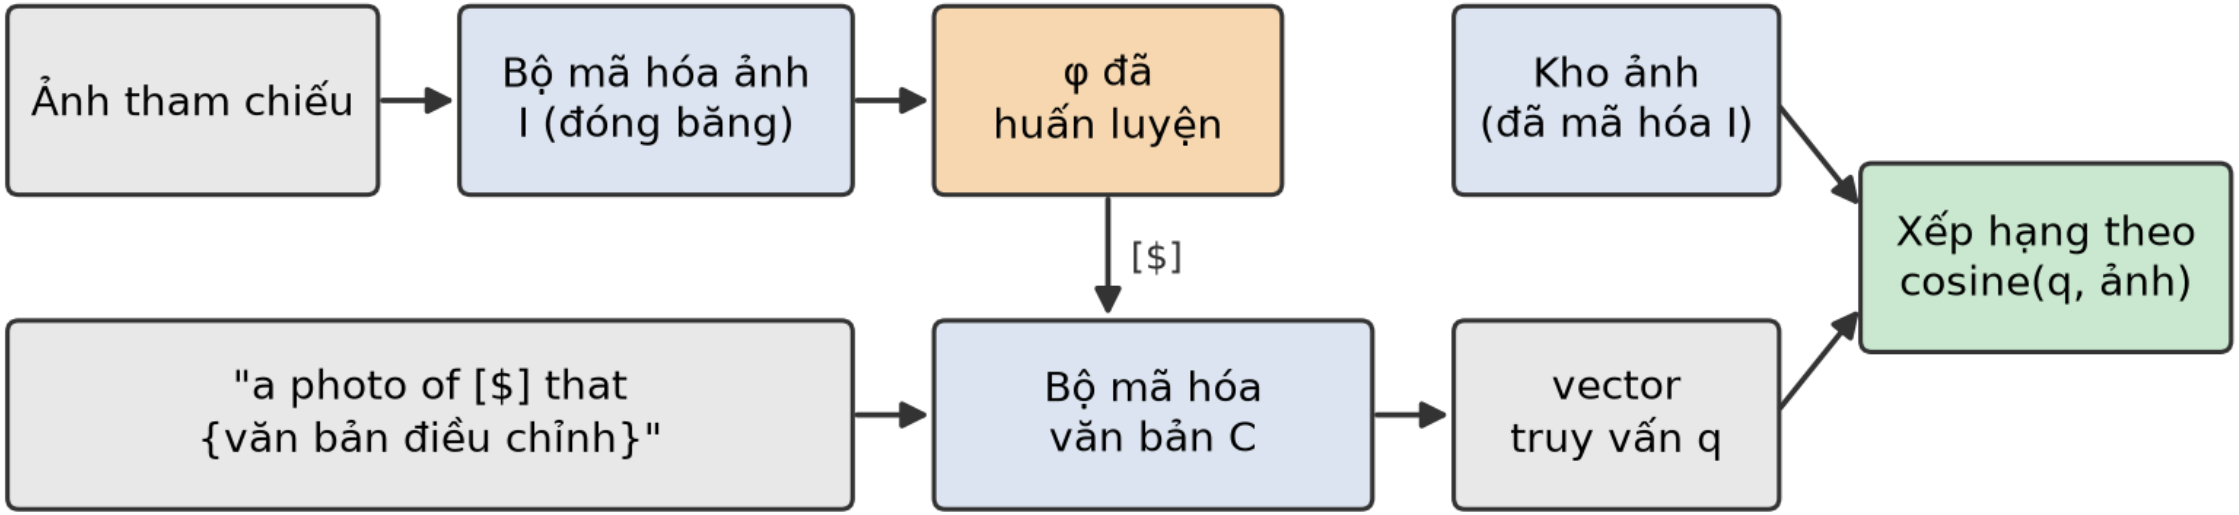
- R@K: ảnh đích nằm trong top-K
- mAP@K: nhiều ảnh đúng, thưởng vị trí cao

Tìm kiếm vector

- Ảnh, truy vấn → vector CLIP
- Xếp hạng theo cosine

Nhóm báo cáo R@10, R@50 trên FashionIQ và mAP@K trên CIRCO

Ảnh được biến thành một “từ giả” [$] trong câu truy vấn



Pic2Word và SEARLE học với câu mẫu cố định và cần ảnh

Câu mẫu cố định

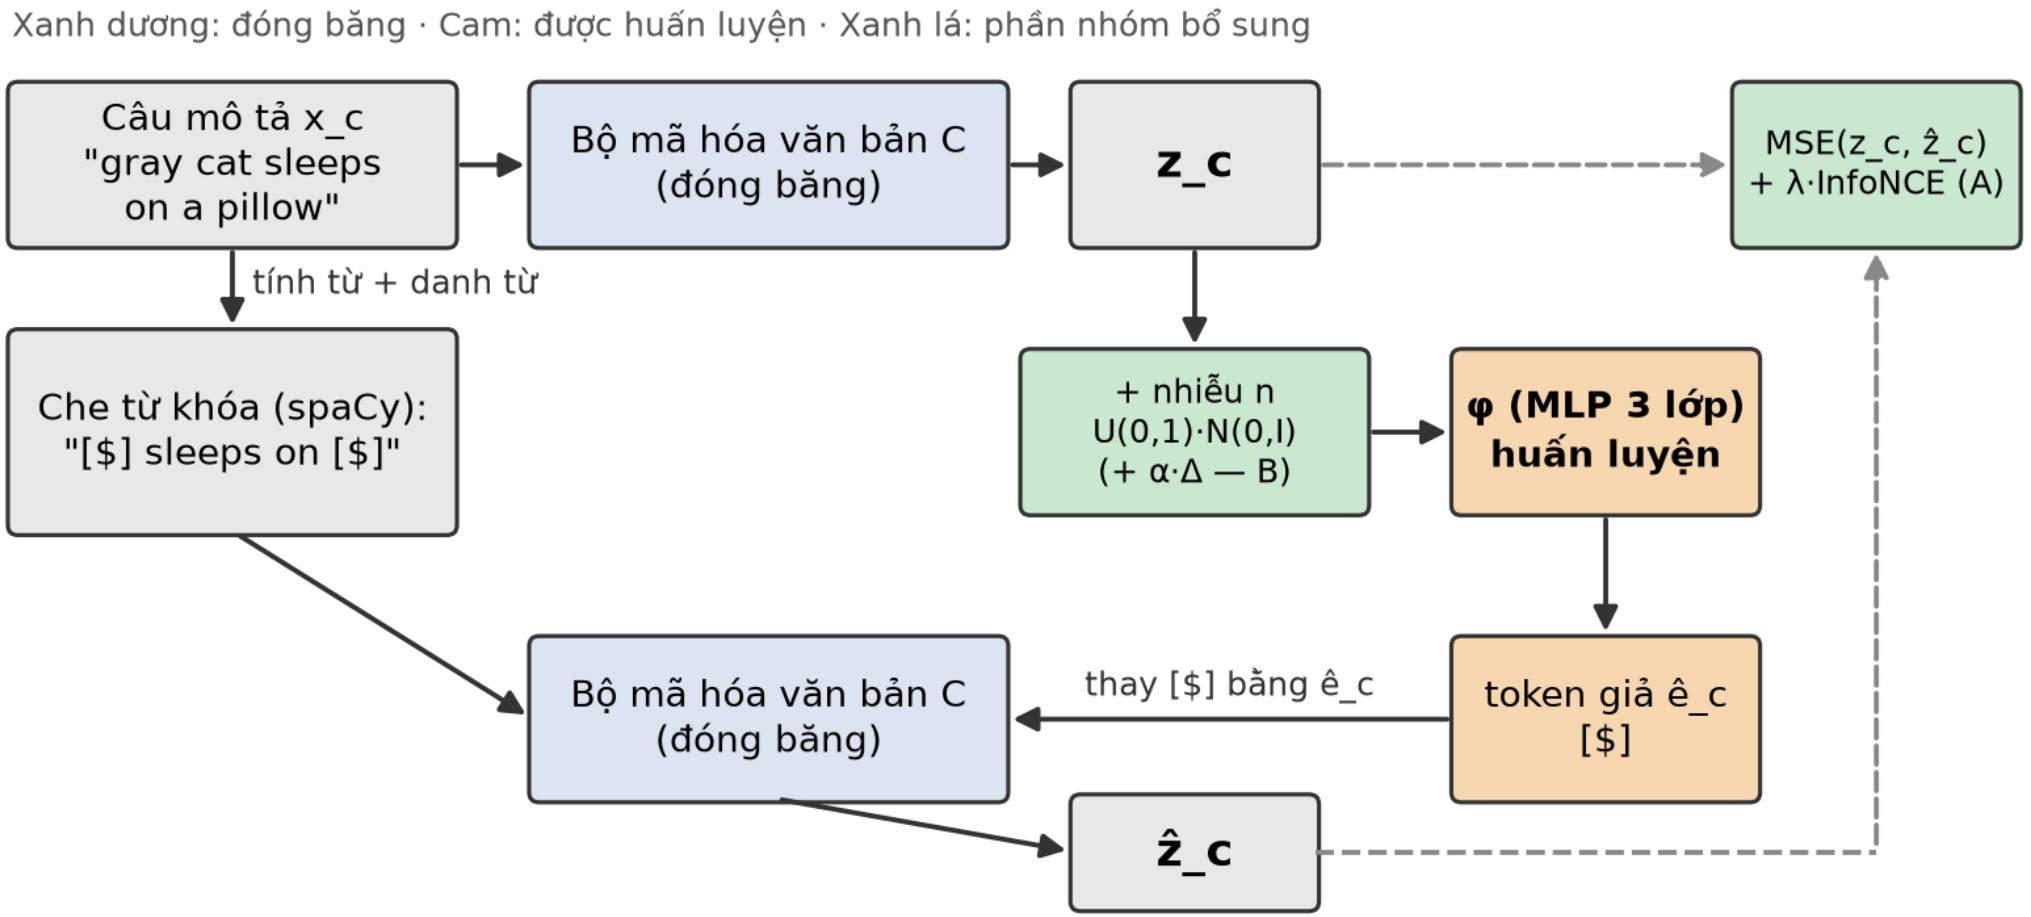
- Chỉ học trên “a photo of [$]”
- Kém với câu điều chỉnh phức tạp
- Giảm khi tăng kích thước backbone

Cần ảnh khi huấn luyện

- Chạy bộ mã hóa ảnh mỗi bước
- Ảnh CC3M ≈ 430 GB, chú thích 125 MB

LinCIR bỏ cả hai hạn chế: chỉ huấn luyện bằng văn bản tự nhiên đa dạng

LinCIR học từ giả chỉ bằng văn bản nhờ Self-Masking Projection



Nhiễu giúp ϕ dùng được vector ảnh dù hai miền lệch nhau

0,82

khoảng cách tâm ảnh – văn bản

0,26

cosine trung bình cặp ảnh – chú thích

Nhiễu của LinCIR

- $\mathbf{n = u \cdot \varepsilon}$
- $u \sim U(0,1)$, $\varepsilon \sim N(0, I)$

Ý nghĩa

- ϕ học trên vector văn bản có nhiễu nên vẫn hoạt động khi nhận vector ảnh

Mã nguồn chạy trên môi trường mới với sai lệch bằng 0

0,00

sai lệch so với CLIP gốc

4

lỗi mã gốc đã sửa

Đã làm

- Viết lại encoder văn bản
- Thay tokenizer, “$” = 259
- Kiểm chứng ViT-B/32, ViT-L/14

Bài báo ≠ mã nguồn

- ϕ không có LayerNorm
- Thêm prompt Midjourney
- Từ khóa giữ cả từ hạn định

Checkpoint chính thức tái hiện khớp bài báo, lệch tối đa 0,77 điểm

FashionIQ val	Dress R@10	Dress R@50	Shirt R@10	Shirt R@50	Toptee R@10	Toptee R@50	TB R@10	TB R@50
Bài báo	20,92	42,44	29,10	46,81	28,81	50,18	26,28	46,49
Nhóm chạy lại	**21,32**	**42,19**	**28,70**	**46,76**	**29,02**	**49,41**	**26,35**	**46,12**

0,77

điểm lệch lớn nhất

10,50

CIRCO val mAP@5 (mốc)

100%

thứ hạng giống hệt khi chạy lại

Cải tiến A: thêm InfoNCE để từ giả phân biệt được các câu

Vấn đề

- MSE không phạt việc gần câu khác
- Đánh giá lại là xếp hạng

Giải pháp

- **L = L_SMP + 0,5 · InfoNCE**
- τ = 0,07 · 511 mẫu âm trong batch

+2%

thời gian mỗi bước (1,474 so với 1,448 giây)

25,54

FashionIQ TB R@10 của A (baseline 25,90)

Cải tiến B: dịch nhiễu theo hướng của modality gap

Nhiễu của LinCIR

- Đẳng hướng: làm mờ vùng văn bản
- Không hướng về vùng ảnh

Nhiễu có hướng

- **$n = 0{,}5 \cdot \Delta + u \cdot \varepsilon$**
- Δ = tâm ảnh – tâm văn bản

13,87

độ lớn của Δ (5.000 cặp COCO)

COCO val

độc lập với FashionIQ, CIRCO

Mọi biến thể dùng cùng cấu hình, 3 seed và kiểm định theo truy vấn

Cấu hình

- ViT-L/14, batch 512
- 5.000 bước
- 3 seed / biến thể

Đánh giá

- FashionIQ val
- CIRCO val
- Bootstrap + Wilcoxon

Vận hành Kaggle

- 2 × T4, 2 run song song
- Không vượt 12 giờ/phiên
- Nạp dữ liệu nhanh ×3,1

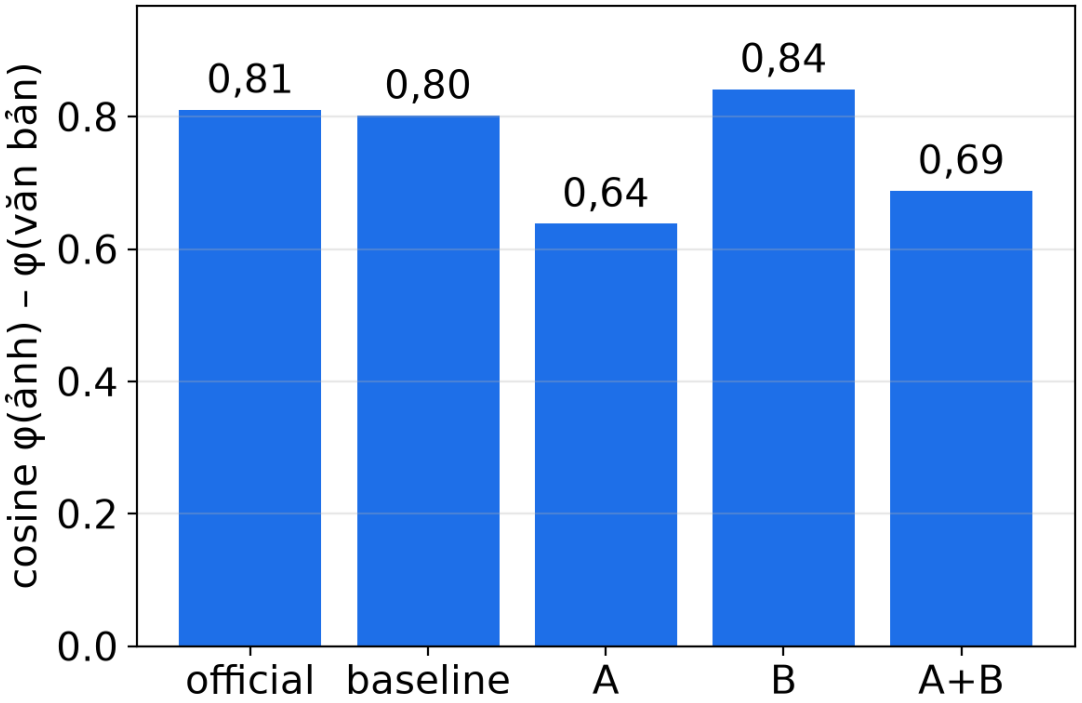
Chỉ khác đúng thành phần cải tiến → chênh lệch là do cải tiến, không do cấu hình

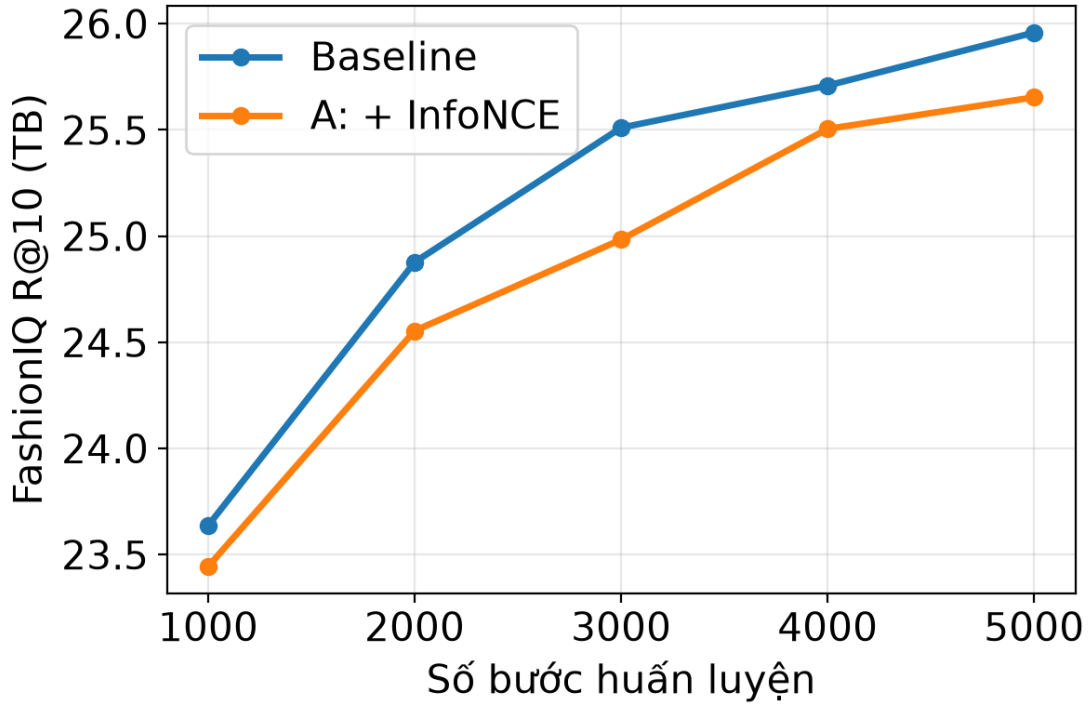
Nhiễu có hướng (B) tốt hơn LinCIR, InfoNCE (A) làm giảm hiệu năng

Biến thể	FIQ TB R@10	FIQ TB R@50	CIRCO mAP@5
Baseline	25,90 ± 0,24	45,53 ± 0,23	10,47 ± 0,10
A: + InfoNCE	25,54 ± 0,14	45,16 ± 0,21	8,02 ± 0,44
B: + nhiễu có hướng	26,50 ± 0,04	46,79 ± 0,07	10,94 ± 0,35
A + B	25,44 ± 0,13	45,36 ± 0,16	7,81 ± 0,19

B: FashionIQ R@10 +0,60 ($p = 0,006$), R@50 +1,27 ($p < 0,001$)
A: CIRCO mAP@5 –2,45, KTC 95% [–3,95; –1,07]; A+B tương tự

Vì sao: B làm ϕ nhất quán hơn giữa ảnh và văn bản, A làm ngược lại





Kết luận: tính nhất quán qua modality gap quyết định chất lượng

Tái hiện khớp bài báo (lệch ≤ 0,77)
B tốt hơn có ý nghĩa, vượt cả checkpoint 20.000 bước
A giảm CIRCO mAP@5 2,45 điểm
ϕ nhất quán ảnh – văn bản là yếu tố then chốt

Hạn chế → hướng phát triển

- 5.000 bước → đủ 20.000
- Quét λ (A), α (B)
- Thêm CIRR, CIRCO test
- Hướng C: từ khóa theo IDF

Cảm ơn cô và các bạn đã theo dõi

Xin mời câu hỏi và góp ý!