TÌM KIẾM VÀ TRUY XUẤT THÔNG TIN · NHÓM 8

Huấn luyện hiệu quả chỉ bằng văn bản cho truy xuất ảnh kết hợp Zero-shot



Tái hiện và cải tiến LinCIR (CVPR 2024)

Giảng viên: TS. Đào Thị Thuý Quỳnh · Lớp M25CQHT02-B
Đào Văn Tâm · Lâm Thành Trung · Nguyễn Xuân Tùng
Trần Quang Đức Dũng · Mekdala Nounou

Phân công công việc của nhóm

Thành viên	Công việc chính	Hỗ trợ slide
Đào Văn Tâm (trưởng nhóm)	Chuyển đổi mã nguồn, kiểm chứng tương đương; chạy thực nghiệm trên Kaggle; trình bày	11
Lâm Thành Trung	Cải tiến A (InfoNCE); phân tích đường học	7, 9, 14
Nguyễn Xuân Tùng	Tái hiện checkpoint chính thức; khác biệt bài báo – mã nguồn	6, 12, 13, 15
Trần Quang Đức Dũng	Giao thức đánh giá, kiểm định thống kê; cải tiến B; modality gap	4, 8, 10, 13, 14
Mekdala Nounou	Tổng quan lý thuyết; phân tích định tính; thiết kế slides	3, 4, 5, 6, 15

Tâm trình bày; khi hỏi đáp, thành viên phụ trách trả lời phần của mình

Truy vấn gồm một ảnh tham chiếu và một câu mô tả thay đổi



Bài báo LinCIR (CVPR 2024) giải bài toán này mà không cần bộ ba gán nhãn: chỉ huấn luyện bằng văn bản.
Câu hỏi của nhóm: sửa hàm mất mát (A) hoặc sửa nhiễu (B) có giúp LinCIR truy xuất tốt hơn không?

CIR

- Giữ các đặc điểm của ảnh tham chiếu
- Thay đổi đúng như câu mô tả
- Trả về danh sách ảnh xếp hạng, đo bằng R@K và mAP@K

CIR là truy xuất có xếp hạng, đo bằng R@K và mAP@K

Chương I

- Nhu cầu › truy vấn › danh sách xếp hạng
- Đánh giá: Precision, Recall
- Boolean, chỉ mục ngược: khớp từ chính xác

Độ đo của CIR

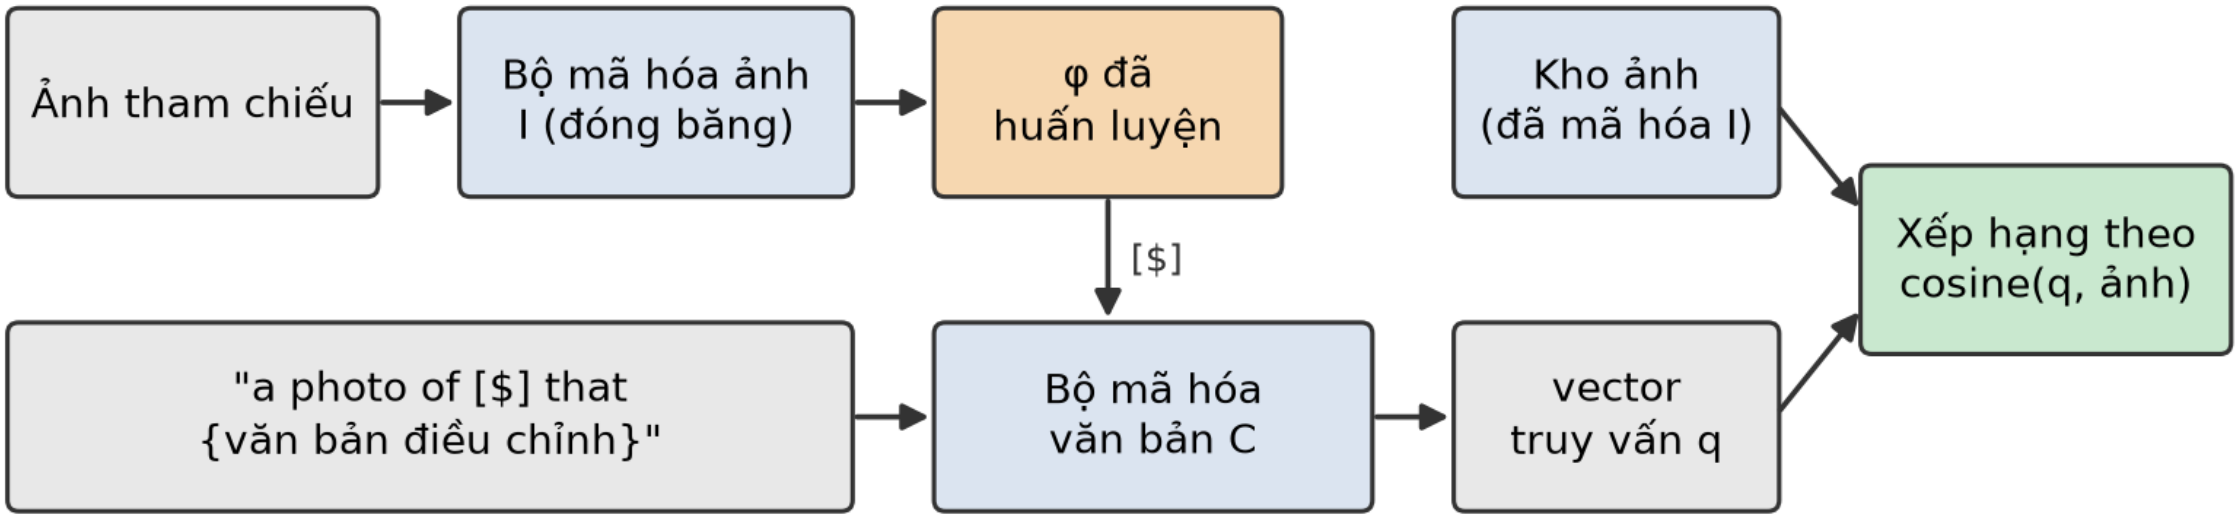
- R@K = số truy vấn có ảnh đích trong top-K / tổng số truy vấn
- mAP@K = trung bình AP@K, với AP@K = Σ P@k·rel(k) / min(K, số ảnh đúng)

Tìm kiếm vector

- Ảnh và truy vấn được mã hóa thành vector CLIP
- Xếp hạng ảnh theo độ tương đồng cosine

Nhóm đánh giá trên FashionIQ val (R@10, R@50) và CIRCO val (mAP@K), kiểm định bootstrap và Wilcoxon theo từng truy vấn

Ảnh được biến thành một “từ giả” [$] trong câu truy vấn



Chỉ học mạng chiếu ϕ; bộ mã hóa ảnh và văn bản của CLIP giữ nguyên

Bài báo LinCIR: huấn luyện truy xuất ảnh kết hợp chỉ bằng văn bản

Vấn đề

- Bộ ba ảnh – câu – ảnh đích phải gán nhãn tay: đắt và ít
- Pic2Word, SEARLE cần ảnh khi huấn luyện, chỉ học câu mẫu cố định

Ý tưởng LinCIR

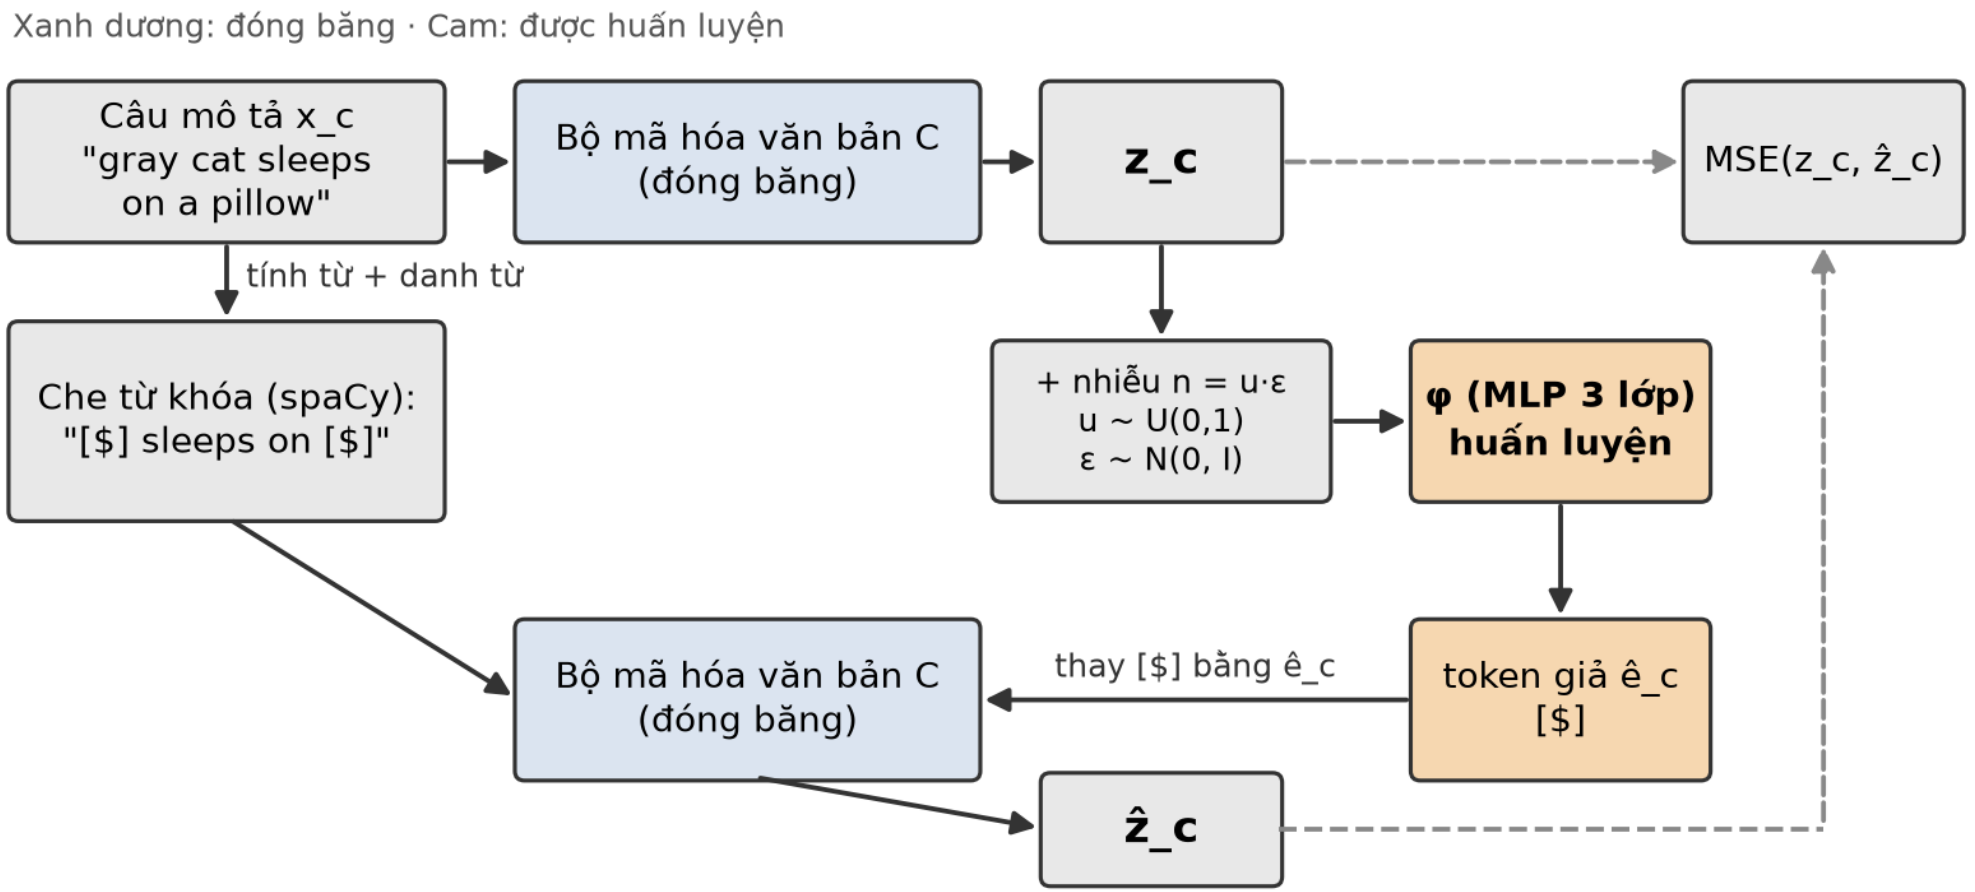
- Self-Masking Projection: học ϕ chỉ từ văn bản, không cần ảnh
- Thêm nhiễu khi huấn luyện để ϕ dùng được cho vector ảnh

Kết quả bài báo

- Tốt nhất trên 4 bộ đánh giá
- Huấn luyện nhanh hơn Pic2Word 6 lần, SEARLE 8,4 lần
- Vượt cả phương pháp có giám sát (FashionIQ)

Gu et al. (NAVER), CVPR 2024, mã nguồn công khai. **Hai thành phần chính: Self-Masking Projection và nhiễu khi huấn luyện**

LinCIR học từ giả chỉ bằng văn bản nhờ Self-Masking Projection



Nhiễu giúp ϕ dùng được vector ảnh dù hai miền lệch nhau

Modality gap của CLIP

- Ảnh, văn bản ở hai vùng tách biệt
- ϕ học trên văn bản, dùng cho ảnh

0,82

khoảng cách giữa tâm vector ảnh và tâm vector văn bản (5.000 cặp COCO)

Nhiễu của LinCIR

- Huấn luyện: ϕ nhận $z_c + u \cdot \varepsilon$
- $u \sim U(0, 1)$, $\varepsilon \sim N(0, I)$

0,26

cosine trung bình giữa một ảnh và chú thích của chính nó

Cải tiến A: thêm InfoNCE để từ giả phân biệt được các câu

Vấn đề

- MSE không phạt khi câu đã che gần cả các câu khác
- Nhưng đánh giá là bài toán xếp hạng

Giải pháp

- **L = L_SMP + 0,5 · InfoNCE**
- InfoNCE kéo về câu gốc, đẩy xa 511 câu khác (τ = 0,07)

+2%

thời gian mỗi bước tăng 2% (1,474 so với 1,448 giây)

H1

giả thuyết: A tăng R@K, mAP@K so với baseline

Cải tiến B: dịch nhiễu theo hướng của modality gap

Vấn đề

- Nhiễu u · ε đều theo mọi hướng
- Không dịch về phía vùng ảnh

Giải pháp: nhiễu có hướng

- **n = 0,5 · Δ + u · ε**
- Δ = tâm ảnh – tâm văn bản

13,87

độ lớn của Δ, tính trên 5.000 cặp COCO val2017 (khác tập đánh giá)

H2

giả thuyết: ϕ nhất quán hơn giữa ảnh và văn bản, nên R@K, mAP@K tăng

Dựng lại mã nguồn và chạy 4 biến thể × 3 seed trên Kaggle

0,00

sai lệch giữa encoder viết lại và CLIP gốc

4

lỗi trong mã gốc đã được sửa

Đã làm

- Viết lại encoder văn bản cho thư viện mới
- Thay tokenizer; token “$” có mã 259
- Kiểm chứng trên ViT-B/32 và ViT-L/14

Chạy trên Kaggle

- Baseline, A, B, A+B (H3: A+B có cộng hưởng không)
- 3 seed, 5.000 bước, chỉ khác thành phần cải tiến
- 2 GPU T4; nạp dữ liệu nhanh gấp 3,1 lần

Checkpoint chính thức tái hiện khớp bài báo, lệch tối đa 0,77 điểm

FashionIQ val	Dress R@10	Dress R@50	Shirt R@10	Shirt R@50	Toptee R@10	Toptee R@50	TB R@10	TB R@50
Bài báo	20,92	42,44	29,10	46,81	28,81	50,18	26,28	46,49
Nhóm chạy lại	**21,32**	**42,19**	**28,70**	**46,76**	**29,02**	**49,41**	**26,35**	**46,12**

0,77

điểm lệch lớn nhất so với bài báo

Bài báo khác mã nguồn (nhóm theo mã)

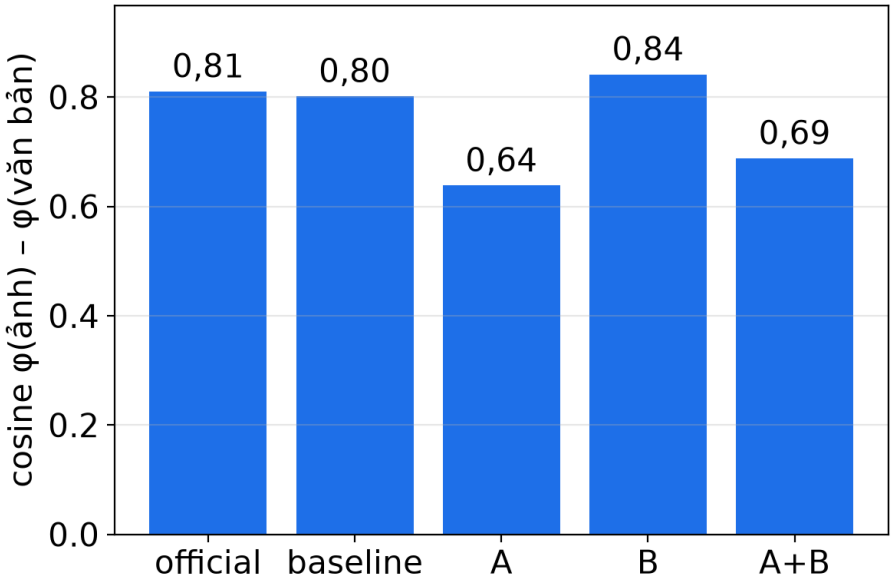
- ϕ trong mã không có LayerNorm (bài báo có)
- Mã nạp thêm câu prompt Midjourney
- Từ khóa bị che gồm cả mạo từ (a, the)

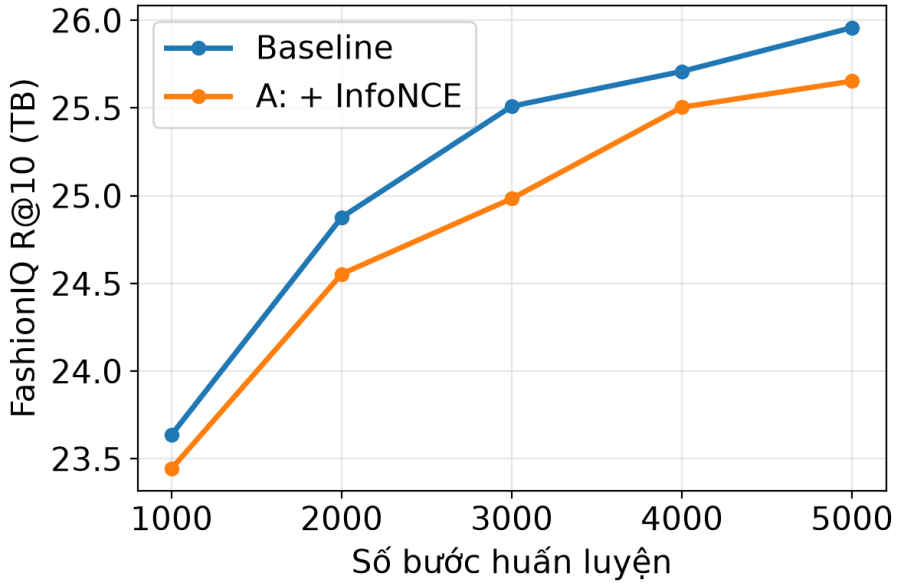
Nhiễu có hướng (B) tốt hơn LinCIR, InfoNCE (A) làm giảm hiệu năng

Biến thể	FashionIQ R@10	FashionIQ R@50	CIRCO mAP@5
Baseline	25,90 ± 0,24	45,53 ± 0,23	10,47 ± 0,10
A: + InfoNCE	25,54 ± 0,14	45,16 ± 0,21	8,02 ± 0,44
B: + nhiễu có hướng	**26,50 ± 0,04**	**46,79 ± 0,07**	**10,94 ± 0,35**
A + B	25,44 ± 0,13	45,36 ± 0,16	7,81 ± 0,19
Checkpoint chính thức (20.000 bước)	*26,35*	*46,12*	*10,50*

B tốt hơn baseline: FashionIQ R@10 +0,60 ($p = 0,006$), R@50 +1,27 ($p < 0,001$)
A kém hơn trên CIRCO: mAP@5 –2,45, khoảng tin cậy 95% [–3,95; –1,07]; A+B tương tự

Vì sao: B làm ϕ nhất quán hơn giữa ảnh và văn bản, A làm ngược lại





Trái: cosine giữa ϕ(ảnh) và ϕ(văn bản) của cùng một cặp; B cao nhất (0,84), A thấp nhất (0,64), cùng thứ tự với CIRCO mAP@5

Phải: A thấp hơn baseline ở mọi mốc huấn luyện, nên kết luận không phụ thuộc điểm dừng

Kết luận: H2 được ủng hộ, H1 và H3 bị bác bỏ



Ví dụ FashionIQ: B xếp đúng ảnh đích ở hạng 1; baseline trả về váy ngắn, tối màu

Đóng góp: dựng lại mã, tái hiện, hai cải tiến, kiểm định thống kê, phân tích cơ chế

Kết luận

- H2 (B) được ủng hộ: R@10 +0,60, R@50 +1,27
- H1 (A) bị bác bỏ: CIRCO mAP@5 giảm 2,45
- H3 (A+B) bị bác bỏ: kém baseline trên CIRCO
- Hạn chế: 5.000 bước, chưa quét λ, α

Cảm ơn cô và các bạn đã theo dõi

Xin mời câu hỏi và góp ý!