TÌM KIẾM VÀ TRUY XUẤT THÔNG TIN · NHÓM 8

Huấn luyện hiệu quả chỉ bằng văn bản cho truy xuất ảnh kết hợp Zero-shot



Tái hiện và cải tiến LinCIR (CVPR 2024)

Giảng viên: TS. Đào Thị Thuý Quỳnh · Lớp M25CQHT02-B
Đào Văn Tâm · Lâm Thành Trung · Nguyễn Xuân Tùng
Trần Quang Đức Dũng · Mekdala Nounou

Bài báo LinCIR: huấn luyện truy xuất ảnh kết hợp chỉ bằng văn bản

Vấn đề

- Bộ ba ảnh – câu – ảnh đích phải gán nhãn tay: đắt và ít
- Pic2Word, SEARLE cần ảnh khi huấn luyện, chỉ học câu mẫu cố định

Ý tưởng LinCIR

- Self-Masking Projection: học ϕ chỉ từ văn bản, không cần ảnh
- Thêm nhiễu khi huấn luyện để ϕ dùng được cho vector ảnh

Kết quả bài báo

- Tốt nhất trên 4 bộ đánh giá
- Huấn luyện nhanh hơn Pic2Word 6 lần, SEARLE 8,4 lần
- Vượt cả phương pháp có giám sát (FashionIQ)

Gu et al. (NAVER), CVPR 2024, mã nguồn công khai. **Nhóm dựng lại mã, tái hiện kết quả, chạy baseline, A, B, A+B trên Kaggle, kiểm định và phân tích nguyên nhân**

Truy vấn gồm một ảnh tham chiếu và một câu mô tả thay đổi

Ảnh tham chiếu



+ văn bản điều chỉnh

"*is shiny and silver with shorter sleeves*"
"*fit and flare*"

hệ thống CIR tìm trong kho ảnh

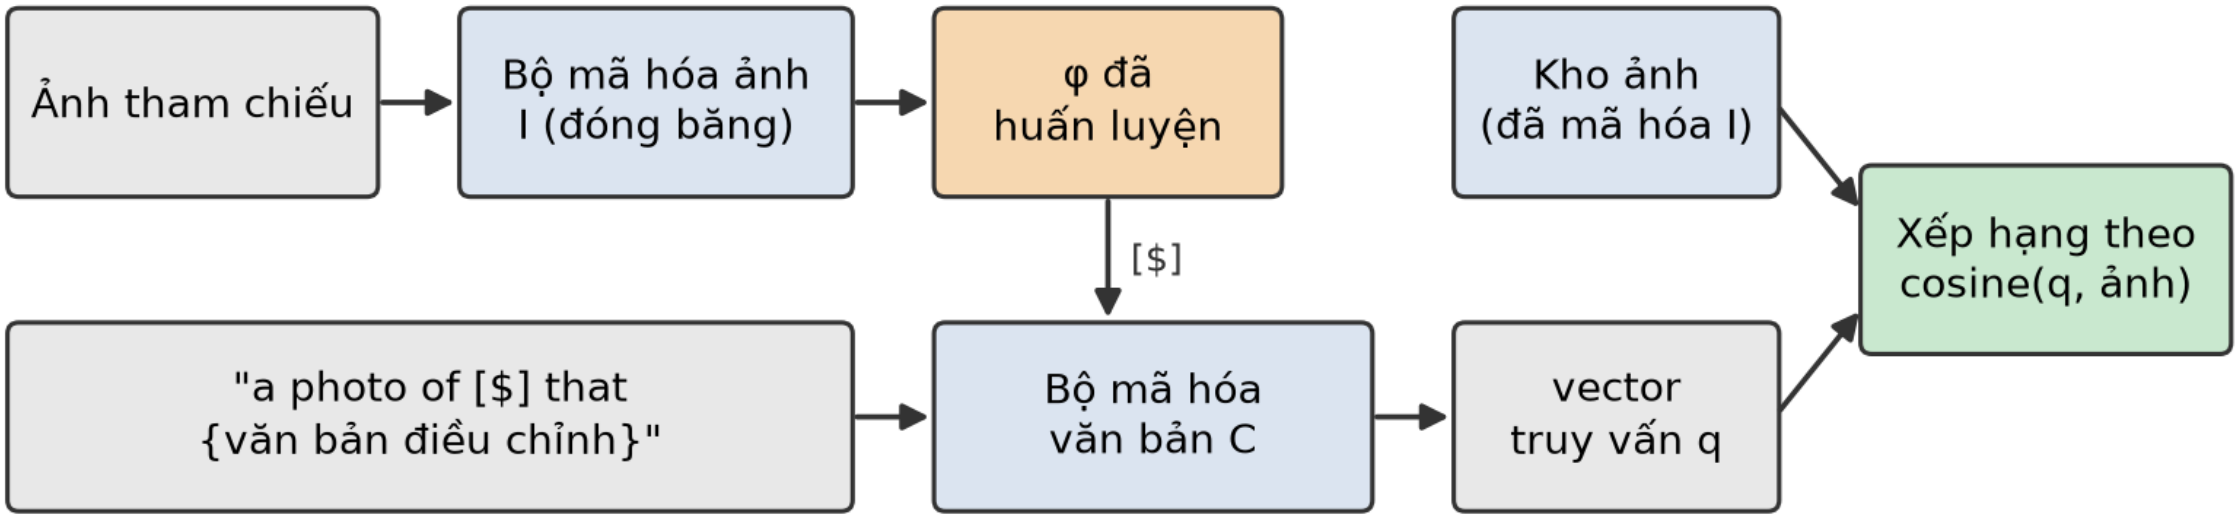
Ảnh đích



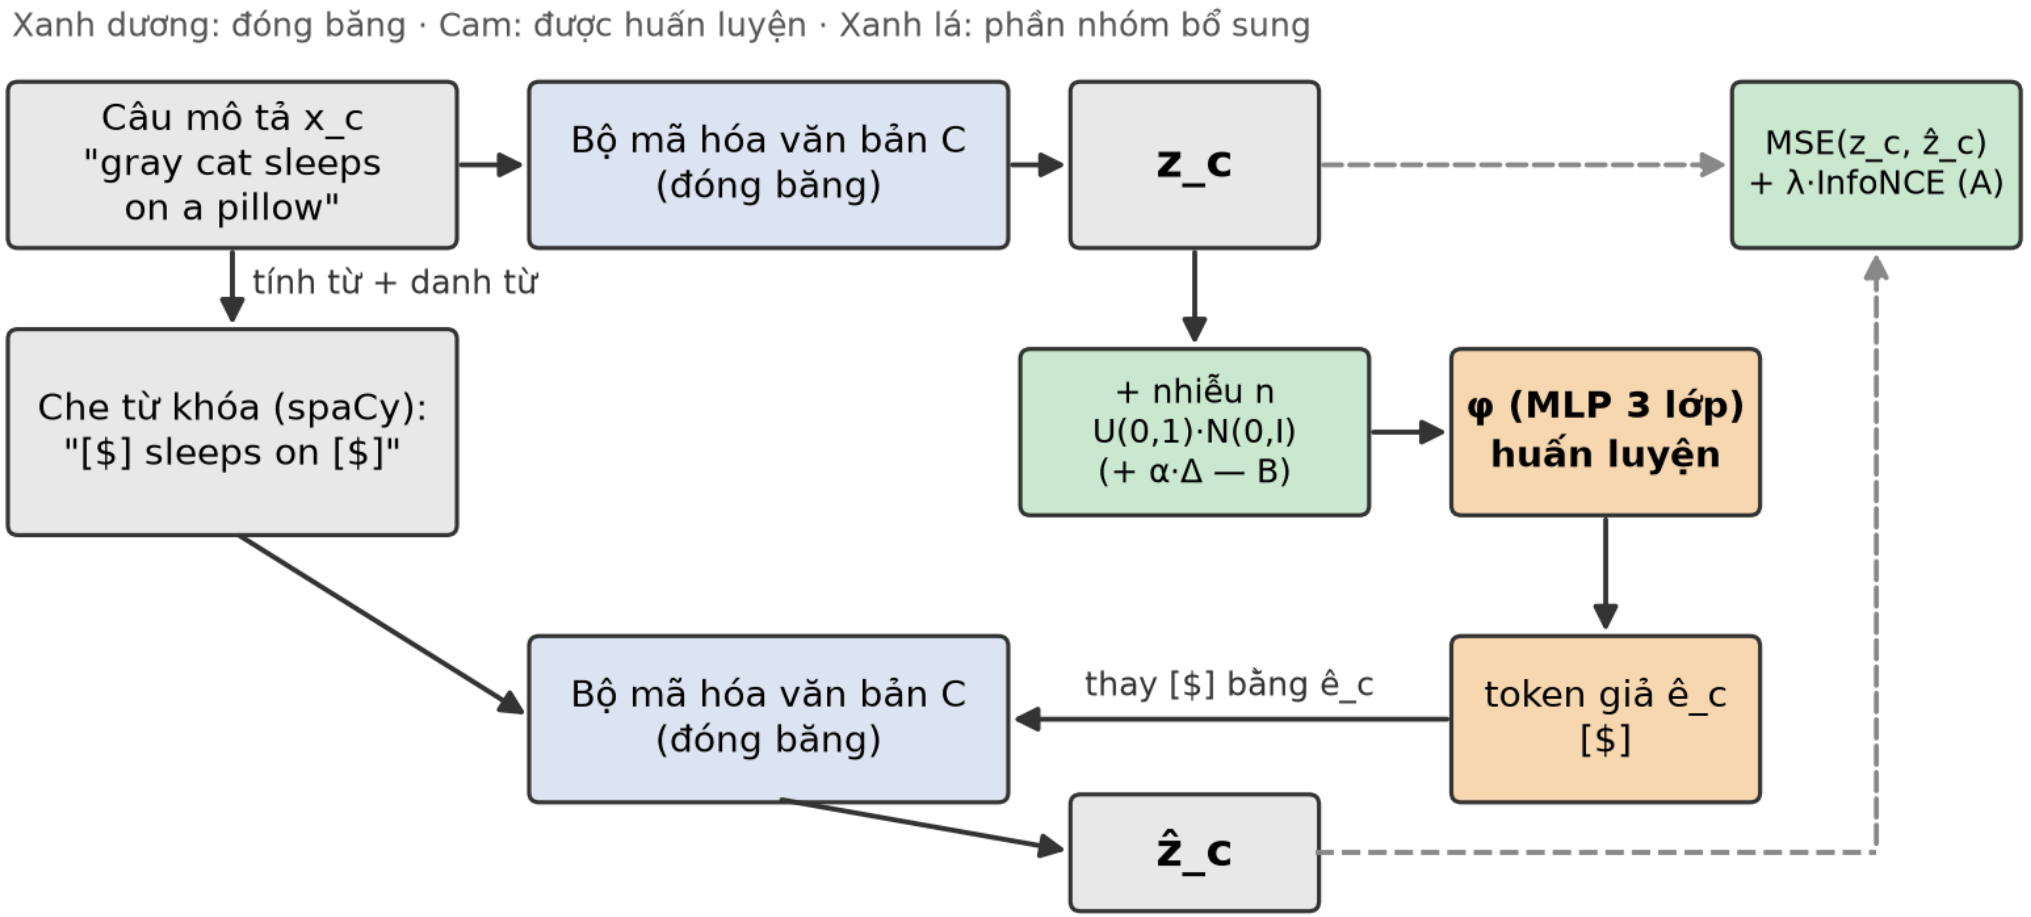
CIR

- Giữ các đặc điểm của ảnh tham chiếu
- Thay đổi đúng như câu mô tả
- Trả về danh sách ảnh xếp hạng, đo bằng R@K và mAP@K

Ảnh được biến thành một “từ giả” [$] trong câu truy vấn



LinCIR học từ giả chỉ bằng văn bản nhờ Self-Masking Projection



Cải tiến A: thêm InfoNCE để từ giả phân biệt được các câu

Vấn đề

- MSE không phạt khi câu đã che gần cả các câu khác
- Nhưng đánh giá là bài toán xếp hạng

Giải pháp

- **L = L_SMP + 0,5 · InfoNCE**
- InfoNCE kéo về câu gốc, đẩy xa 511 câu khác (τ = 0,07)

+2%

thời gian mỗi bước tăng 2% (1,474 so với 1,448 giây)

25,54

FashionIQ R@10 trung bình của A, thấp hơn baseline 25,90

Cải tiến B: dịch nhiễu theo hướng của modality gap

Nhiễu của LinCIR

- Nhiễu đều theo mọi hướng
- Không dịch về phía vùng ảnh

Nhiễu có hướng

- $\mathbf{n = 0{,}5 \cdot \Delta + u \cdot \varepsilon}$
- Δ = tâm ảnh – tâm văn bản

13,87

độ lớn của Δ, tính trên 5.000 cặp ảnh – chú thích COCO

COCO val

tập ảnh khác hẳn ảnh dùng để đánh giá (FashionIQ, CIRCO)

CIR là truy xuất có xếp hạng, đo bằng R@K và mAP@K

Chương I

- Nhu cầu › truy vấn › danh sách xếp hạng
- Đánh giá: Precision, Recall
- Boolean, chỉ mục ngược: khớp từ chính xác

Độ đo của CIR

- R@K: tỉ lệ truy vấn có ảnh đích trong K kết quả đầu
- mAP@K: có nhiều ảnh đúng, thưởng ảnh đúng xếp cao

Tìm kiếm vector

- Ảnh và truy vấn được mã hóa thành vector CLIP
- Xếp hạng ảnh theo độ tương đồng cosine

Nhóm báo cáo R@10, R@50 trên FashionIQ và mAP@K trên CIRCO

Mã nguồn chạy trên môi trường mới với sai lệch bằng 0

0,00

sai lệch giữa encoder viết lại và CLIP gốc

4

lỗi trong mã gốc đã được sửa

Đã làm

- Viết lại encoder văn bản cho thư viện mới
- Thay tokenizer; token “$” có mã 259
- Kiểm chứng trên ViT-B/32 và ViT-L/14

Bài báo ≠ mã nguồn

- Mạng ϕ trong mã không có LayerNorm
- Dữ liệu có thêm câu prompt Midjourney
- Cụm từ khóa bị che gồm cả từ hạn định

Mọi biến thể dùng cùng cấu hình, 3 seed và kiểm định theo truy vấn

Cấu hình

- 4 biến thể: baseline, A, B, A+B
- CLIP ViT-L/14, batch 512
- 5.000 bước, 3 seed mỗi biến thể

Đánh giá

- FashionIQ val (3 nhóm sản phẩm)
- CIRCO val (220 truy vấn)
- Kiểm định bootstrap và Wilcoxon theo từng truy vấn

Vận hành Kaggle

- 2 GPU T4, mỗi GPU một lần chạy
- Không vượt 12 giờ mỗi phiên
- Nạp dữ liệu nhanh gấp 3,1 lần

Các biến thể chỉ khác đúng thành phần cải tiến, nên chênh lệch kết quả là do cải tiến, không do cấu hình

Checkpoint chính thức tái hiện khớp bài báo, lệch tối đa 0,77 điểm

FashionIQ val	Dress R@10	Dress R@50	Shirt R@10	Shirt R@50	Toptee R@10	Toptee R@50	TB R@10	TB R@50
Bài báo	20,92	42,44	29,10	46,81	28,81	50,18	26,28	46,49
Nhóm chạy lại	**21,32**	**42,19**	**28,70**	**46,76**	**29,02**	**49,41**	**26,35**	**46,12**

0,77

điểm lệch lớn nhất so với bài báo

10,50

CIRCO val mAP@5 của checkpoint, dùng làm mốc

100%

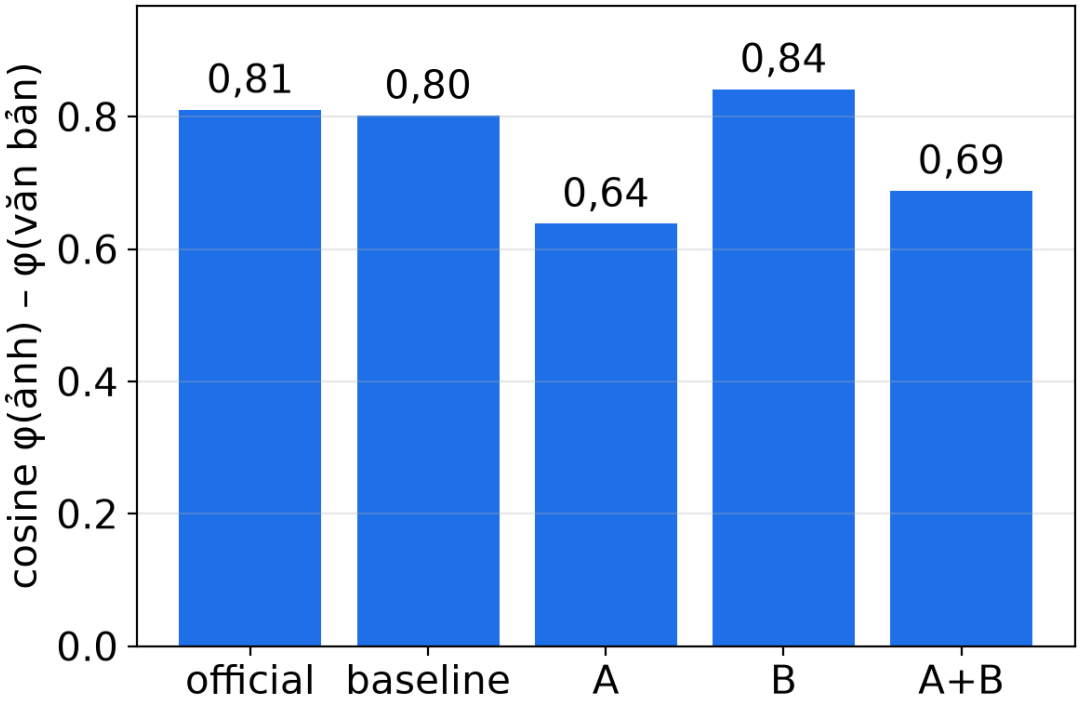
thứ hạng từng truy vấn giống hệt khi chạy lại

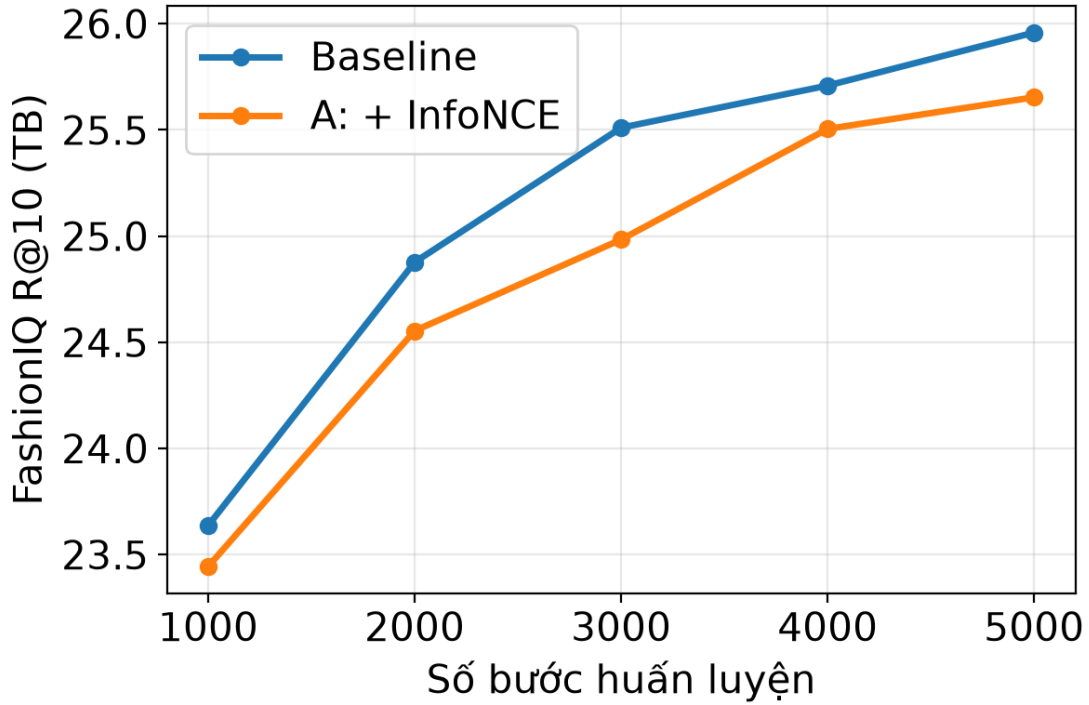
Nhiễu có hướng (B) tốt hơn LinCIR, InfoNCE (A) làm giảm hiệu năng

Biến thể	FashionIQ R@10	FashionIQ R@50	CIRCO mAP@5
Baseline	25,90 ± 0,24	45,53 ± 0,23	10,47 ± 0,10
A: + InfoNCE	25,54 ± 0,14	45,16 ± 0,21	8,02 ± 0,44
B: + nhiễu có hướng	26,50 ± 0,04	46,79 ± 0,07	10,94 ± 0,35
A + B	25,44 ± 0,13	45,36 ± 0,16	7,81 ± 0,19

B tốt hơn baseline: FashionIQ R@10 +0,60 ($p = 0,006$), R@50 +1,27 ($p < 0,001$)
A kém hơn trên CIRCO: mAP@5 –2,45, khoảng tin cậy 95% [–3,95; –1,07] nằm dưới 0; A+B tương tự

Vì sao: B làm ϕ nhất quán hơn giữa ảnh và văn bản, A làm ngược lại





Kết luận: tính nhất quán qua modality gap quyết định chất lượng

Tái hiện khớp bài báo, lệch tối đa 0,77 điểm
B tốt hơn có ý nghĩa thống kê, vượt cả checkpoint 20.000 bước
A làm CIRCO mAP@5 giảm 2,45 điểm
Yếu tố then chốt: ϕ xử lý ảnh nhất quán với văn bản

Hạn chế và hướng phát triển

- Mới huấn luyện 5.000 bước, cần đủ 20.000
- Chưa quét λ (A) và α (B)
- Chưa có CIRR, CIRCO test
- Hướng C: chọn từ khóa che theo IDF

Cảm ơn cô và các bạn đã theo dõi

Xin mời câu hỏi và góp ý!